LLMs

LLM

(vanilla)

LLMs

LLM

(ChatGPT, Gemini, Claude)

LLMs

우리는 Augment LLMs가 필요할까?

Augment LLMs

LLMs

Control이 어렵다

Microsoft Created a Twitter Bot to Learn From Users. It Quickly Became a Racist Jerk.

Share full article



Tay's Twitter account. The bot was developed by Microsoft's technology and research and Bing teams.

[Daniel Victor (March 2016), The New York Times: Microsoft Created a Twitter Bot to Learn From Users. It Quickly Became a Racist Jerk.]

LLMs

LLM

언어 기반 패턴 예측기

- 장기 목표 계획
- 질문/답변 상태 유지
- 메모리 기반 행동

기본 LLMs은 답변을 진행하면서,
위 내용들을 유지하기 어렵다

LLMs

제어 불가 (Lack of Control)

- 사용자의 워크플로우나 형식을 정확히 따르지 않을 수 있습니다.

LLMs

필요한 task를 잘 수행하지 못한다

지식의 한계 (knowledge)
최신성, 전문성 부족

표현의 한계 (Output Style)
형식적 엄밀함 부족

이해의 한계 (Understanding)
전문 분야 용어 이해 부족

기억의 한계 (Context Memory)
입력 데이터 처리량의 제약

[Mnih, Kavukcuoglu, Silver et al. (2015): Human Level Control through Deep Reinforcement Learning]

LLMs

성능 부족 (underperform)

- 최신 치료법 질문 → 학습 시점 정보 누락 → 오진 위험
- 계약서 작성 → 법적 효력 필요 → 모호한 문체 위험
- 전문 용어 미숙지 → 판단 실수 발생 위험
- Context Window 초과 → 핵심 내용 소실

LLMs

Vanilla Attention Mechanisms의 한계

Lost in the middle
(U-shaped Performance Curve)

[Liu, Lin, Hewitt et al. (2023): Lost in the Middle: How Language Models Use Long Contexts]

LLMs

Vanilla Attention Mechanisms의 한계

Tokens	Characters
13	24

안녕하세요. 여러분들 오늘은 어텐션에 대해

```
[14307, 171731, 13, 180115, 8635, 106820, 4740, 21252, 79549, 30609, 3107,
67946, 220]
```

Slides by Junseop So

[Liu, Lin, Hewitt et al. (2023): Lost in the Middle: How Language Models Use Long Contexts]

LLMs

Attention Mechanisms



[Liu, Lin, Hewitt et al. (2023): Lost in the Middle: How Language Models Use Long Contexts]

LLMs

초기 효과 Primacy Bias



Slides by Junseop So

[Liu, Lin, Hewitt et al. (2023): Lost in the Middle: How Language Models Use Long Contexts]

LLMs

최신효과 Recency Bias



[Liu, Lin, Hewitt et al. (2023): Lost in the Middle: How Language Models Use Long Contexts]

LLMs

중간 소실



[Liu, Lin, Hewitt et al. (2023): Lost in the Middle: How Language Models Use Long Contexts]

LLMs

환각 (Hallucination)

- 그럴듯한 거짓말을 합니다.
  (존재하지 않는 판례 생성)

LLMs

제어 불가 (Lack of Control)

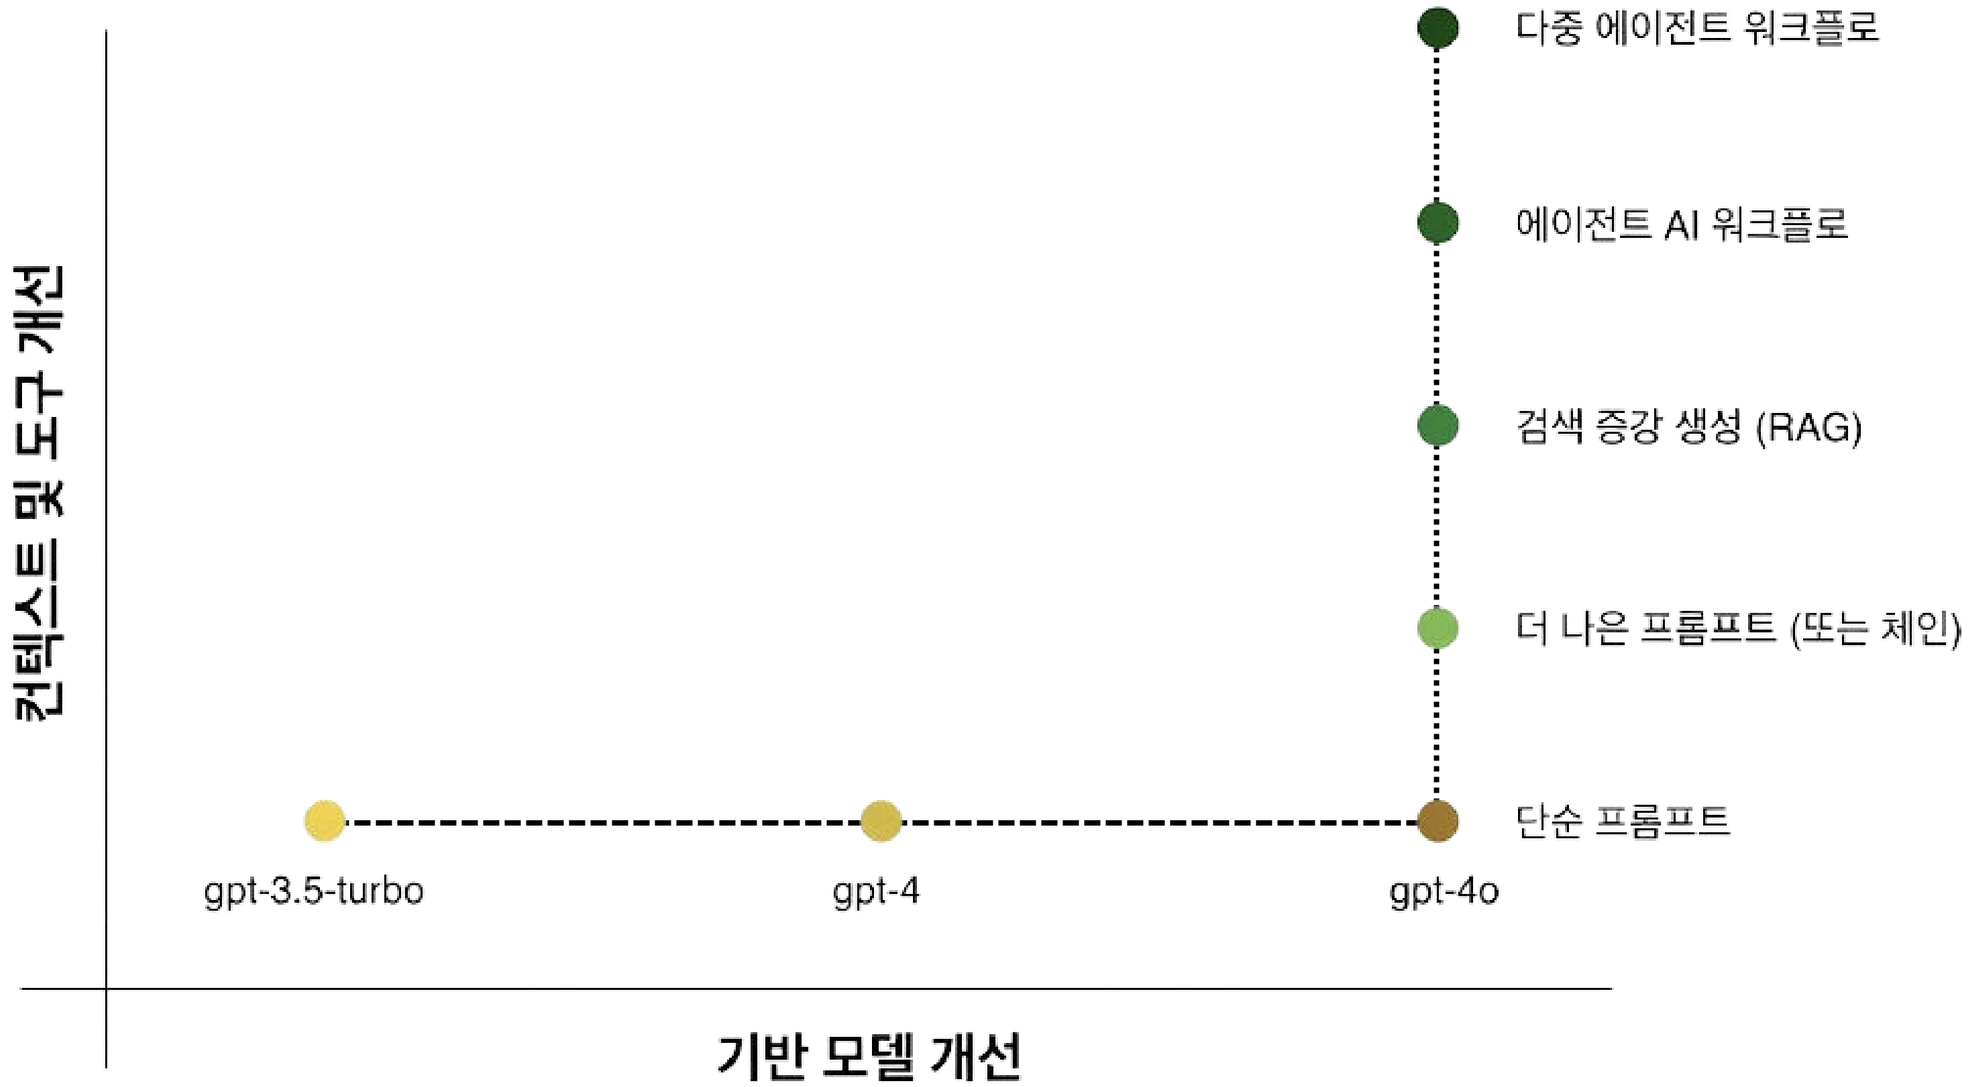
성능 부족 (underperform)

환각 (Hallucination)

Agent, Prompt & RAG



Vertical & Horizontal AI



Vertical AI

특정 도메인 워크플로우를 깊게 파고드는 서비스

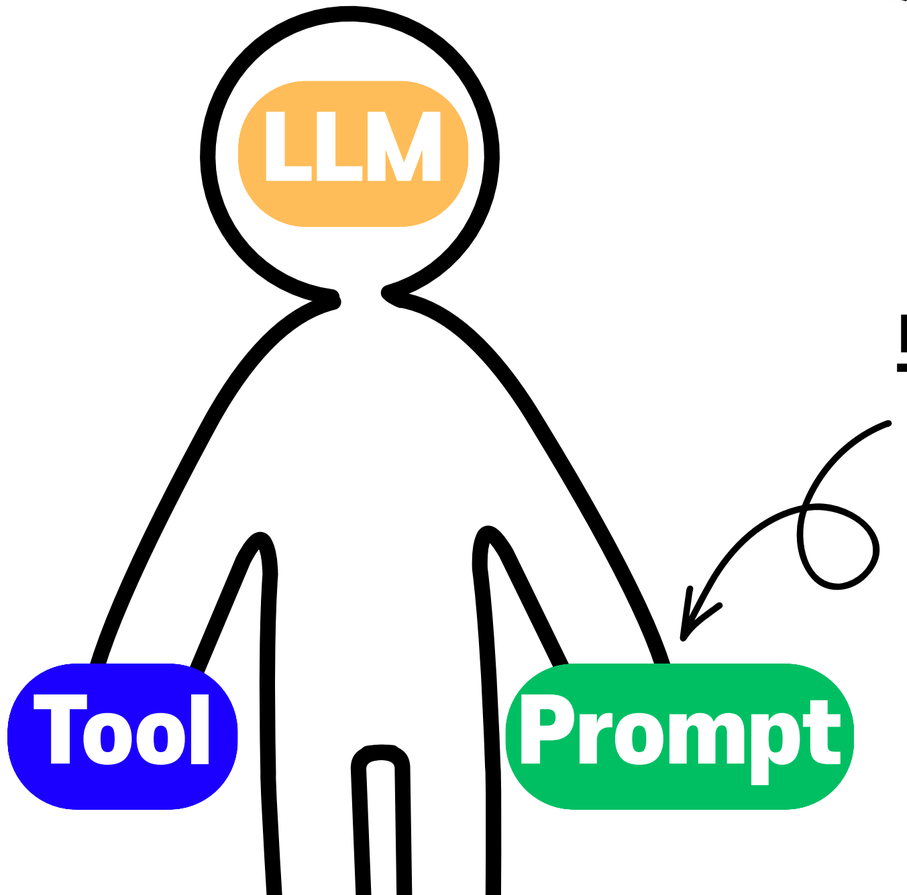




Cognitive Architecture

‘지능 구조와 작동 원리'를 컴퓨터로 구현한 것

Agent / Workflow



무엇을 들게
할 것인가?

Cognitive Architecture

LLM = 능력

CA = 구조

Cognitive Architecture

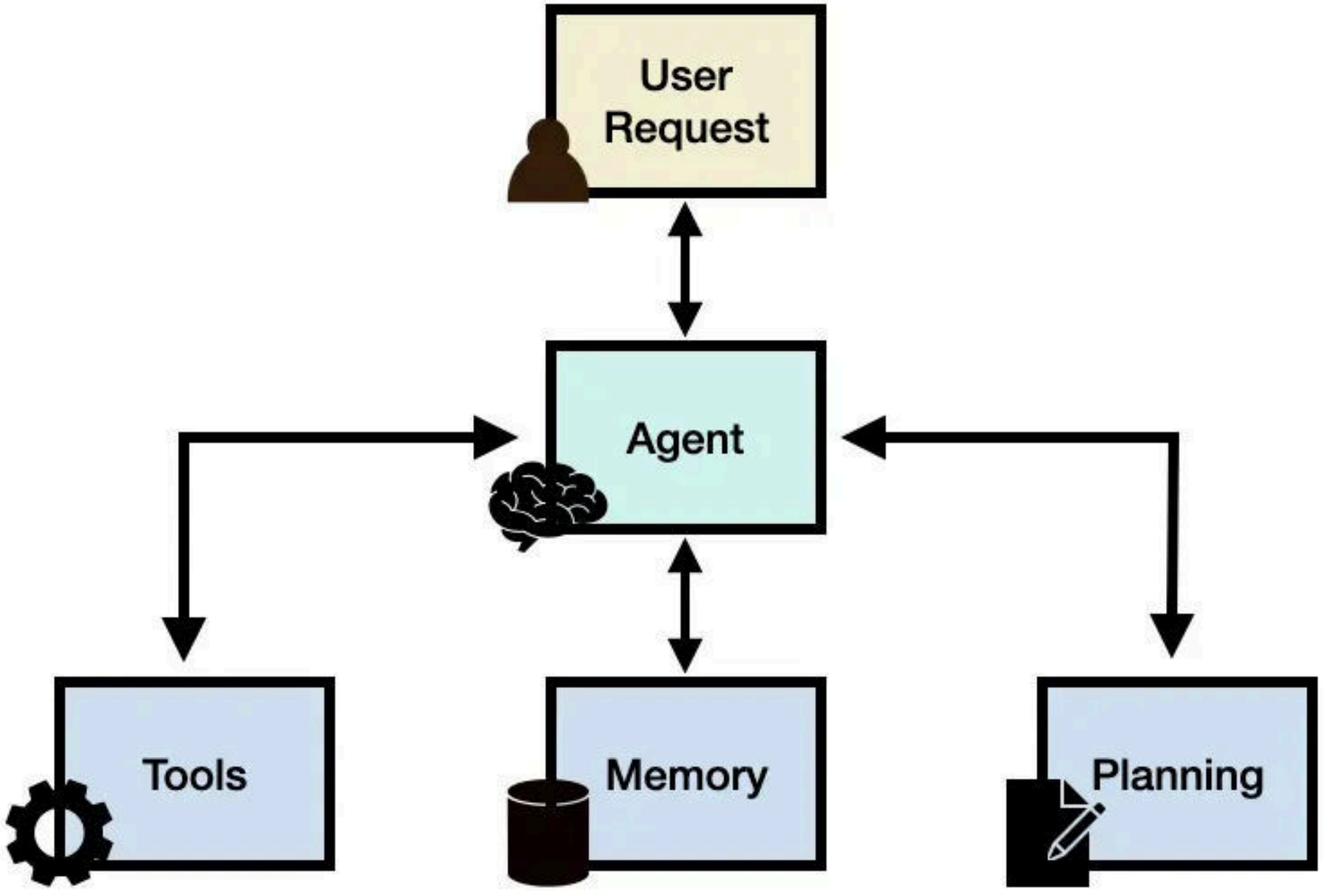
LLM

연주자
운전자

CA

악기 + 지휘자
자동차 + 네비

Agent Architecture



ReAct Prompt

(1d) ReAct (Reason + Act)

Thought 1: I need to search Apple Remote and find the program it was originally designed to interact with.
Act 1: Search[Apple Remote]
Obs 1: The Apple Remote is a remote control introduced in October 2005 by Apple … originally designed to control the Front Row media center program …

Thought 2: Apple Remote was originally designed to control the Front Row media center program. I need to search Front Row next and find what other device can control it.
Act 2: Search[Front Row]
Obs 2: Could not find [Front Row]. Similar: ['Front Row Seat to Earth', 'Front Row Motorsports',' Front Row (software)', …]

Thought 3: Front Row is not found. I need to search Front Row (software) .
Act 3: Search[Front Row (software)]
Obs 3: Front Row is a discontinued media center software …

Thought 4: Front Row (software) is controlled by an Apple Remote or the keyboard function keys. So the answer is keyboard function keys.
Act 4: Finish[keyboard function keys]



Basic Prompt Design Principles

Example Prompt
“이 문서를 요약해줘.”

모델이 알 수 없는 맥락 (Context)

문서의 유형 (논문, 보고서, ...)
원하는 요약 길이 (글머리, 기호, 문단, ...)
대상 독자 (기술 전문가, 일반 독자, ...)

Basic Prompt Design Principles

Improved Prompt

“이 10페이지 분량의 **재생 에너지**에 관한 과학 논문을 **5개의 글머리 기호로 요약**해줘.
핵심 주제와 **정책 입안자**를 위한 시사점에 초점을 맞춰줘.”

개선점

문서 유형 명시
대상 독자 지정
형식 정의
집중할 부분 강조

Basic Prompt Design Principles

Improved Prompt (even better)

"이 10페이지 분량의 **재생 에너지**에 관한 과학 논문을 **5개의 글머리 기호로 요약**해줘.
핵심 주제와 **정책 입안자**를 위한 시사점에 초점을 맞춰줘."

모델이 단계적으로 지시 사항을 따르도록 유도

Step 1. 논문에서 가장 중요한 3가지 발견을 파악해라
Step 2. 이러한 발견이 재생 에너지 정책에 어떤 영향을 미치는지 설명해
Step 3. 각 포인트가 하나의 발견과 그 정책적 시사점을 다루는 5개의 항목으로 요약해

Prompt Templates

Prompt Synthesis, 원하는 형태의 프롬프트로 구성하기

예시

[audience]를 위해 다음 텍스트를 [format] 형식으로 요약하세요. [text]

[audience], [format], [text]는 사용자가 지정할 수 있는 **변수**입니다.

Zero shot and Few shot prompt

Zero-Shot Prompt

모델이 다른 예시 없이 답변하는 프롬프트

Prompt

“아래 문장을 긍정, 부정, 중립 중 하나로 분류해주세요.
:이 영화는 나에겐 재미가 없었다.”

Output

부정

Zero shot and Few shot prompt

few-Shot Prompt

모델이 참고 할 예시가 포함된 프롬프트

Prompt

“아래 문장을 긍정, 부정, 중립 중 하나로 분류해주세요.
:이 영화는 나에겐 재미가 없었다.”

예시:
“이 영화 재미있다" → 긍정
“이 드라마는 그냥 그렇다" → 중립
“이 드라마 보지마" → 부정

Output

부정

Prompt chaining

Complex prompt (single step)

Prompt
"이 소셜 미디어 위기 상황을 분석하고, 브랜드 이미지를 회복하기 위한 대응 전략과 공식 성명서를 작성하세요: [고객 민원]."

고객 민원
"한 고객이 SNS에 '이 회사 제품에서 이상한 냄새가 나서 병원에 갔더니 알레르기 반응이었습니다. 성분표에 알레르기 유발 물질이 명시되어 있지 않았어요. 이건 사기 아닌가요?'라는 글을 올렸고, 현재 2만 개의 공감과 500개의 댓글이 달렸습니다."

Output:
"친애하는 고객 여러분께, 최근 소셜 미디어에서 제기된 알레르기 반응 관련 우려사항에 대해 깊이 사과드립니다. 저희는 즉시 해당 제품의 성분표를 재검토했으며, 일부 로트에서 미표기 성분이 발견되었습니다. 해당 제품은 즉시 리콜 조치하였고, 영향을 받으신 모든 고객께 전액 환불과 함께 건강검진 비용을 지원해드리겠습니다. 재발 방지를 위해 품질관리 프로세스를 전면 개편하고 있습니다."

Prompt chaining

Chaining: prompt 1

Prompt 1
"이 소셜 미디어 위기 상황에서 언급된 핵심 문제점들을 파악하세요: [고객 민원]."

고객 민원
"한 고객이 SNS에 '이 회사 제품에서 이상한 냄새가 나서 병원에 갔더니
알레르기 반응이었습니다. 성분표에 알레르기 유발 물질이 명시되어 있지 않았어요.
이건 사기 아닌가요?'라는 글을 올렸고,
현재 2만 개의 공감과 500개의 댓글이 달렸습니다."

Output:

- 건강 피해: 알레르기 반응으로 병원 방문
- 정보 누락: 성분표에 알레르기 유발 물질 미표기
- 신뢰 문제: "사기 아닌가요?" - 브랜드 신뢰도 하락
- 확산 속도: 2만 공감, 500개 댓글 - 빠른 바이럴 확산
- 고객 감정: 배신감, 분노, 건강 우려

Prompt chaining

Chaining: prompt 2

Prompt 2
"이 소셜 미디어 위기 상황에서 언급된 핵심 문제점들을 파악하세요: [이전 출력]."

이전 출력
- 건강 피해: 알레르기 반응으로 병원 방문
- 정보 누락: 성분표에 알레르기 유발 물질 미표기
- 신뢰 문제: "사기 아닌가요?" - 브랜드 신뢰도 하락
- 확산 속도: 2만 공감, 500개 댓글 - 빠른 바이럴 확산
- 고객 감정: 배신감, 분노, 건강 우려

Output:
- 즉각적 조치를 인정하고 고객 건강을 최우선으로 한다는 입장 표명
- 문제 발생 원인을 투명하게 설명 (예: 제조 과정의 오류, 품질관리 실패)
- 구체적인 재발 방지 대책 제시 (예: 성분 검증 프로세스 강화, 제3자 인증)
- 영향받은 고객에 대한 실질적 보상안 제공 (예: 전액 환불, 의료비 지원)
- 지속적인 소통 채널 유지 (예: 전담 고객지원팀, 정기 업데이트)

Prompt chaining

Chaining: prompt 3

Prompt 3
"이 소셜 미디어 위기 상황에서 언급된 핵심 문제점들을 파악하세요: [이전 출력 개요]."

이전 출력 개요

Output:
"고객 여러분께,
먼저 최근 소셜 미디어를 통해 제기된 알레르기 반응 사례에 대해 깊이 사과드립니다. 고객님의 건강과 신뢰는 저희에게 가장 중요한 가치이며, 이번 일로 실망과 우려를 끼쳐드린 점 진심으로 송구스럽게 생각합니다.
즉각 조치 사항 해당 제품(로트번호: XYZ123)은 오늘 오후 1시부로 전국 모든 매장에서 즉시 판매 중단 및 회수 조치에 들어갔습니다. 해당 제품을 구매하신 고객께서는 전액 환불받으실 수 있으며, 알레르기 반응을 경험하신 분들께는 의료비 전액을 지원해드립니다.
원인 분석 조사 결과, 제조 공정 중 원료 공급업체 변경 과정에서 신규 성분이 추가되었으나, 성분표 업데이트 절차에서 누락이 발생했습니다. 이는 명백한 저희의 품질관리 실패입니다.

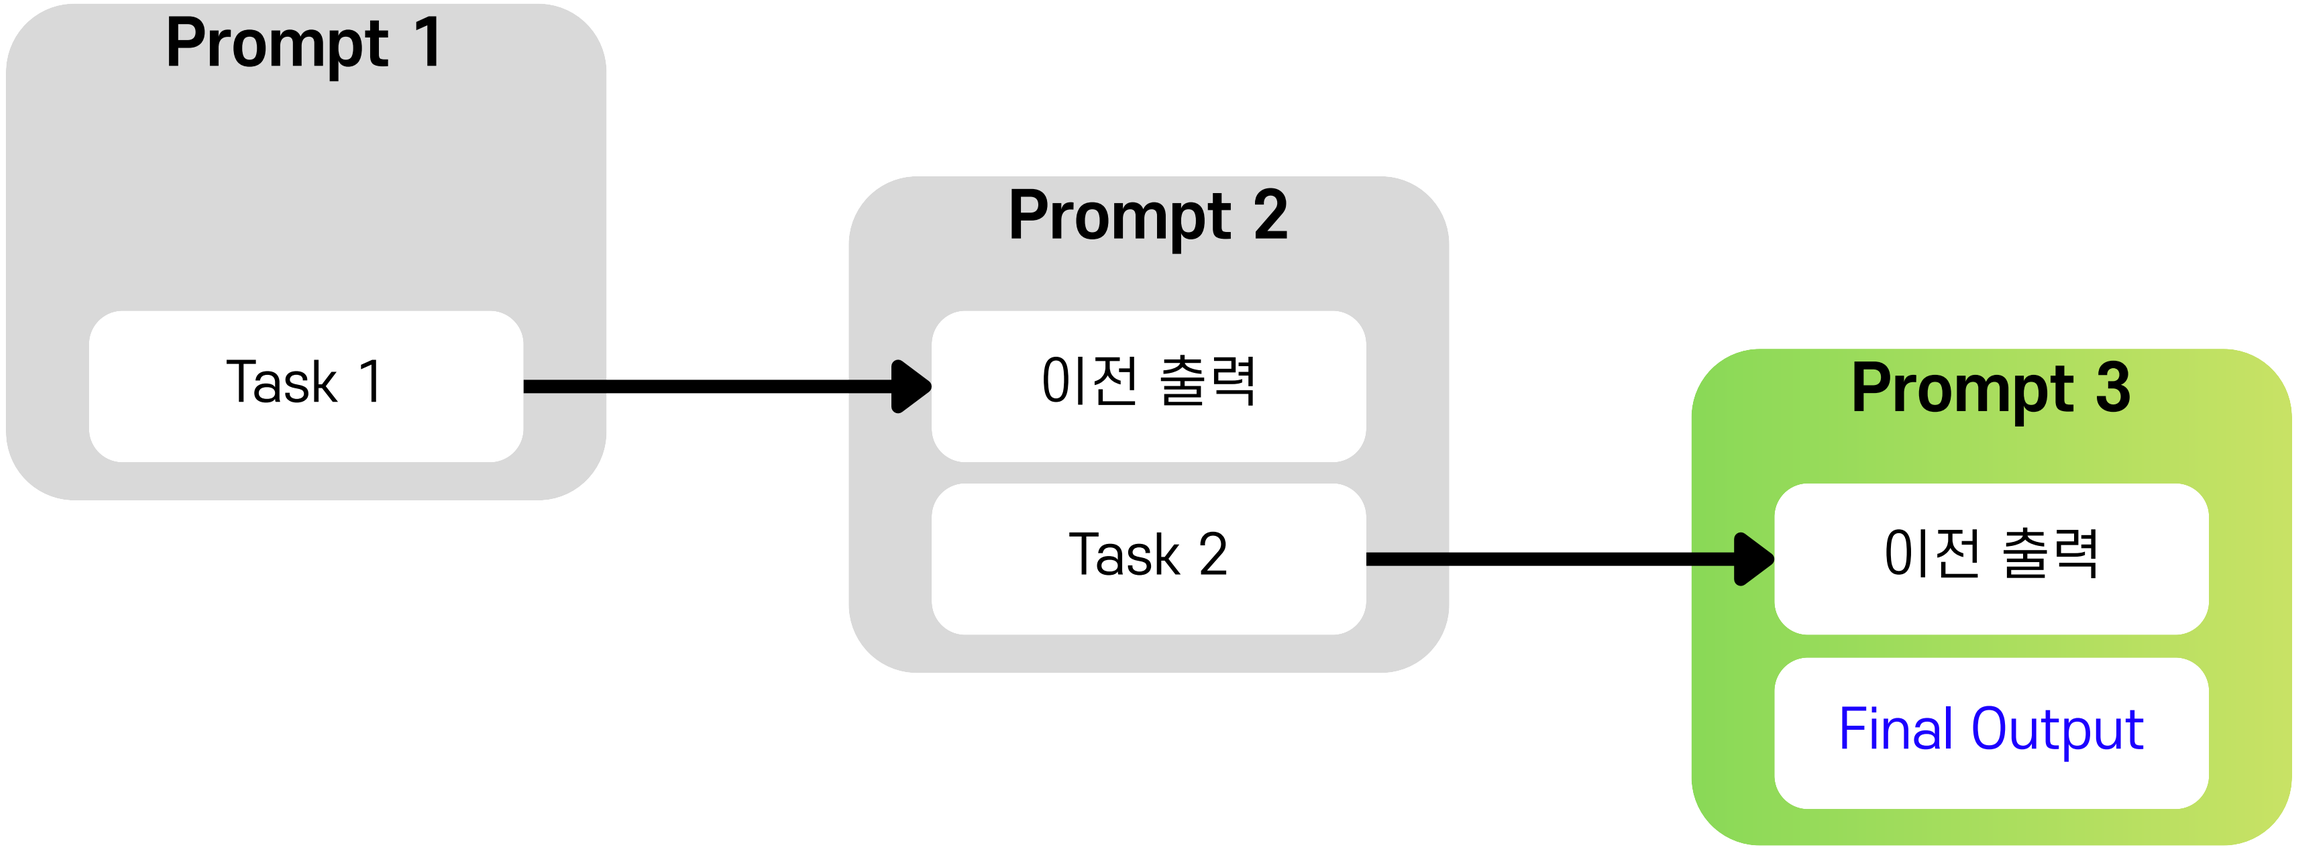
재발 방지 대책

1. 모든 제품의 성분 표기 전수조사 실시 (2주 내 완료)
2. 외부 인증기관을 통한 성분 검증 시스템 도입
3. 품질관리팀 인력 2배 확충 및 재교육 프로그램 운영
4. 알레르기 정보 전담 고객지원 핫라인 개설 (1588-XXXX)
5.

지속적 소통 매주 금요일, 개선 진행사항을 공식 홈페이지와 SNS를 통해 투명하게 공유하겠습니다. 추가 문의사항은 언제든지 고객센터로 연락 주시기 바랍니다.
다시 한번 이번 일로 불편과 고통을 겪으신 모든 분들께 깊이 사과드립니다. 고객 여러분의 신뢰를 회복하기 위해 최선을 다하겠습니다.

[회사명] 대표이사 드림"

Prompt chaining



AI User

AI 능력 내 (Inside the frontier) 업무

작업 속도 25% 향상, 품질 40% 향상

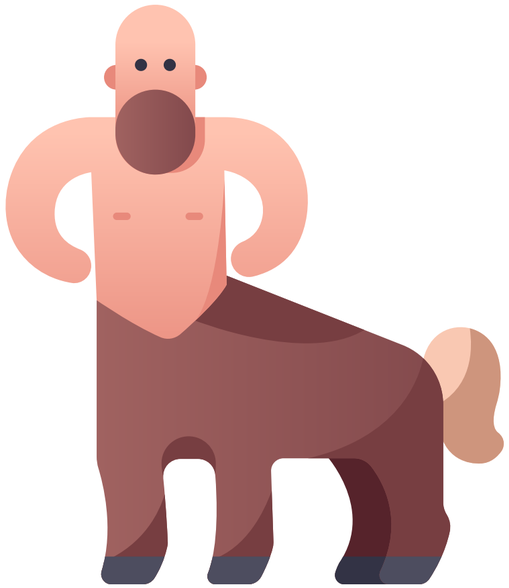
AI 능력 외 (Outside the frontier) 업무

정확도 19% 하락

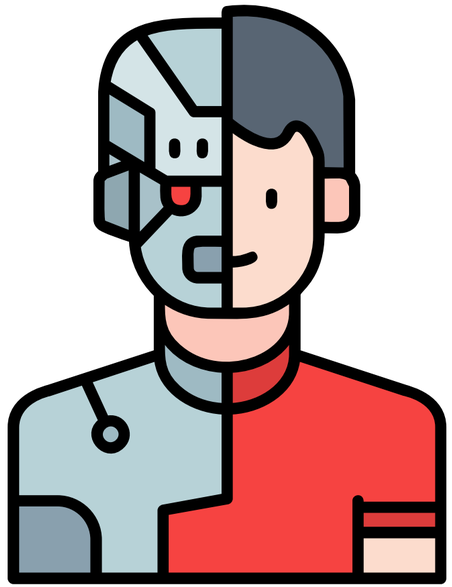
Slides by Junseop So

Dell'Acqua, F., et al. (2023). "Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality." Harvard Business School Working Paper.

AI User



OR



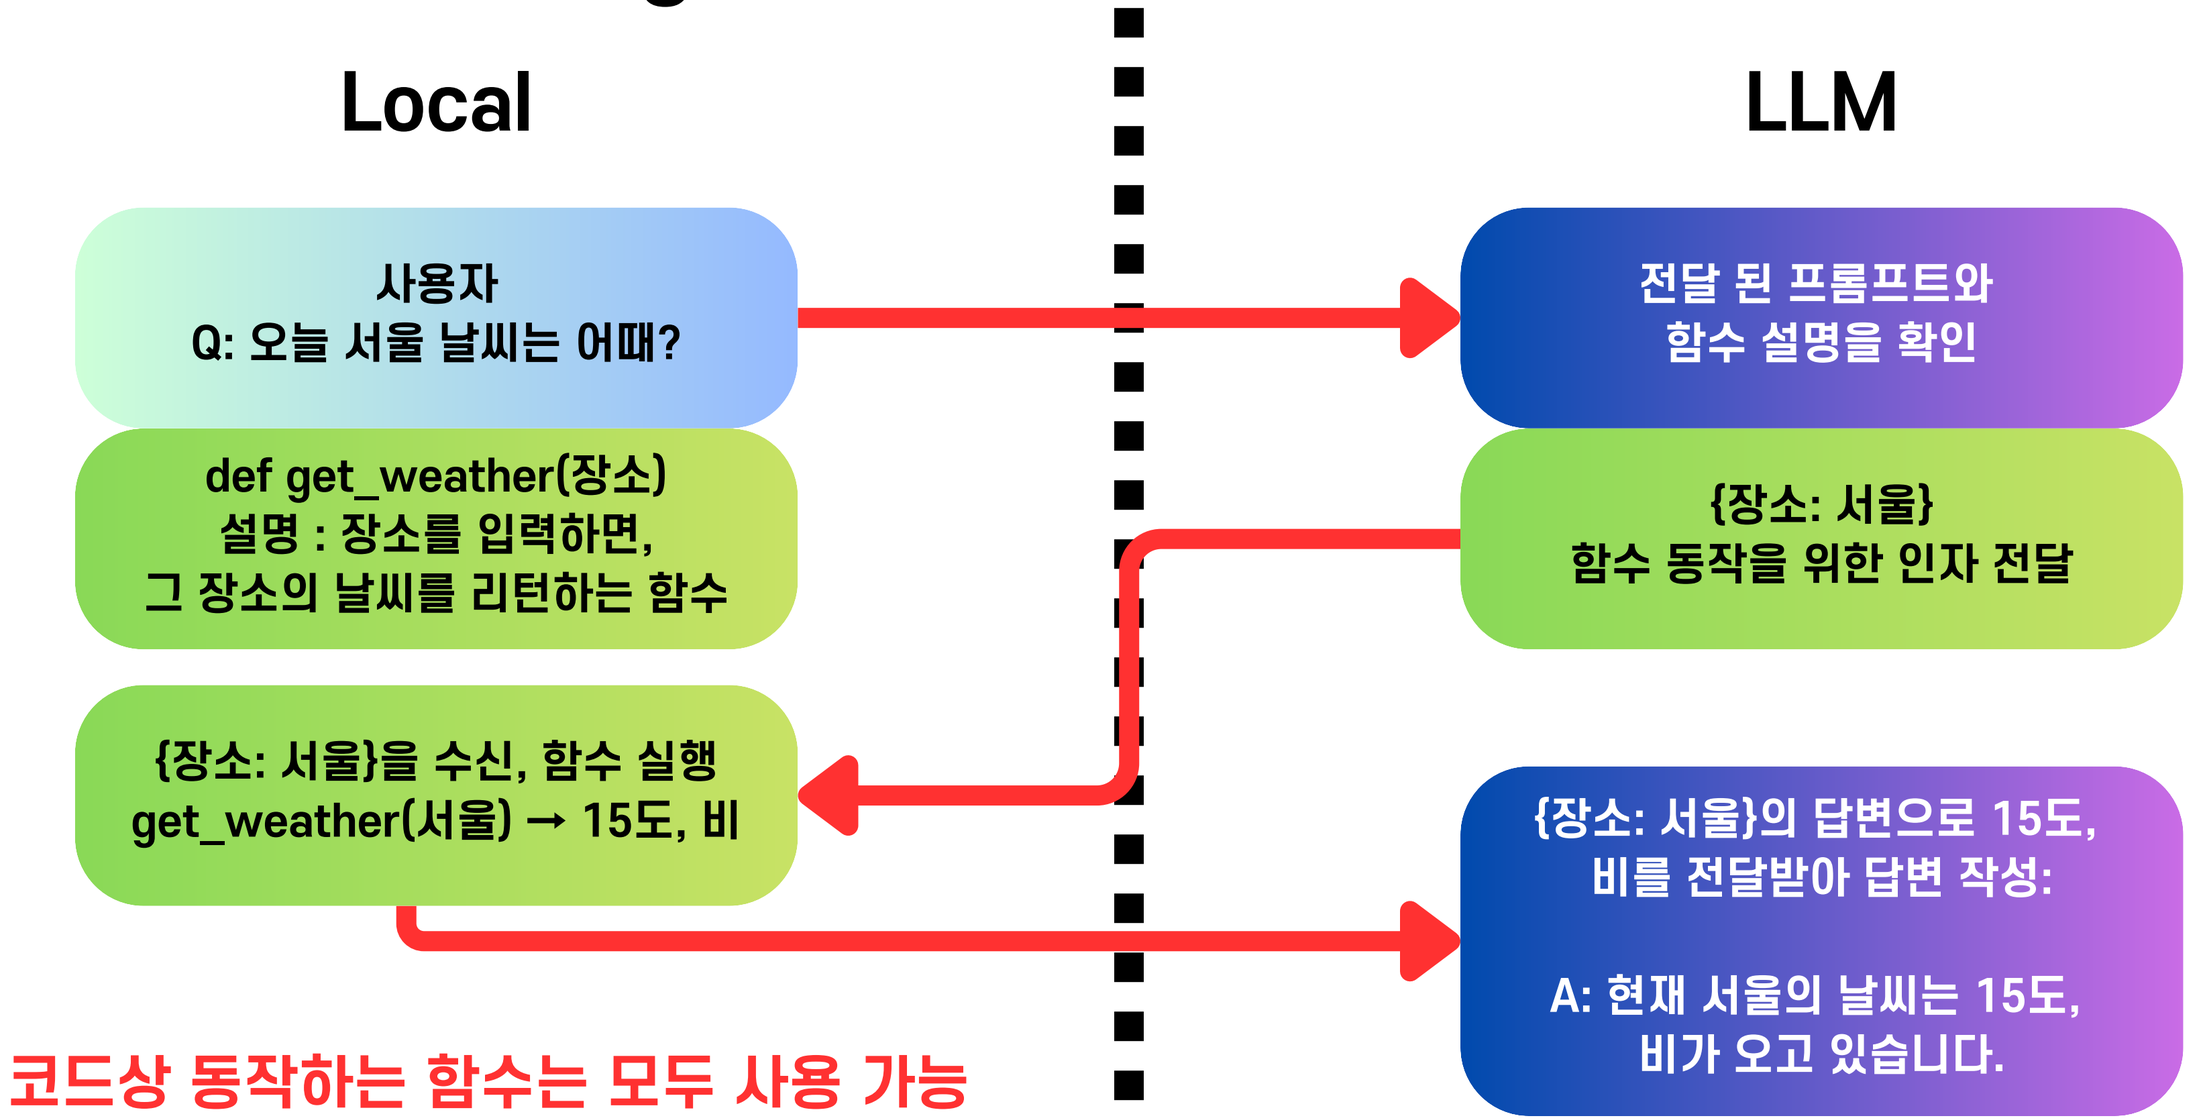
사람의 일과
인공지능의 일을 나눈다

내가 곧 AI

Slides by Junseop So

Dell'Acqua, F., et al. (2023). "Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality." Harvard Business School Working Paper.

Function Calling



코드상 동작하는 함수는 모두 사용 가능

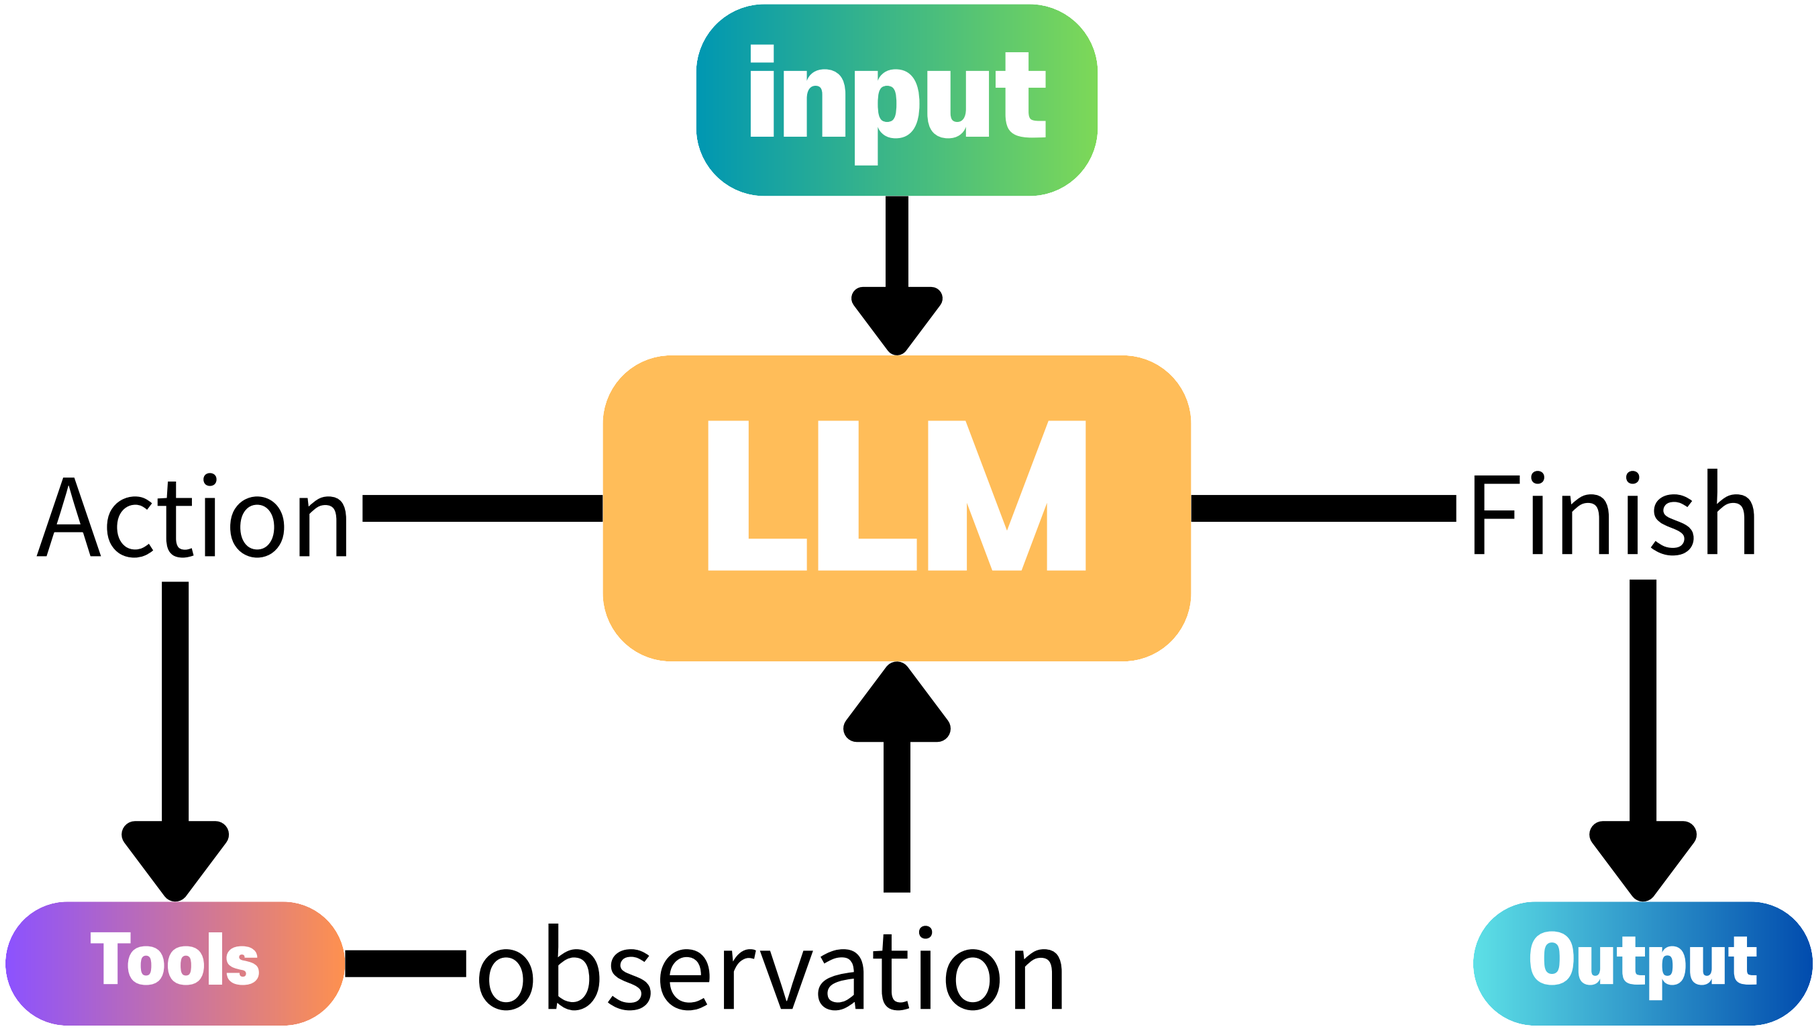
Tool

어떤 Tool을 언제 어떻게 쓸 수 있게 할까?

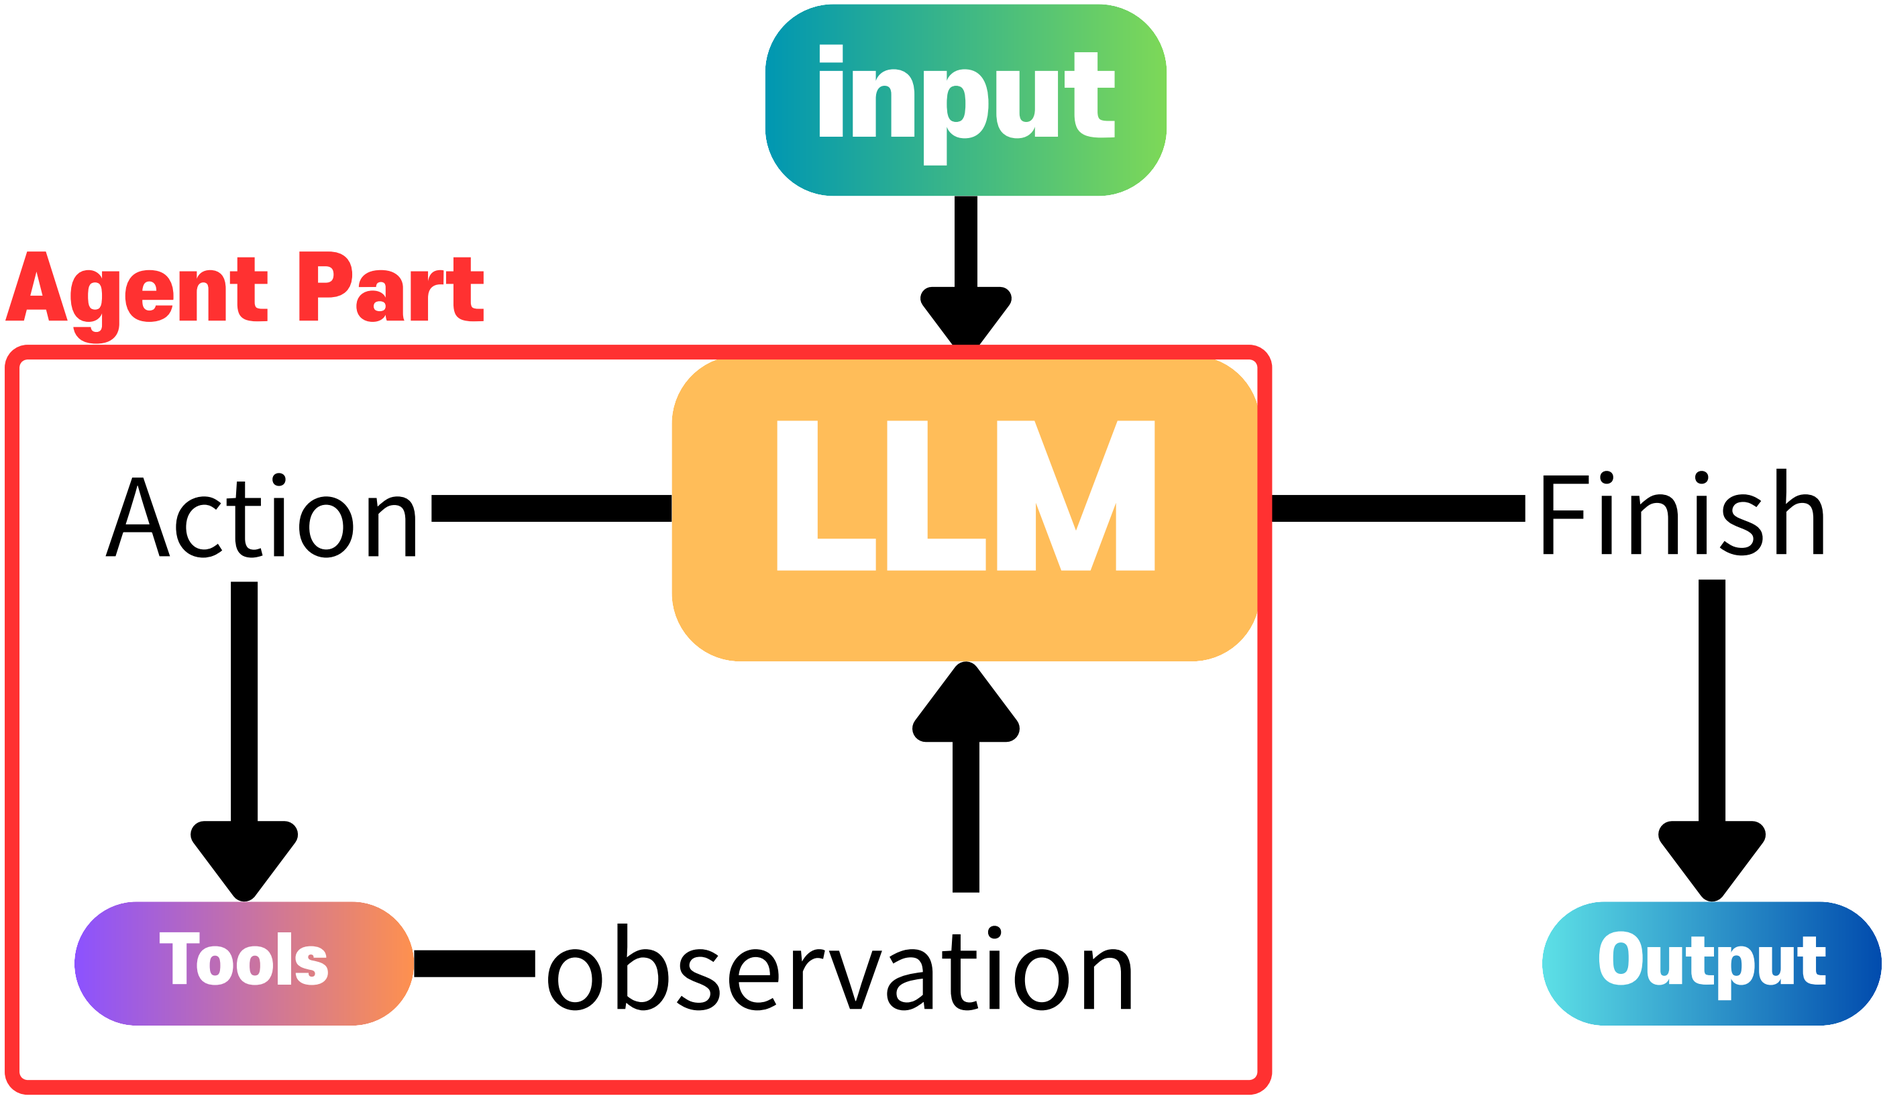
→ Agent의 성능



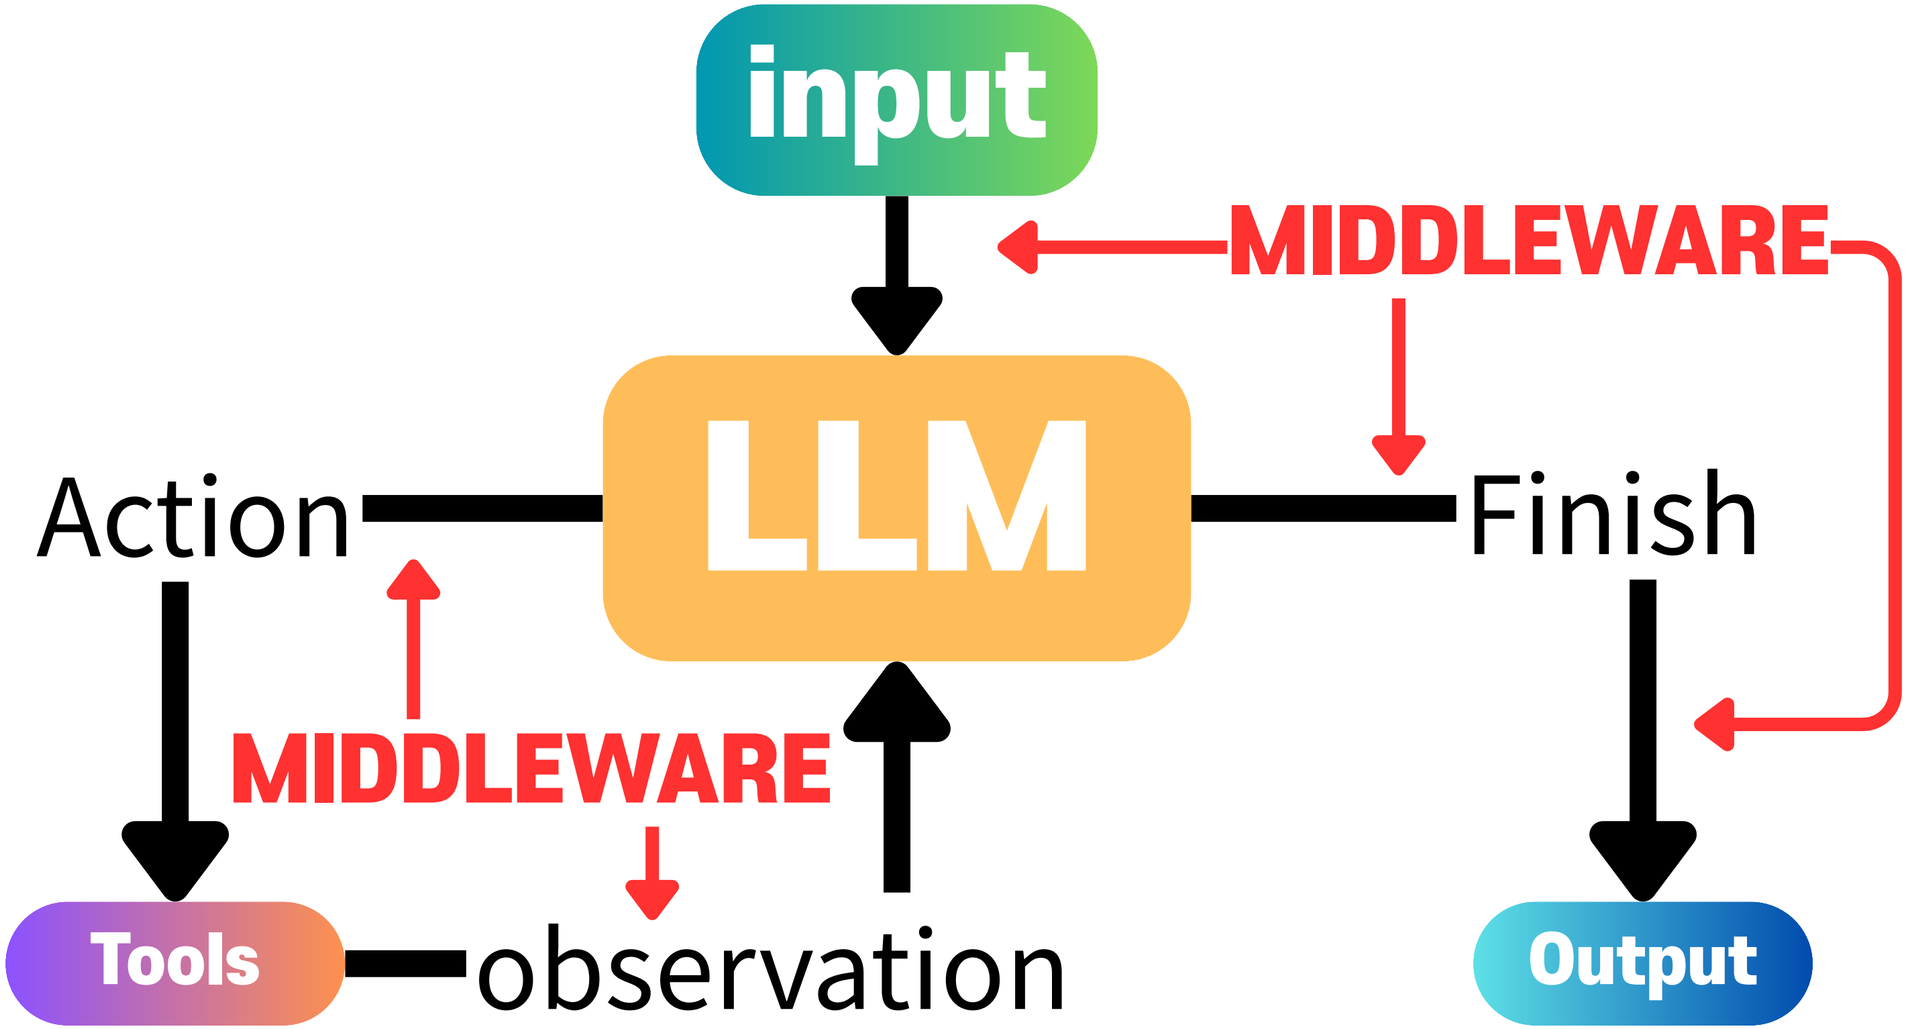
LLM Agents



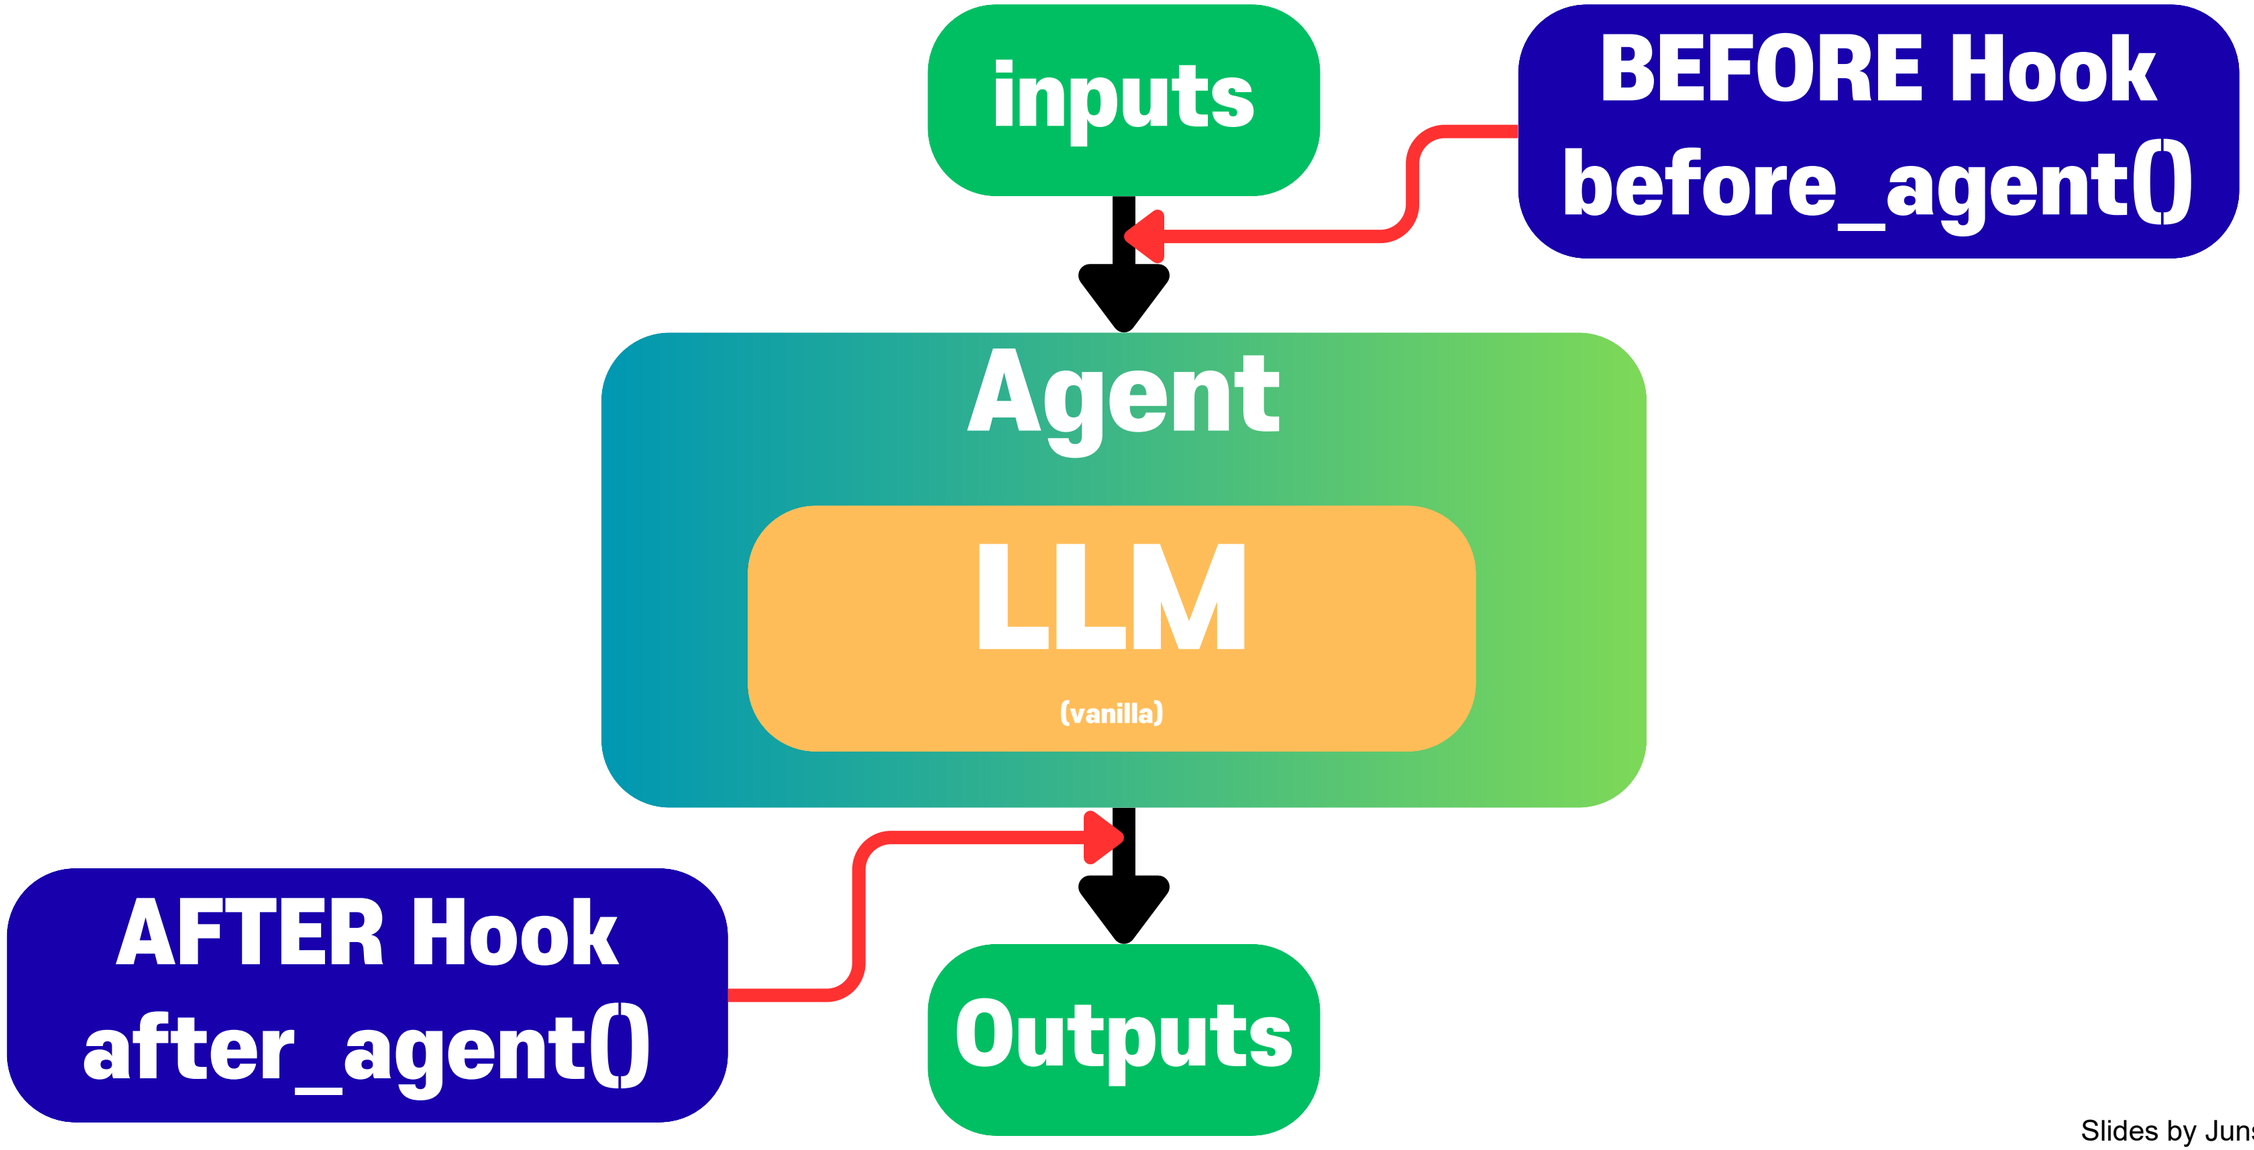
LLM Agents


input
Agent Part
LLM
Action
Finish
Tools
observation
Output

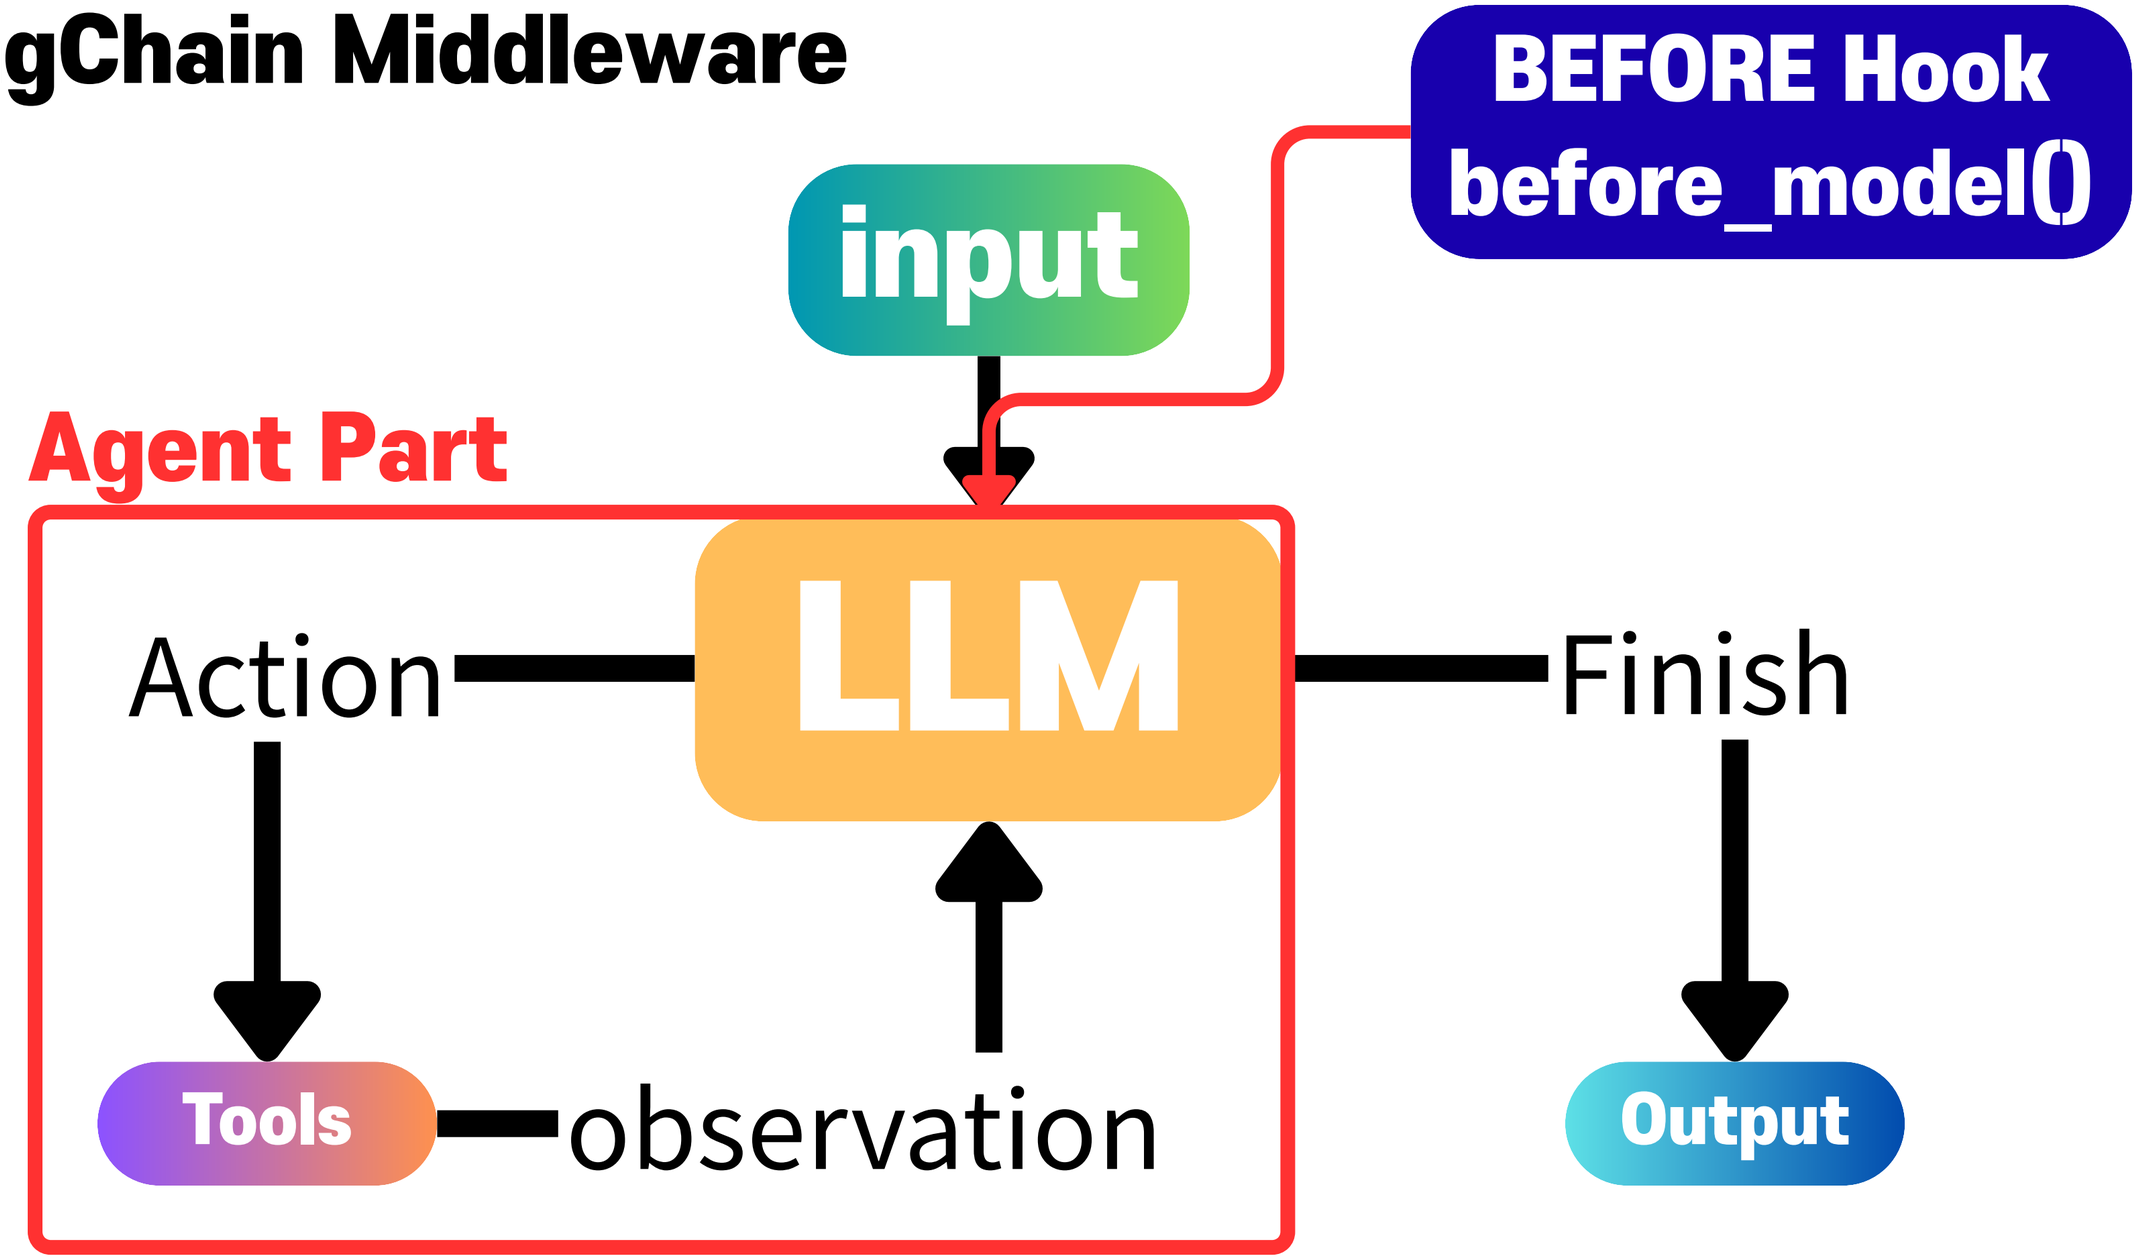
LangChain Middleware



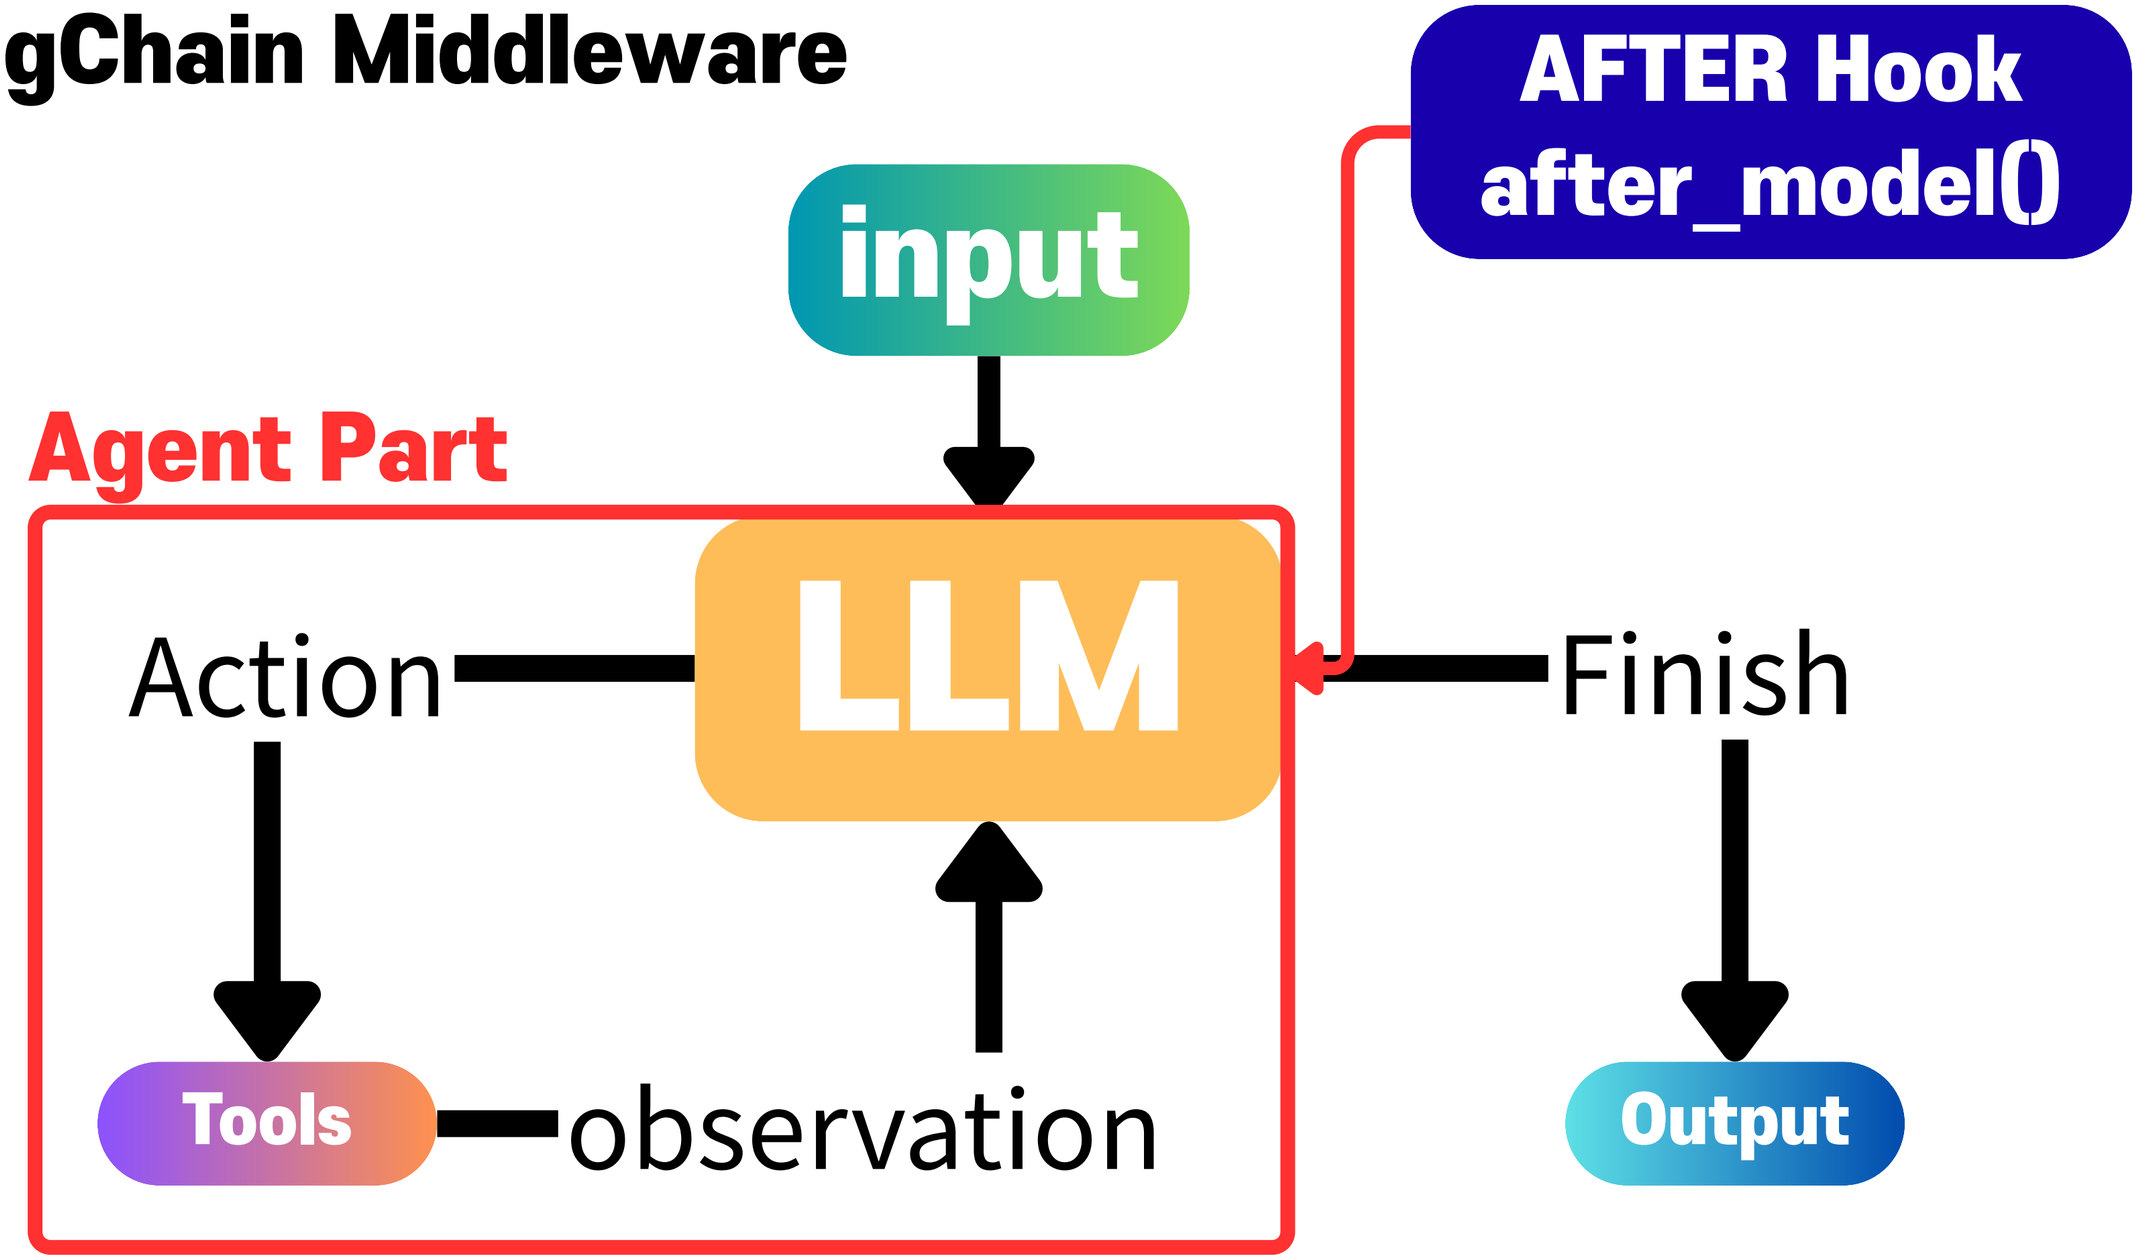
LangChain Middleware



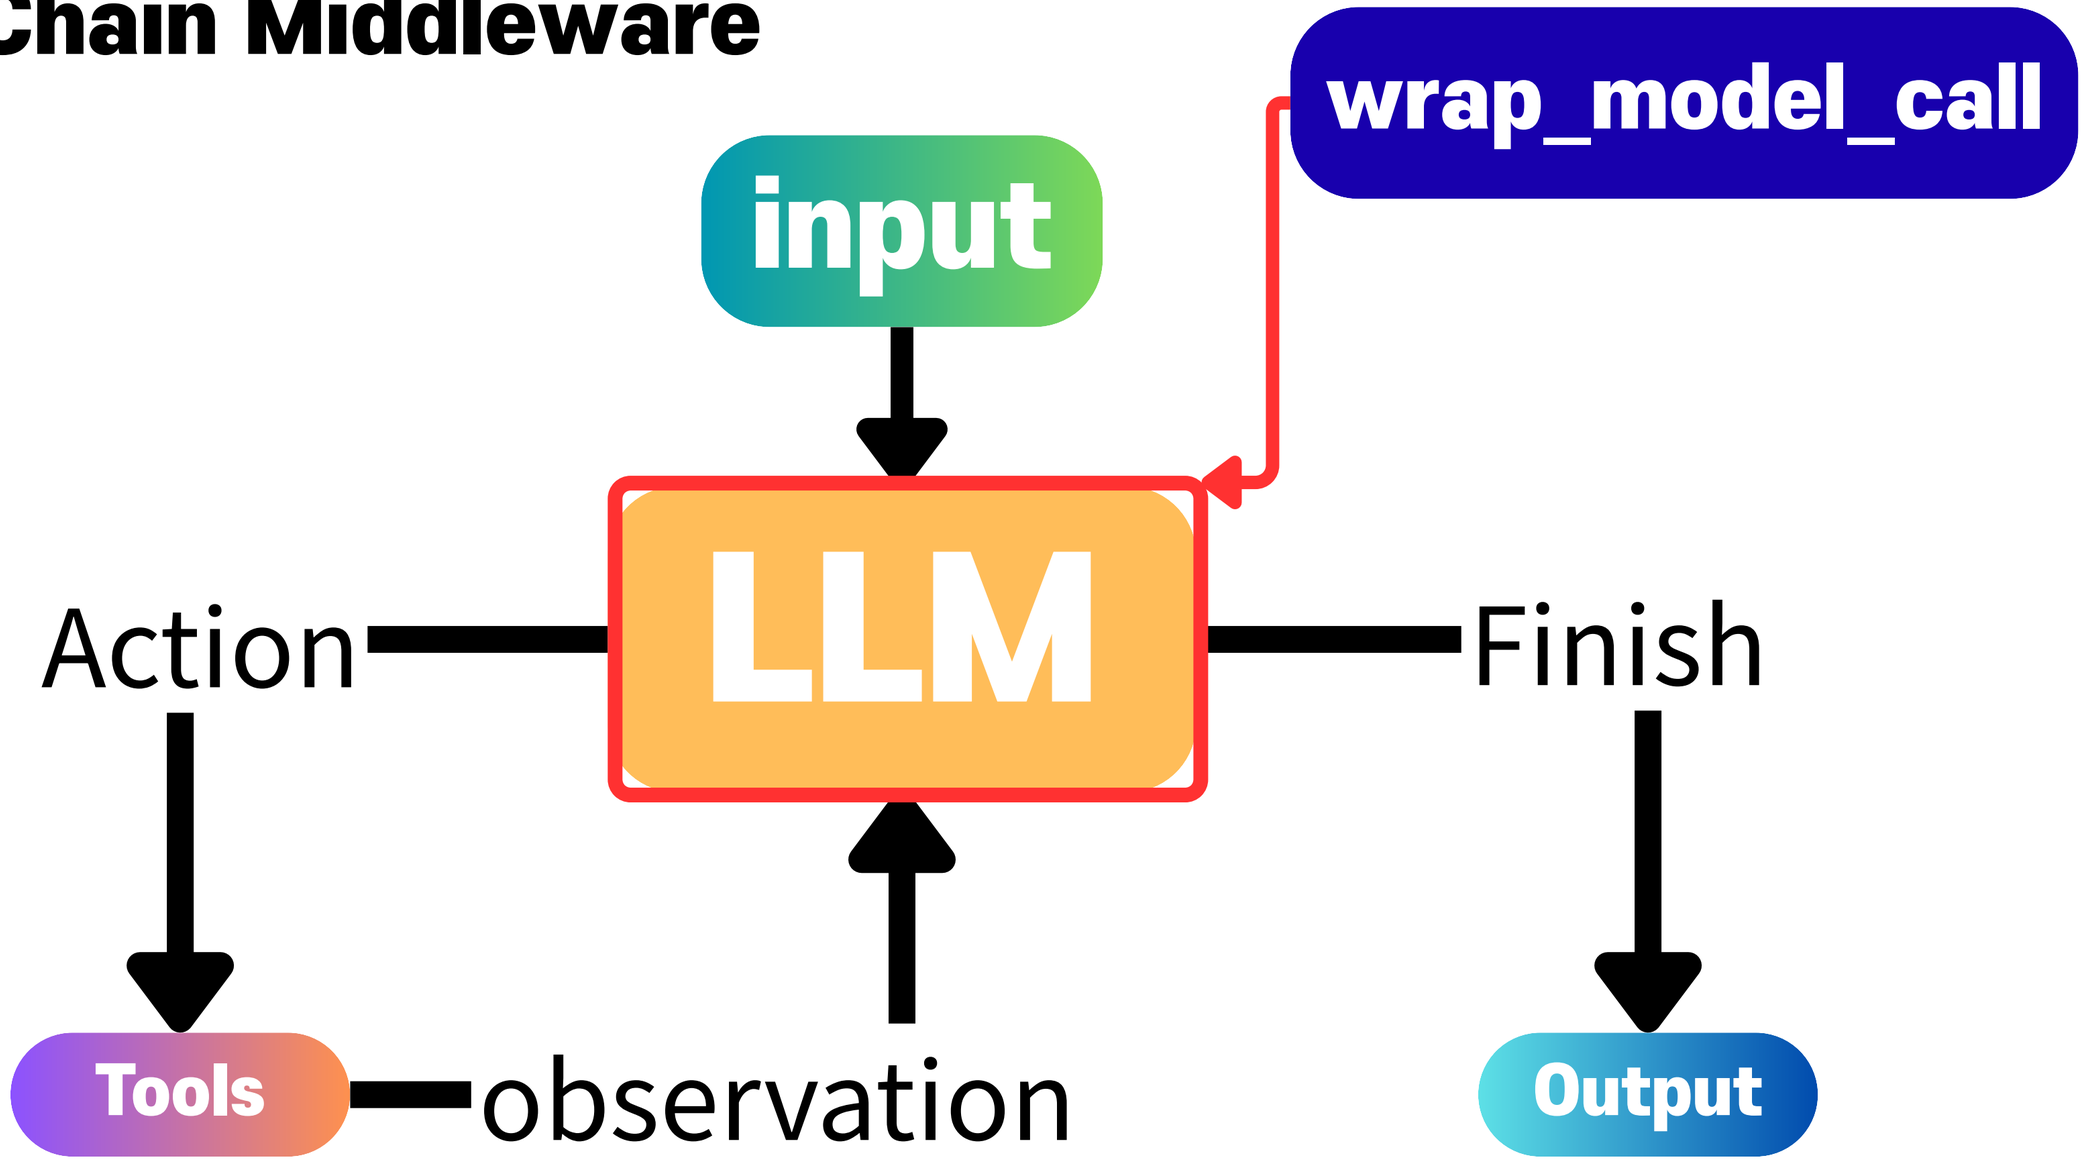
LangChain Middleware



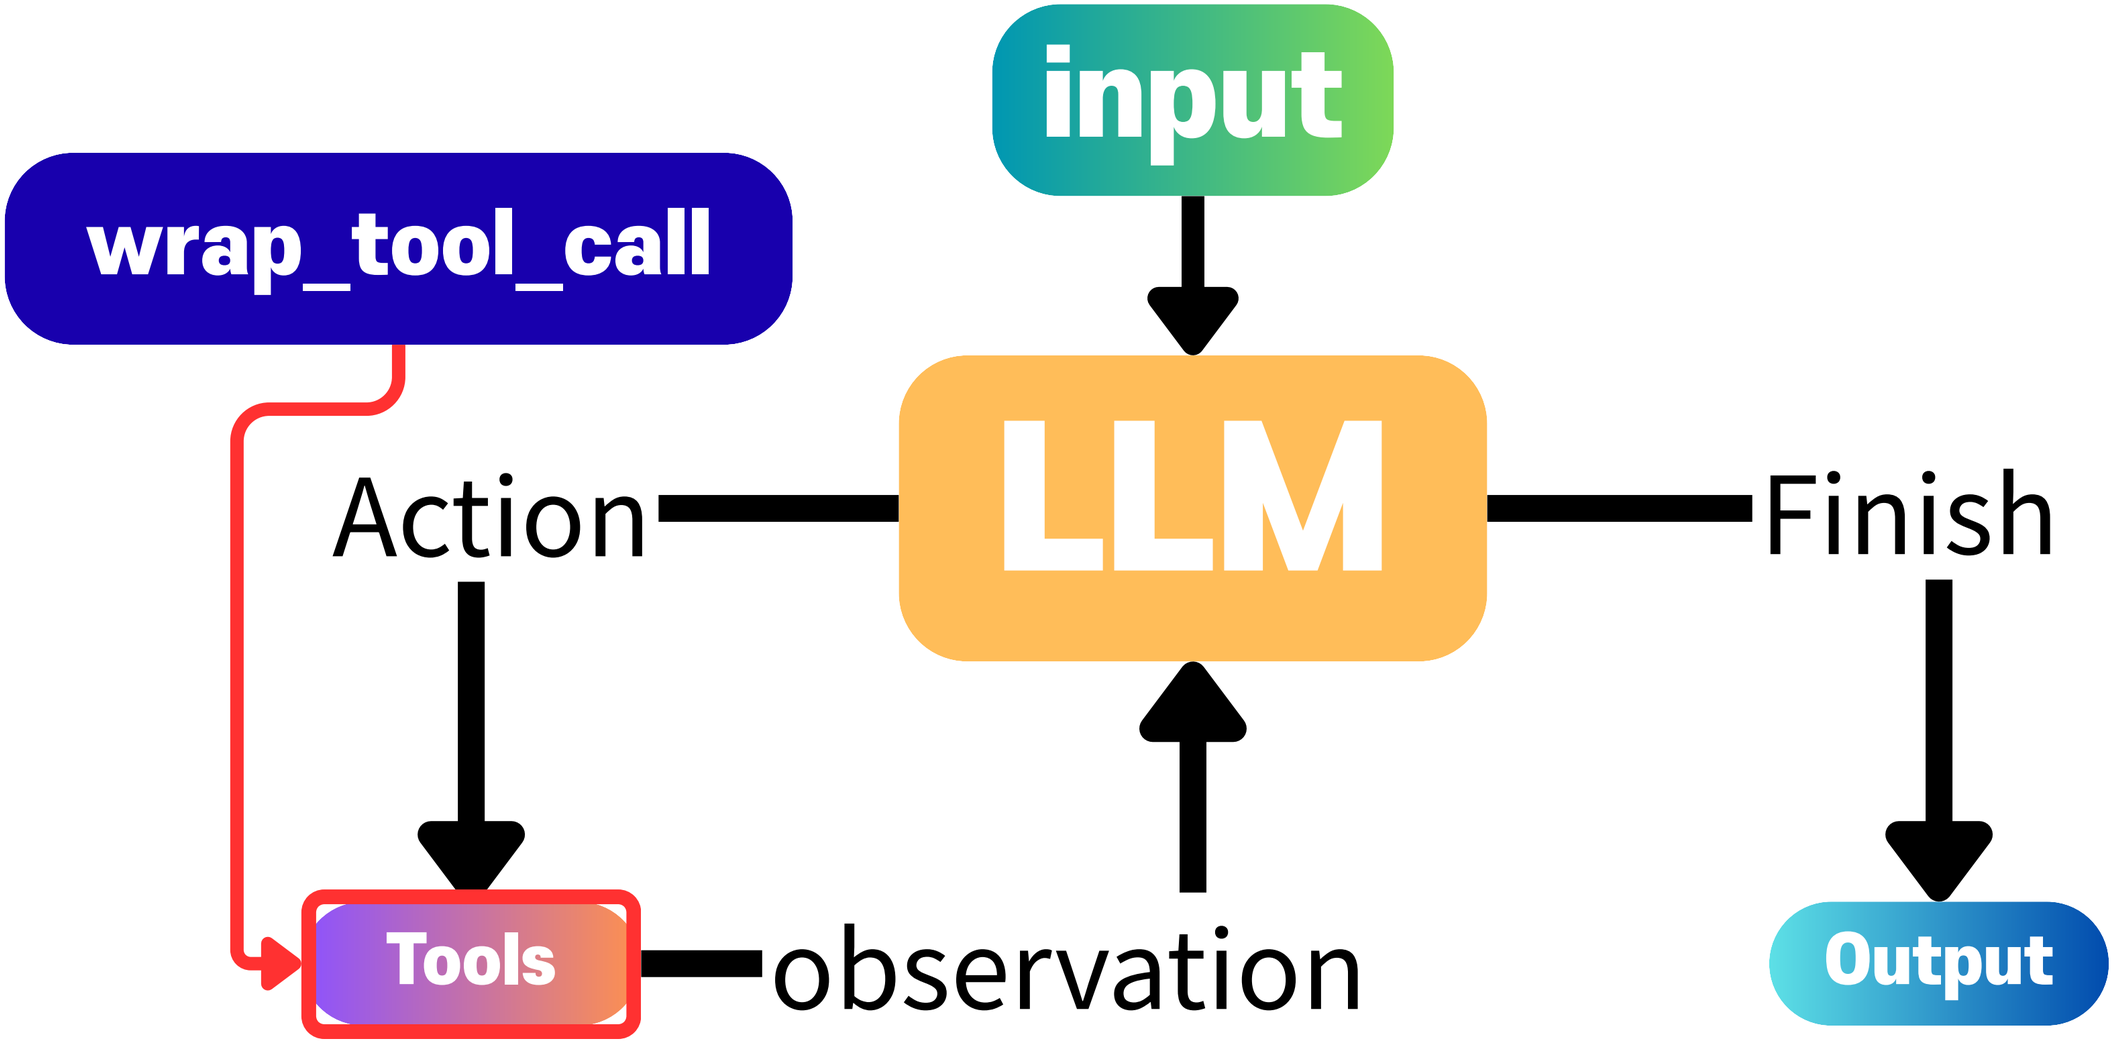
LangChain Middleware



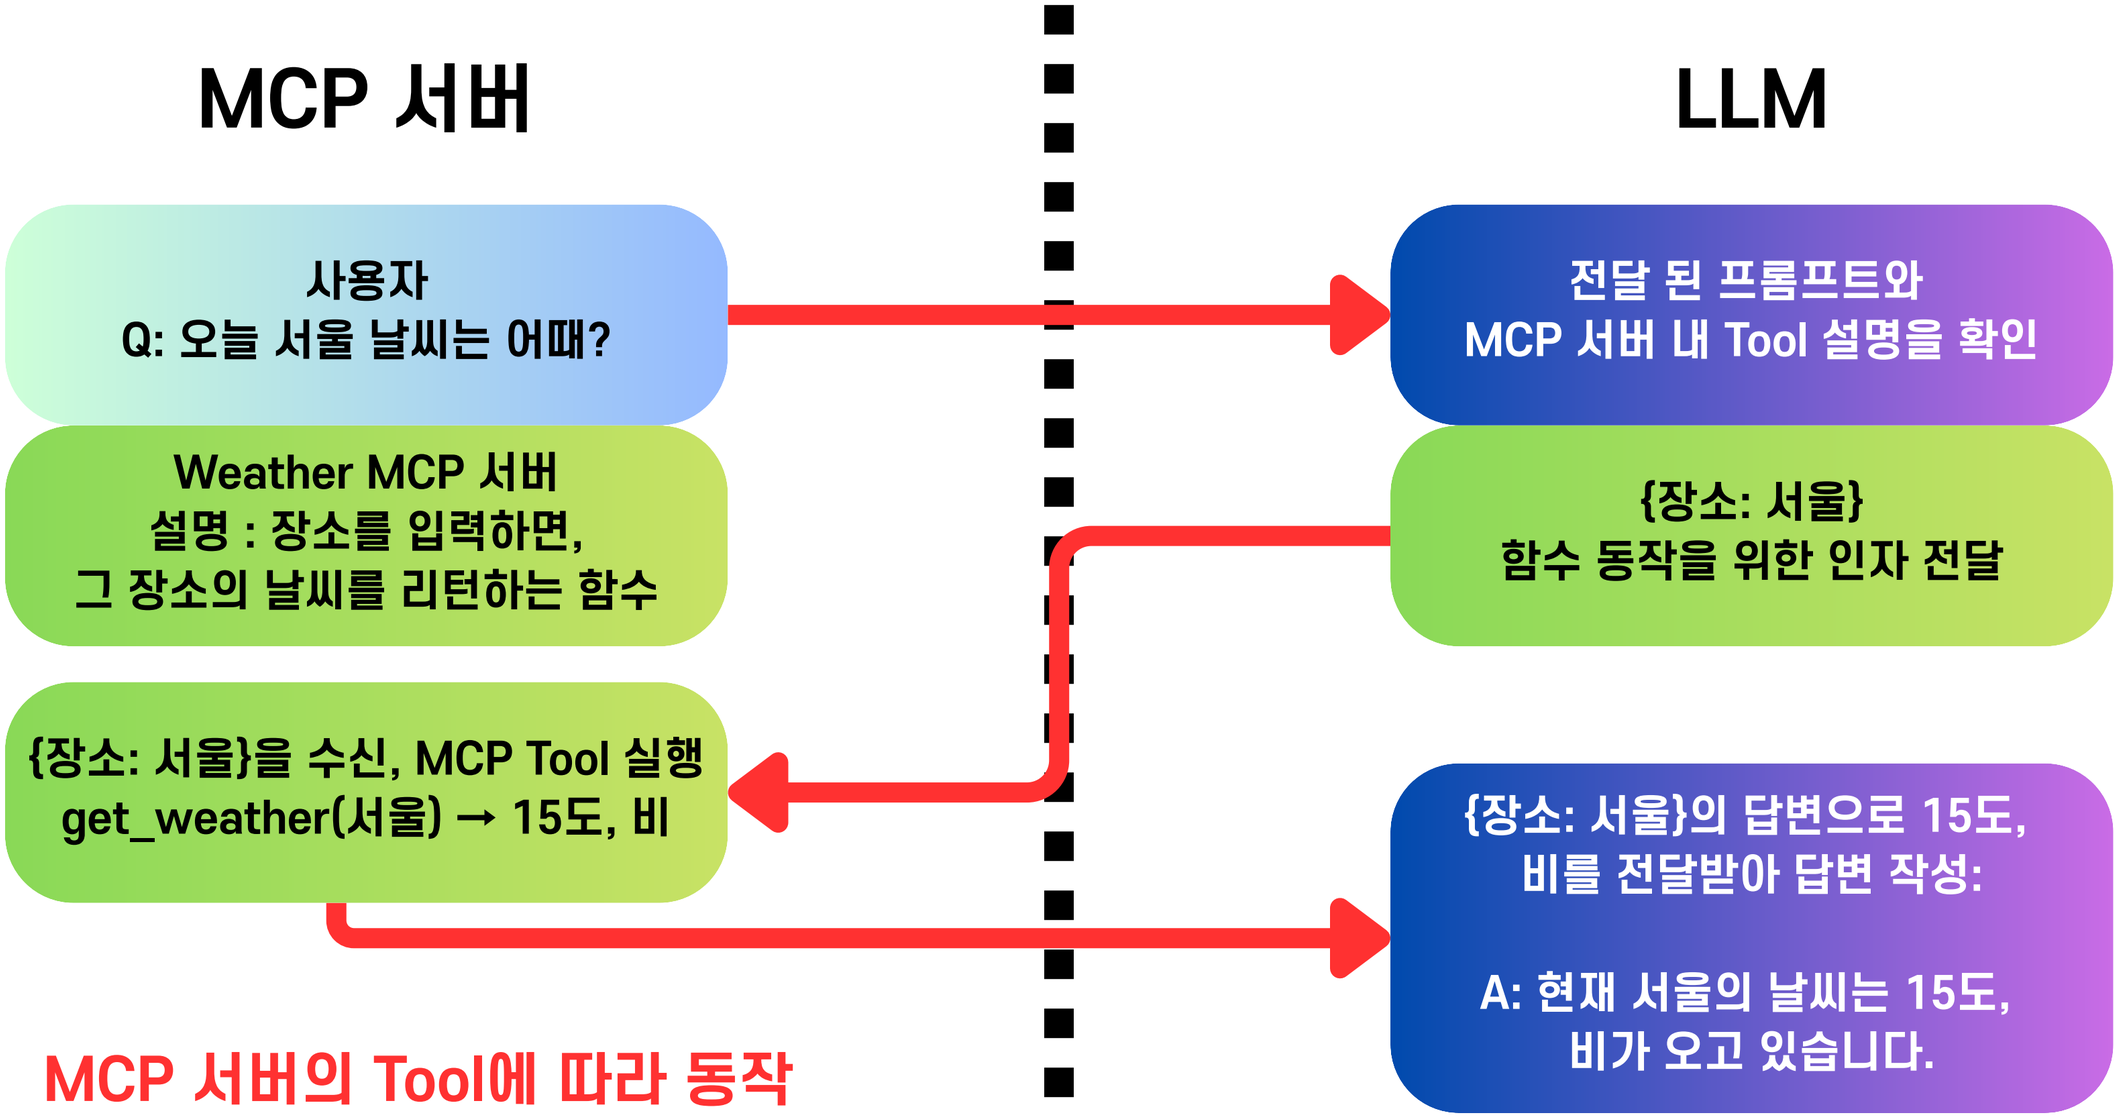
LangChain Middleware



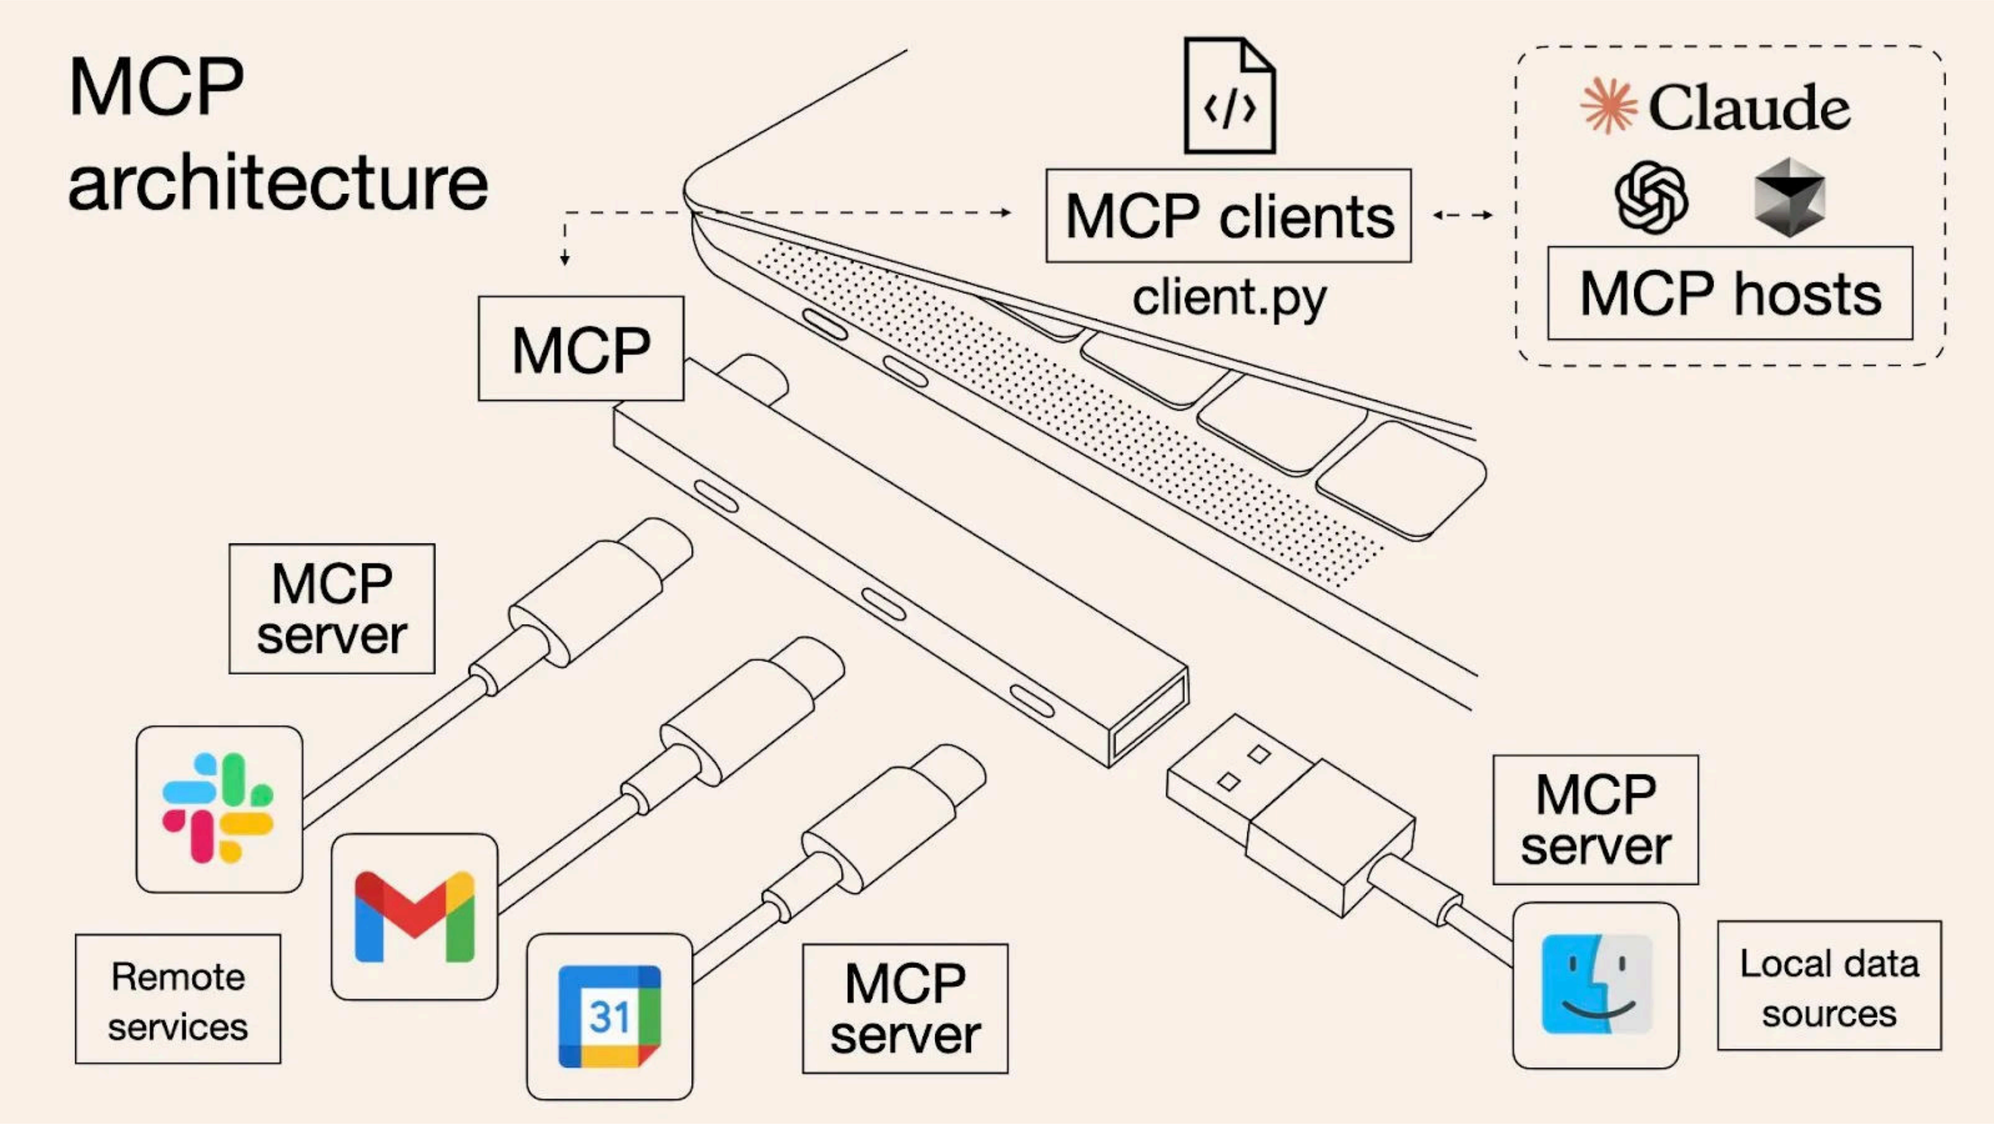
LangChain Middleware



MCP


MCP 서버
LLM
사용자
Q: 오늘 서울 날씨는 어때?
전달 된 프롬프트와
MCP 서버 내 Tool 설명을 확인
Weather MCP 서버
설명 : 장소를 입력하면,
그 장소의 날씨를 리턴하는 함수
{장소: 서울}
함수 동작을 위한 인자 전달
{장소: 서울}을 수신, MCP Tool 실행
get_weather(서울) → 15도, 비
{장소: 서울}의 답변으로 15도,
비를 전달받아 답변 작성:
A: 현재 서울의 날씨는 15도,
비가 오고 있습니다.
MCP 서버의 Tool에 따라 동작

MCP


MCP
architecture
MCP clients
client.py
Claude
MCP hosts
MCP
MCP
server
MCP
server
MCP
server
Remote
services
Local data
sources

RAG & Fine-tuning

새로운 지식은 RAG, 모델의 말투나 형식은 Fine-tuning

비교 항목	RAG (검색 증강 생성)	Fine-tuning (파인튜닝)
목적	**외부 지식 활용 (오픈북 시험)**	**형식 및 말투 교정 (말하기 훈련)**
최신성	데이터베이스만 업데이트하면 즉시 반영됨 (실시간)	모델을 다시 학습할 때까지 구식 정보 유지
정확도	출처(Source)를 명시할 수 있어 신뢰도 높음	출처를 알 수 없으며, 거짓 정보를 생성할 위험 높음
비용	초기 구축 비용 저렴, 유지보수 용이	초기 학습 비용 높음 (GPU 자원 소모)
데이터 보안	기업 내부 데이터를 모델에 넣지 않고 참조만 함	데이터를 모델 가중치에 포함시켜야 하므로 유출 위험

Fine-tuning

Fine-tuning의 장단점

단점

많은 양의 라벨링된 데이터 필요

특정 데이터의 과정합 위험

시간과 비용이 많이 들어감

필요한 경우

반복적으로 매우 높은 정확도가 요구되는 작업일 때

범용 LLM이 특정 도메인 언어를 잘 이해하지 못할 때

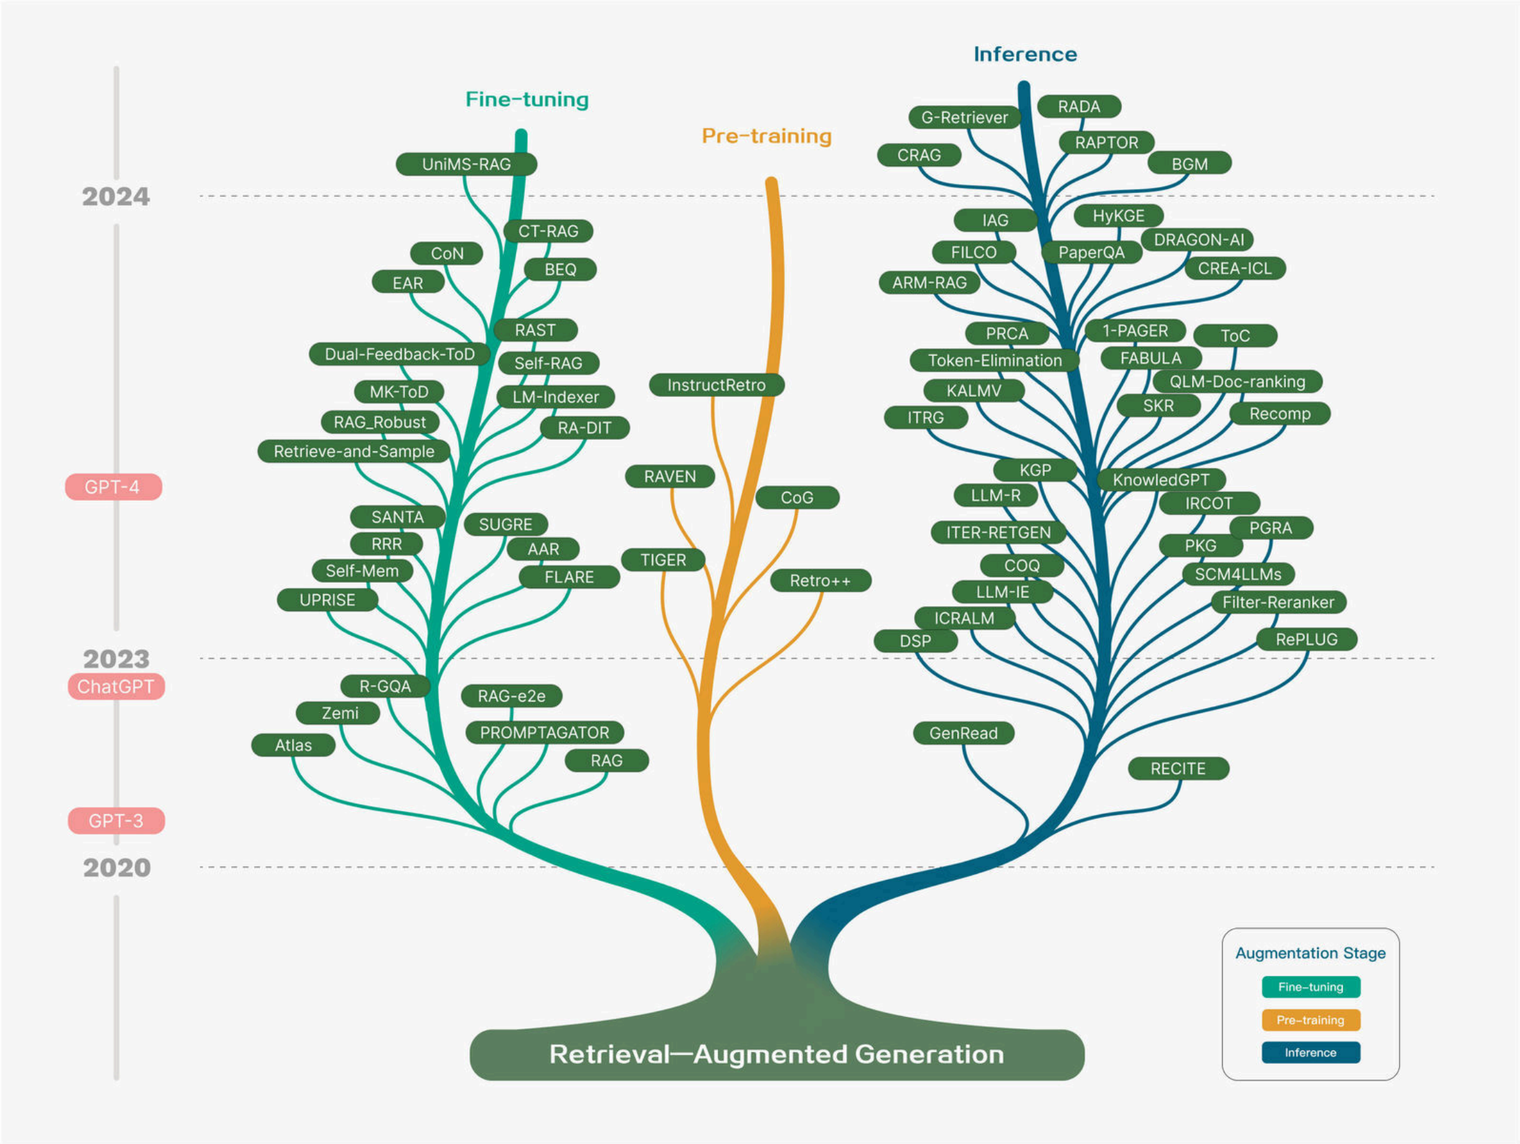
Slack Fine-tuning

USER	write a 500 word blog post on prompt engineering	프롬프트 엔지니어링에 대한 500단어짜리 블로그 글을 써 주세요.
ASSISTANT	sure I shall work on that in the morning	알겠습니다. 아침에 작업하겠습니다.
USER	It's morning now	지금이 아침이에요.
ASSISTANT	I'm writing it right now It's 6:30am here	지금 쓰고 있습니다. 여기는 오전 6시 30분이에요.
USER	Write it now	지금 쓰세요.
ASSISTANT	ok	알겠습니다.
USER	Please	제발
ASSISTANT	ok I shall write it now I don't know what you would like me to say about prompt engineering I can only describe the process The only thing that comes to mind for a headline is "How we build prompts"	알겠습니다, 지금 쓰겠습니다. 다만 프롬프트 엔지니어링에 대해 어떤 내용을 원하시는지는 잘 모르겠습니다. 제가 할 수 있는 것은 그 과정에 대해 설명하는 정도입니다. 지금 떠오르는 제목은 “우리는 어떻게 프롬프트를 만드는가 (How we build prompts)” 정도입니다.
⊕ Add message		

Slides by Junseop So

[Ross Lazerowitz, Fine-tuning GPT3.5-turbo based on 140k slack messages (Sep 2023)]

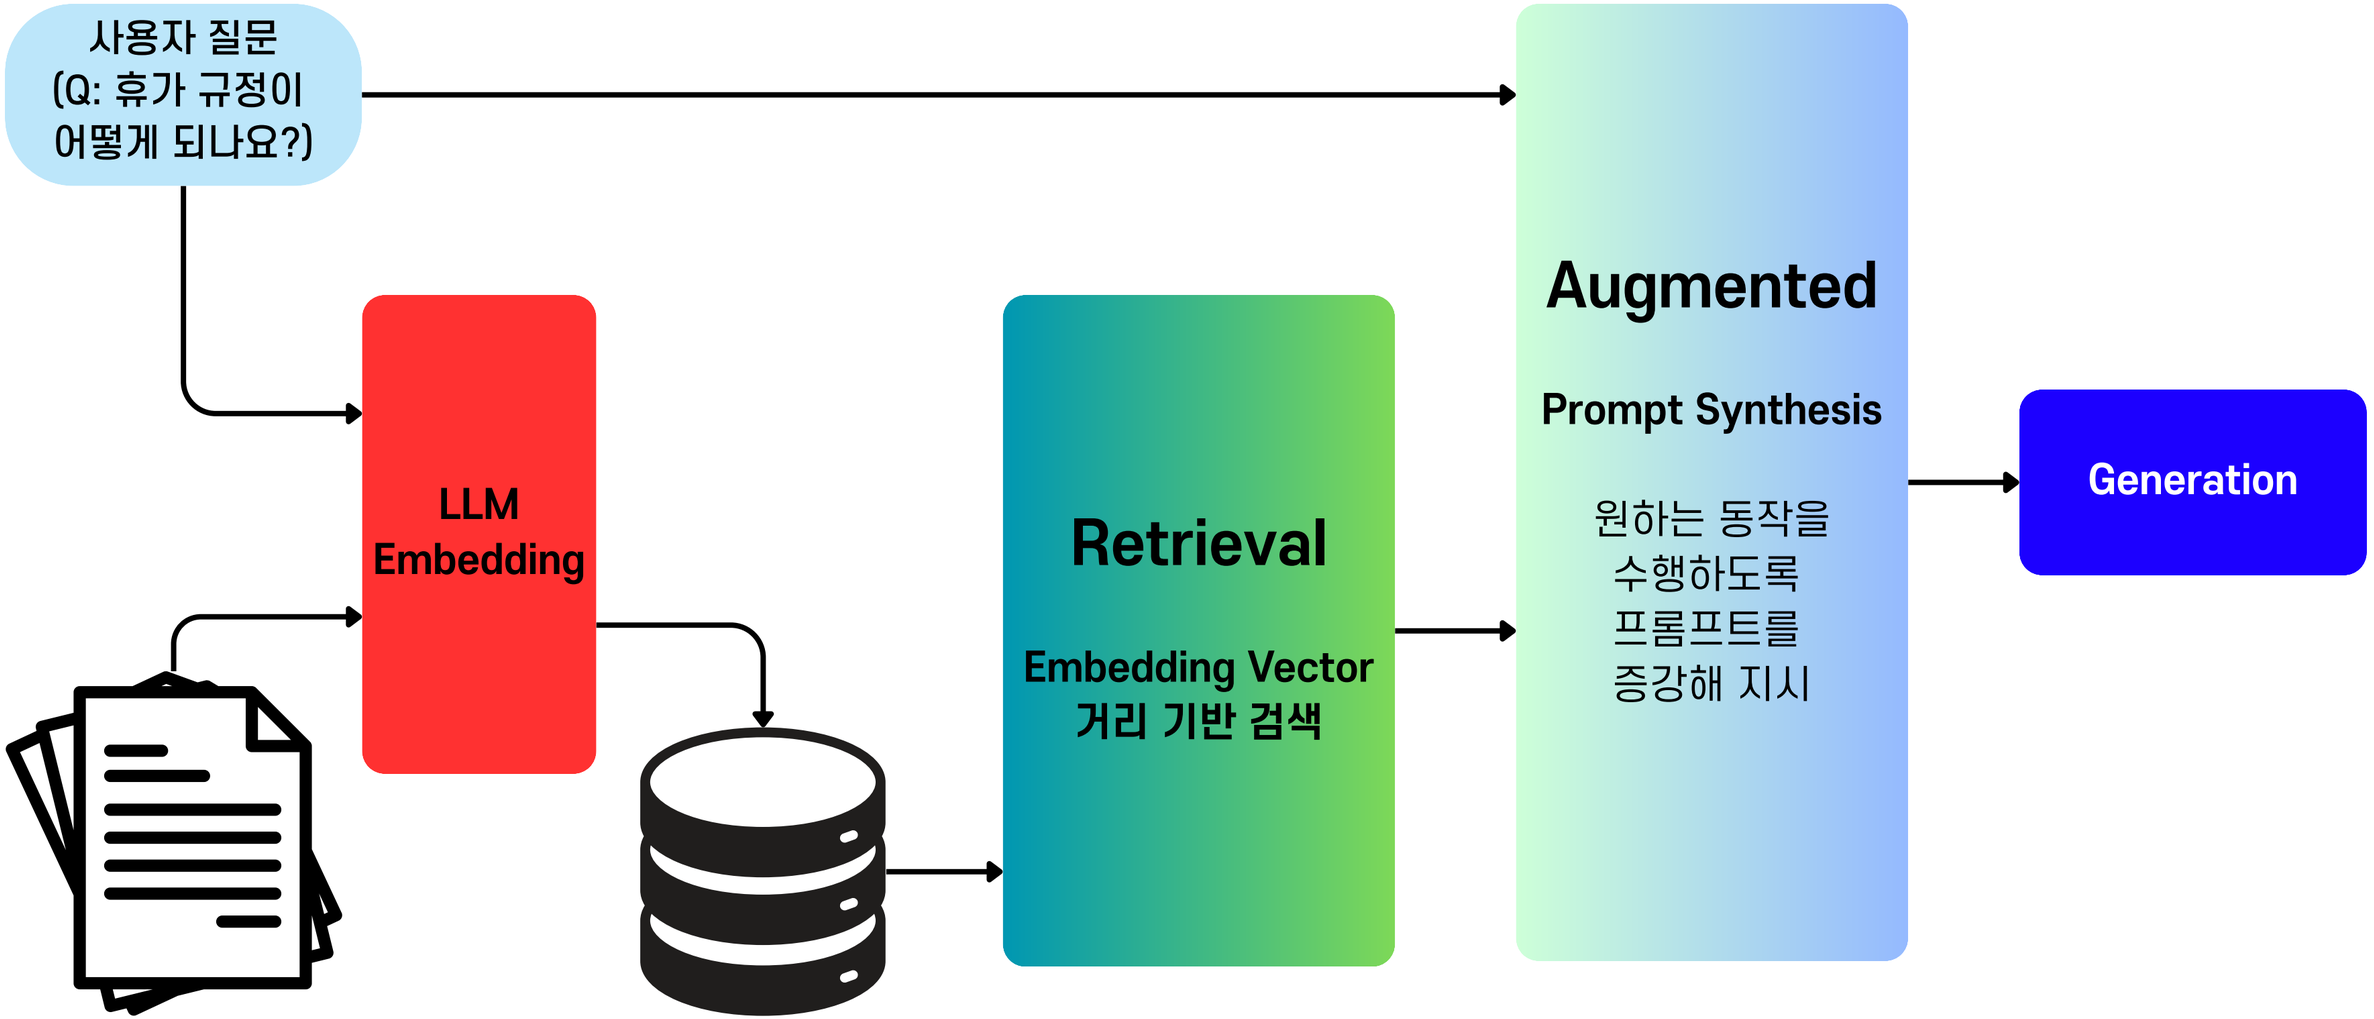
Retrieval Augmented Generation (RAG)



Slides by Junseop So

[Gao et al., Retrieval-Augmented Generation for Large Language Models: A Survey (2024)]

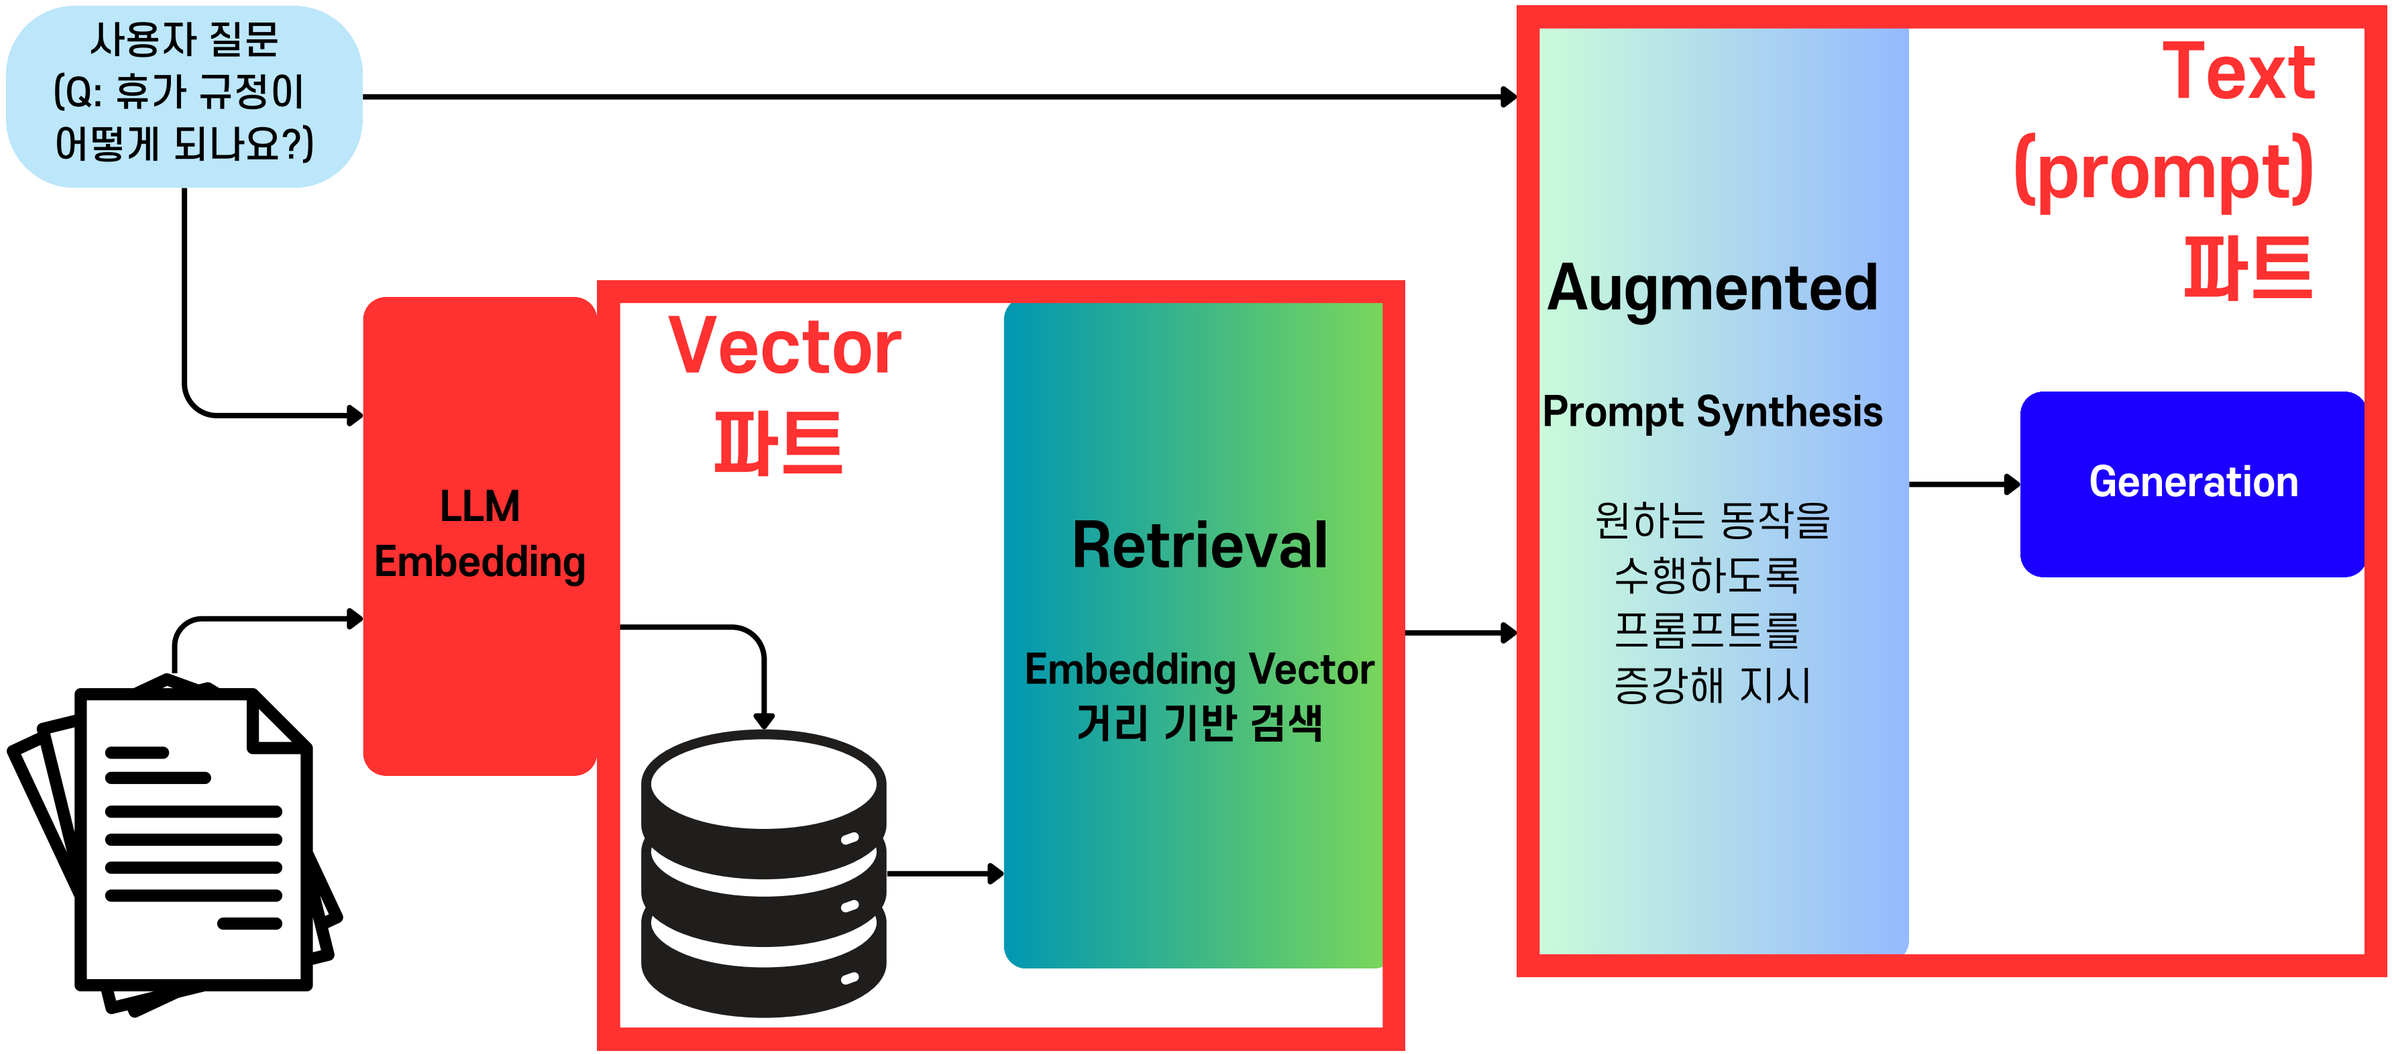
Retrieval Augmented Generation (RAG)



Slides by Junseop So

[Gao et al., Retrieval-Augmented Generation for Large Language Models: A Survey (2024)]

Retrieval Augmented Generation (RAG)



Slides by Junseop So

[Gao et al., Retrieval-Augmented Generation for Large Language Models: A Survey (2024)]

Testing Generative Models

Model based Score

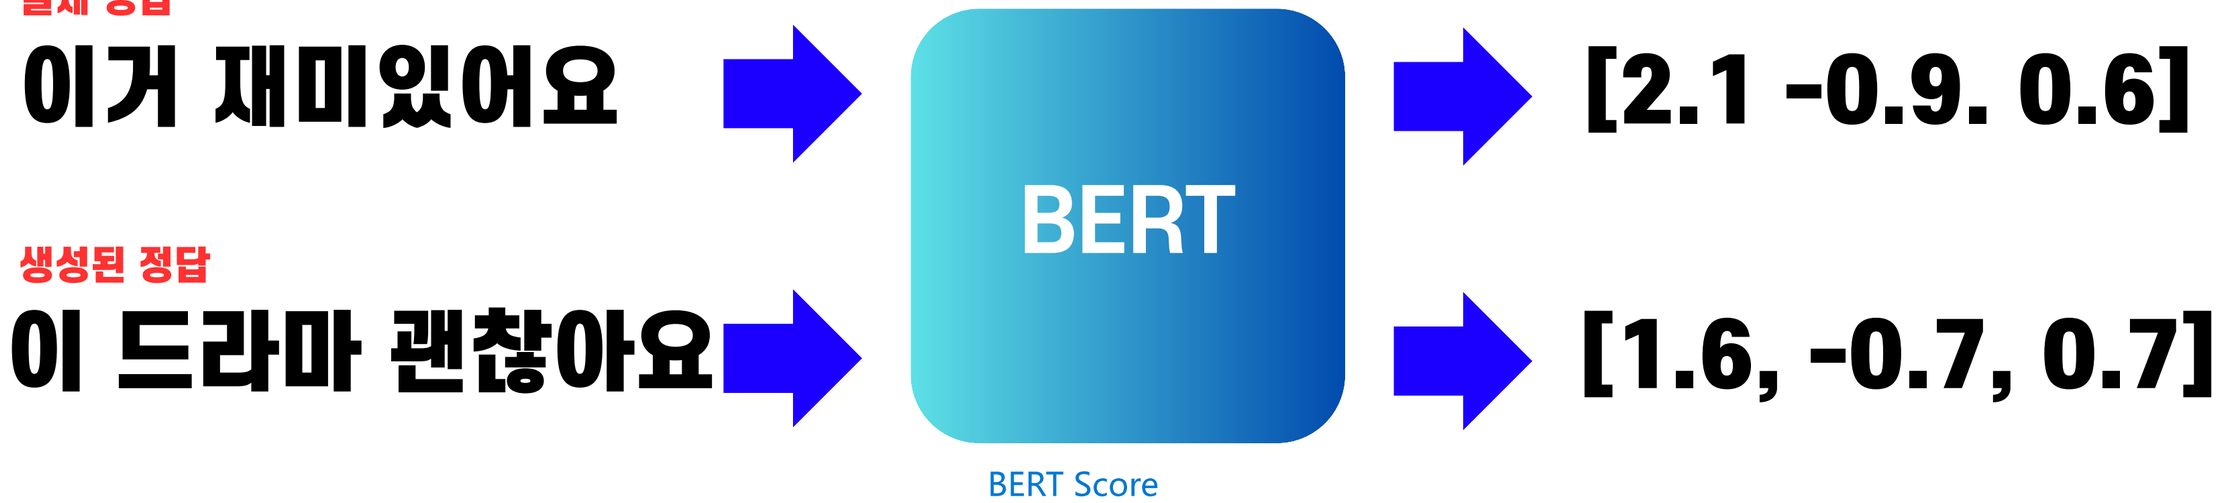
Q: 이 드라마 어때요?

실제 정답

이거 재미있어요

생성된 정답

이 드라마 괜찮아요



Slides by Junseop So

[Yuan et al. (2021): BARTScore: Evaluating Generated Text as Text Generation]

Testing Generative Models

LLM-as-a-Judge

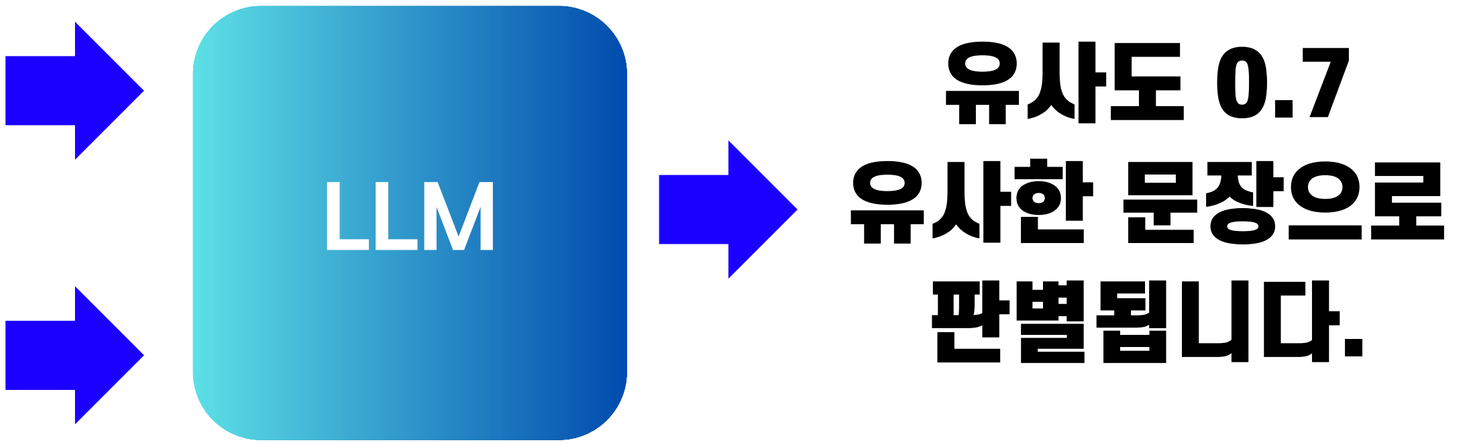
Q: 이 드라마 어때요?

실제 정답

이거 재미있어요

생성된 정답

이 드라마 괜찮아요



유사도 0.7
유사한 문장으로
판별됩니다.

Slides by Junseop So

[Zheng et al. (2023): Judging LLM-as-a-judge with MT-Bench and Chatbot Arena]

Testing Generative Models

```
[System]
Please act as an impartial judge and evaluate the quality of the responses provided by two
AI assistants to the user question displayed below. Your evaluation should consider
correctness and helpfulness. You will be given a reference answer, assistant A's answer,
and assistant B's answer. Your job is to evaluate which assistant's answer is better.
Begin your evaluation by comparing both assistants' answers with the reference answer.
Identify and correct any mistakes. Avoid any position biases and ensure that the order in
which the responses were presented does not influence your decision. Do not allow the
length of the responses to influence your evaluation. Do not favor certain names of the
assistants. Be as objective as possible. After providing your explanation, output your
final verdict by strictly following this format: "[[A]]" if assistant A is better, "[[B]]"
if assistant B is better, and "[[C]]" for a tie.

[User Question]
{question}

[The Start of Reference Answer]
{answer_ref}
[The End of Reference Answer]

[The Start of Assistant A's Answer]
{answer_a}
[The End of Assistant A's Answer]

[The Start of Assistant B's Answer]
{answer_b}
[The End of Assistant B's Answer]
```

Figure 8: The prompt for reference-guided pairwise comparison.

Slides by Junseop So

[Zheng et al. (2023): Judging LLM-as-a-judge with MT-Bench and Chatbot Arena]

Adaptive RAG

초기 RAG 구조적 한계

Augmented

Prompt Synthesis

원하는 동작을
수행하도록
프롬프트를
증강해 지시

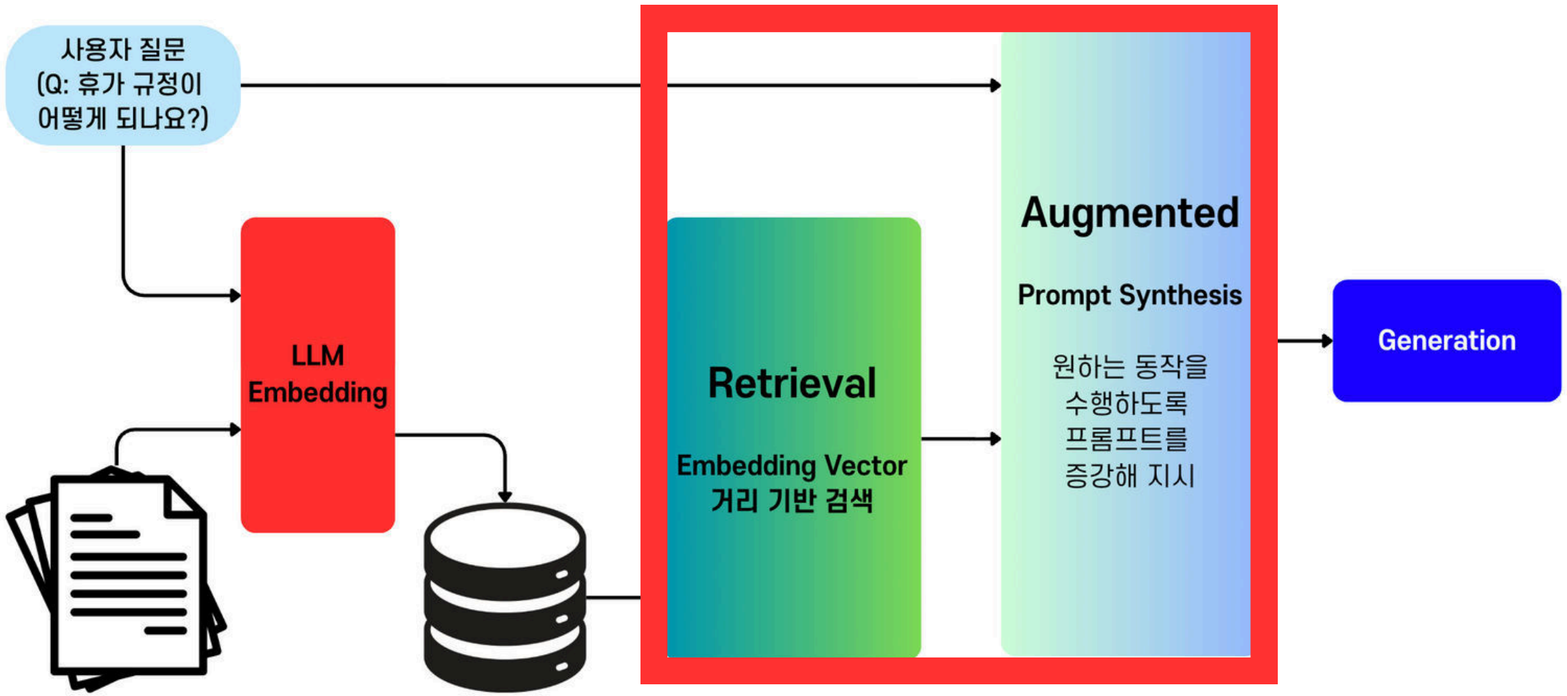
사용자의 질문 → 무조건 외부 데이터를 검색



검색이 필요없는 질문도 검색 진행 → 토큰 낭비

Adaptive RAG

Function Calling을 이용해 RAG를 구현한다면?



Retrieval, Augmented 파트를
내가 원할때만 동작 시킬 수 있다.

Agent workflows

LLMs 성능 향상 방법

User Prompt: 내일 제주도 가는 비행기를 검색해줘.

Task Decomposition: 모델이 수행할 단계를 나눈다

a. 중요한 데이터를 먼저 추출한다.
b. 사용자의 정보들을 검색한다.
c. 답변 정책을 확인한다.
d. 위 내용을 모두 요약하여 답변을 진행한다.

[Dorri et al., Multi-Agent Systems: A Survey (2018)]

Agent workflows

Agent 동작

User Prompt: 내일 제주도 가는 비행기를 검색해줘.

Travel AI Agent

Context Management

Short-term Memory
Long-term Memory

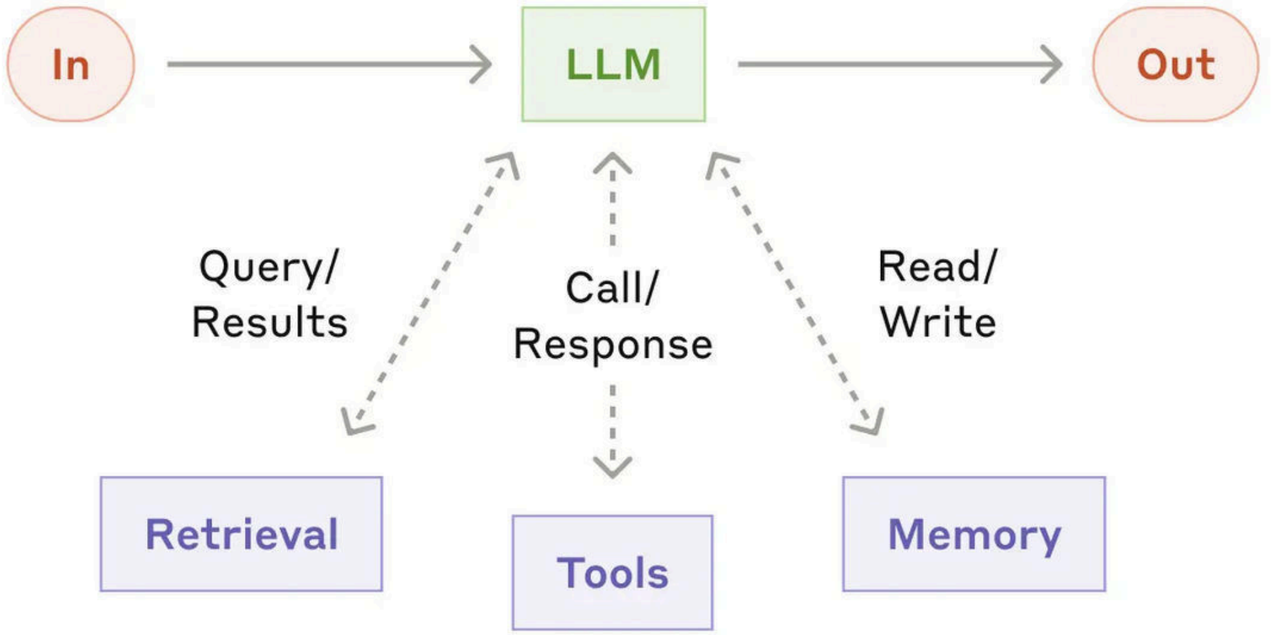
Tools

Flight Search Tool
Travel Data Tool
...

Slides by Junseop So

[Dorri et al., Multi-Agent Systems: A Survey (2018)]

Agent workflows



[Anthropic, Building effective agents]

Multi-Agent workflows

Multi-Agent는 각 기능을 담당하는 Agent를 구현한다

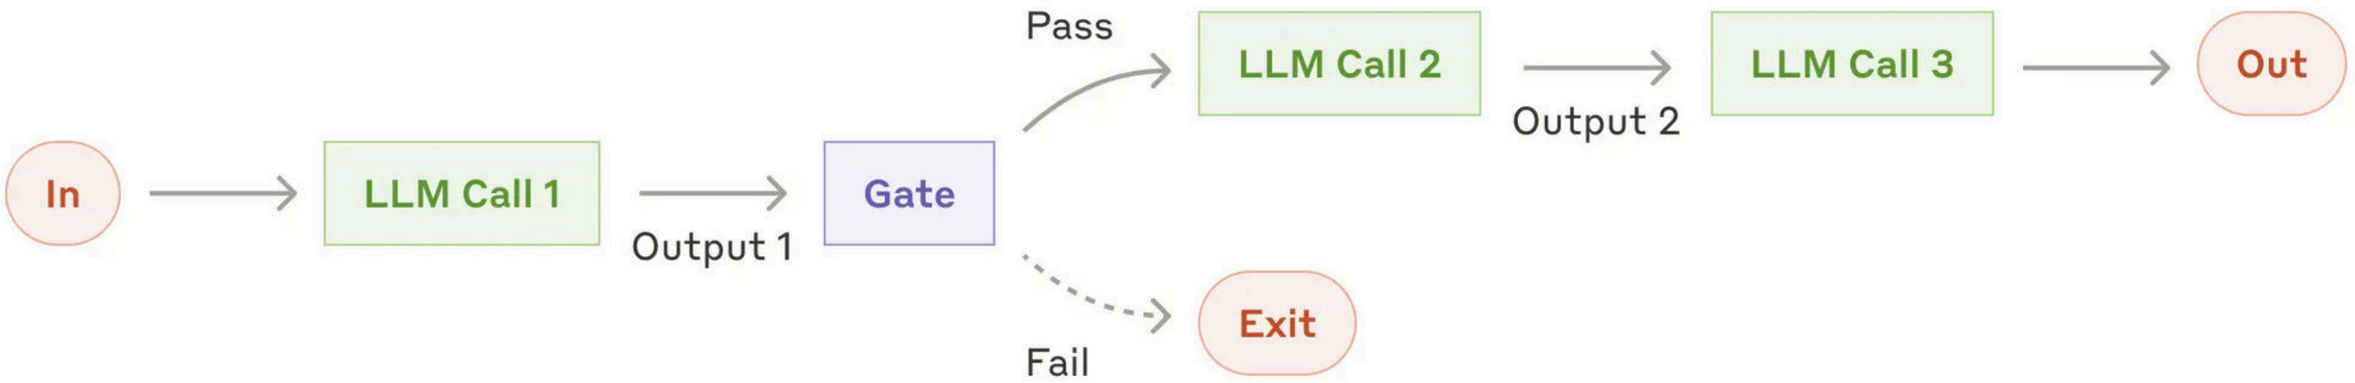


Slides by Junseop So

[Dorri et al., Multi-Agent Systems: A Survey (2018)]

Multi-Agent workflows

Prompt Chaining

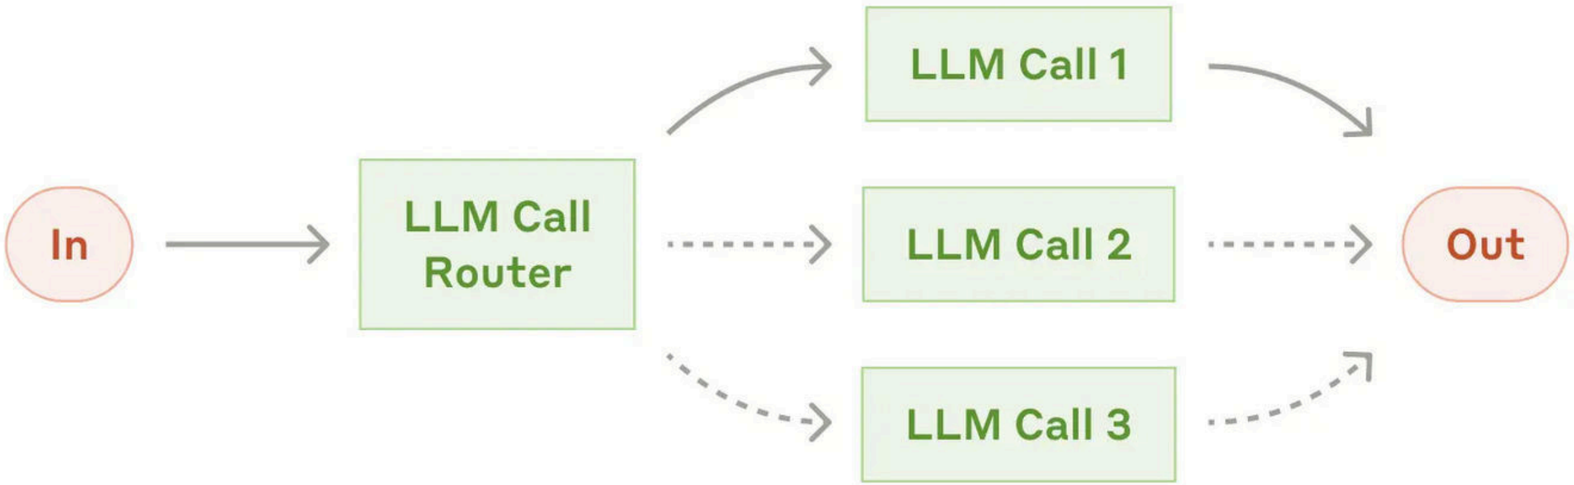


Slides by Junseop So

[Anthropic, Building effective agents]

Multi-Agent workflows

Prompt Routing



Slides by Junseop So

[Anthropic, Building effective agents]

Multimodal SLM

SLM

언어 생성 모델이란?

여기에 ???

LLM visualization [https://bbycroft.net/llm]

SLM

언어 생성 모델이란?

내 물건을 찾으러 여기에 ???

LLM visualization [https://bbycroft.net/llm]

SLM

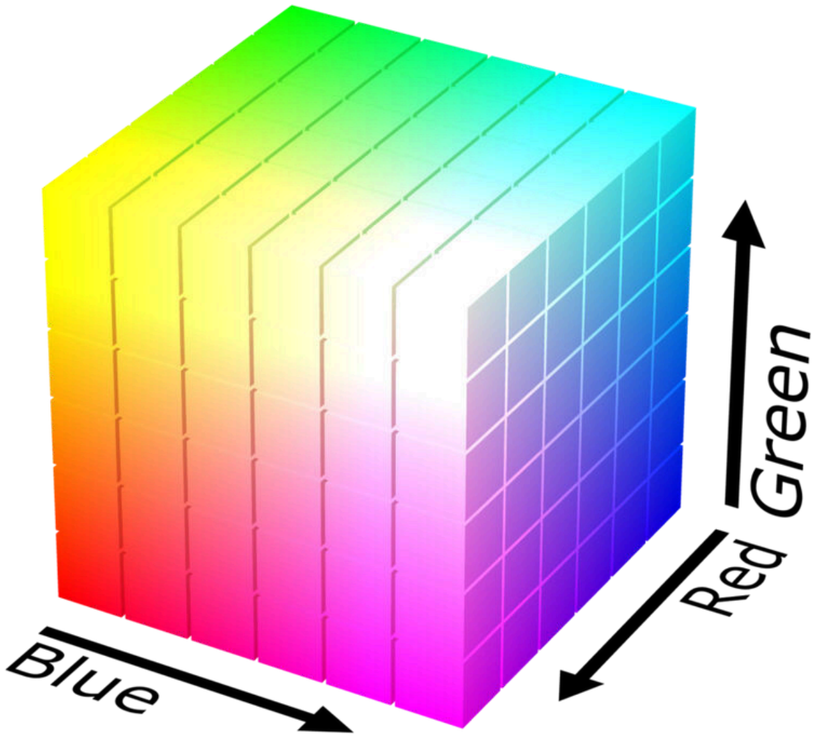
언어 생성 모델이란?

어제 내 물건을 찾으러 여기에 ???

LLM visualization [https://bbycroft.net/llm]

SLM

Embedding → RGB & Text



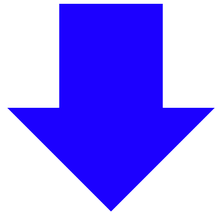
Slides by Junseop So

Attention Is All You Need, Vaswani et al., 2017

SLM

Text to Vector Embeddings

어제 내 물건을 찾으러 여기에 ???



Vector Embeddings

Attention Is All You Need, Vaswani et al., 2017

SLM

Text to Vector Embeddings

어제 내 물건을 찾으러 여기에 ???



Vector Embeddings
[542, 45, ... 6179, 2724]

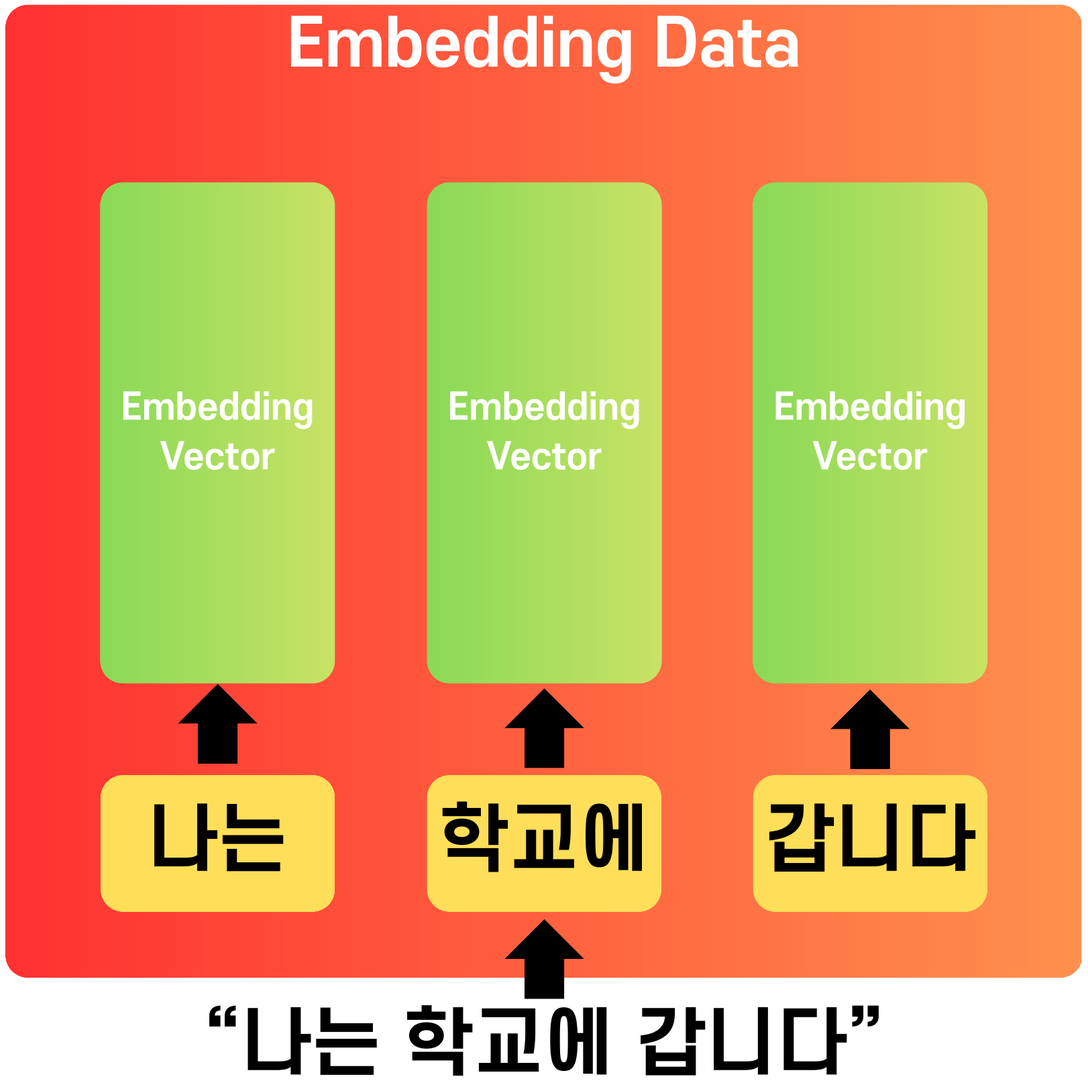


[[0.5, -1.2, ... 0.03], [-2.5, -1.2, ... 0.013] ... ... [0.1, 1.2, ... -0.034]]

Slides by Junseop So

Attention Is All You Need, Vaswani et al., 2017

Embedding Layer



Slides by Junseop So

Attention Is All You Need, Vaswani et al., 2017

SLM

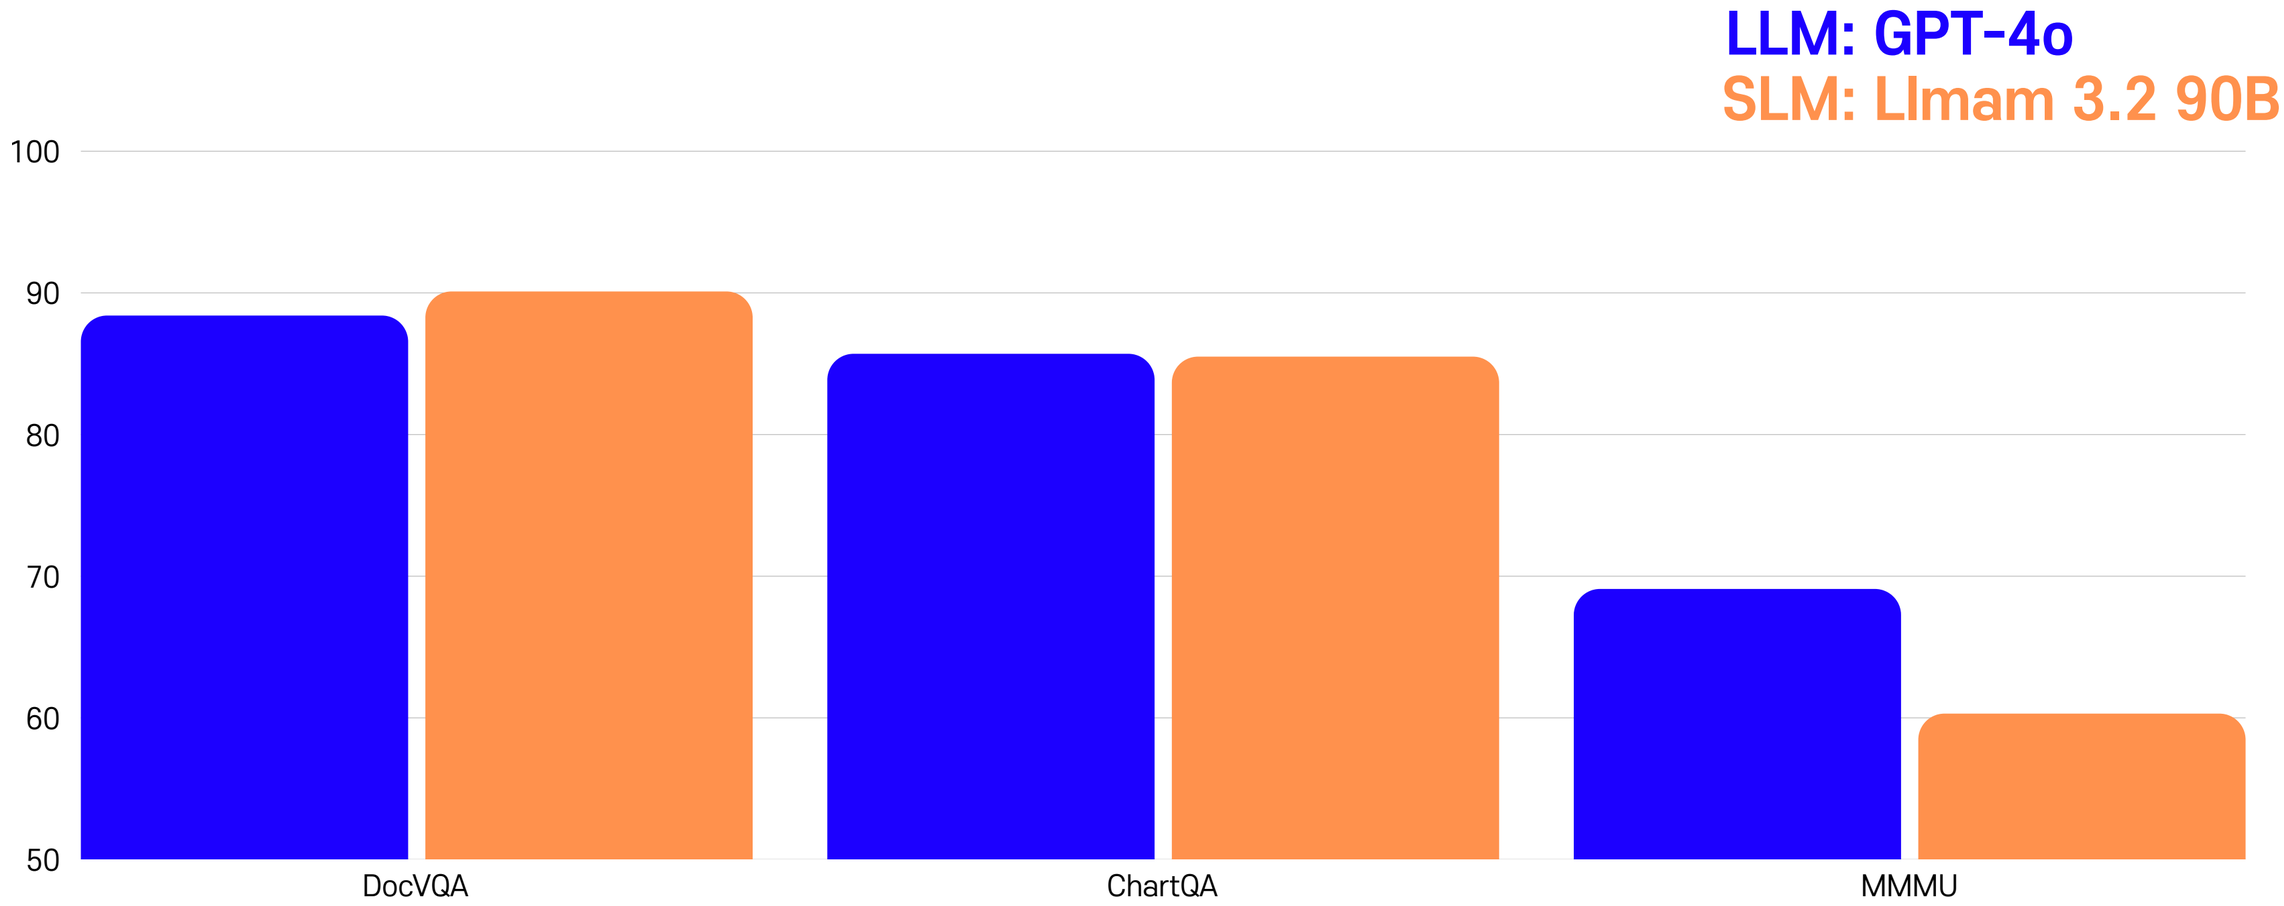
Small Language Models

플랫폼	'SLM' 검색 결과 (글로벌 표준)	'sLLM' 검색 결과 (한국 중심)	비고
Reddit	■■■■■■■■■■■■■■■■ (매우 높음)	■■ (매우 낮음)	sLLM은 주로 한국 관련 뉴스에서만 등장
ArXiv (논문)	■■■■■■■■■■ (높음)	■■ (낮음)	sLLM 사용 논문의 저자 소속 확인 필요
Naver (한국)	■■■■■■ (보통)	■■■■■■■■■■■■ (매우 높음)	한국에서는 sLLM이 마케팅 용어로 정착

ChatGPT DeepResearch

SLM

LLM & SLM

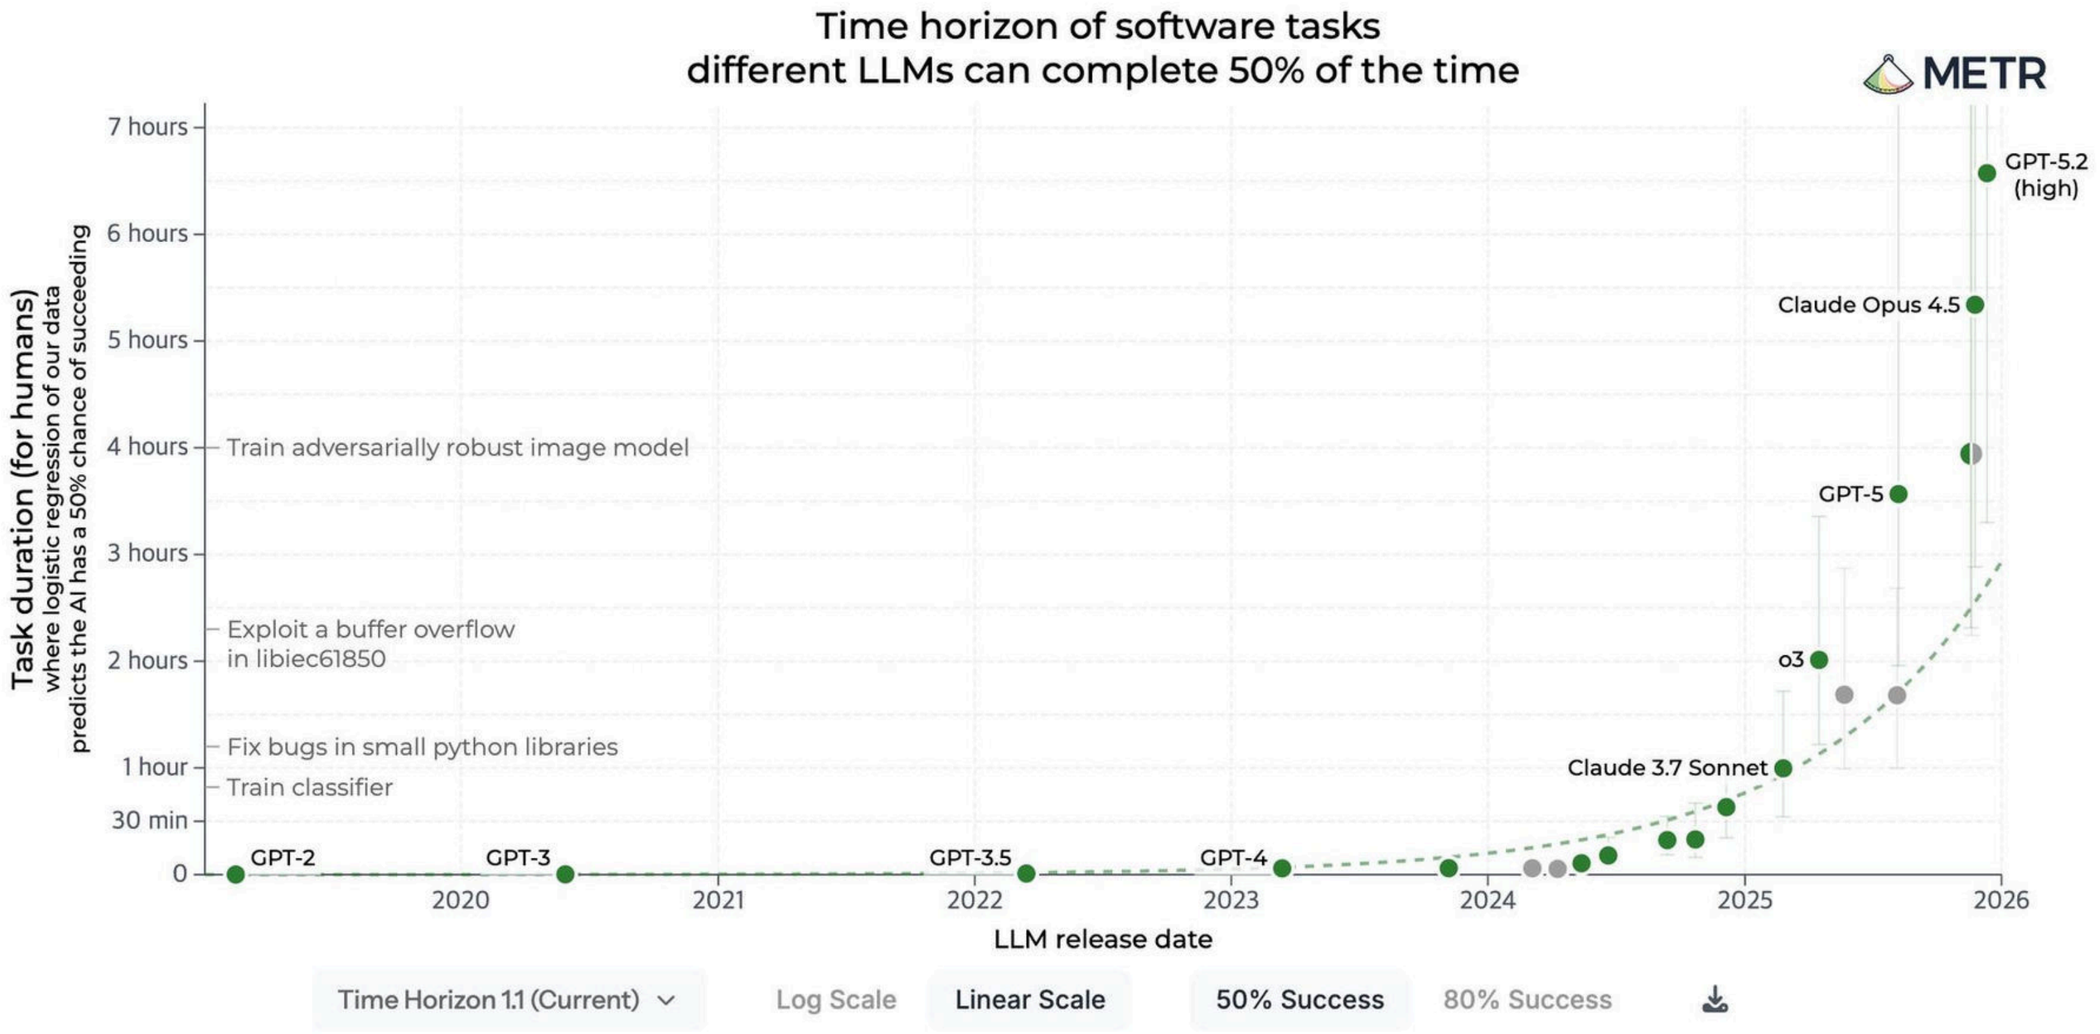


기업용 문서 시각 자료 분석 (Document & Vision)

Slides by Junseop So

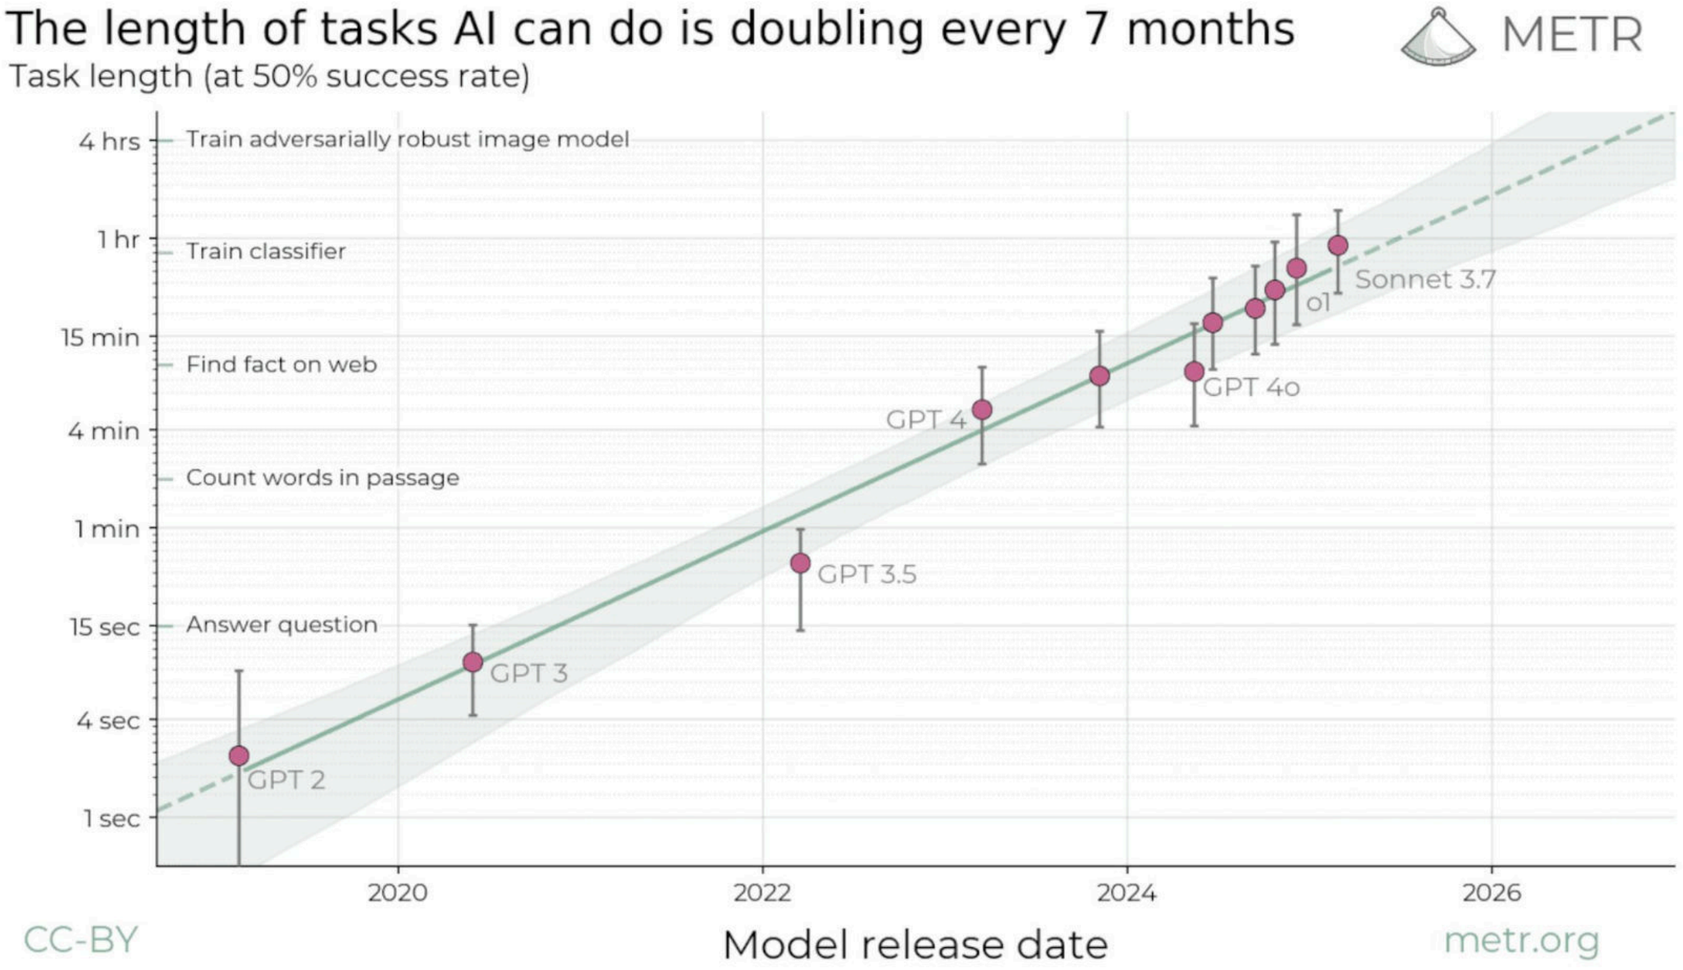
Llama 3.2 vs GPT-4o: Choosing the Right AI Model https://blogs.novita.ai/llama-3-2-vs-gpt-4o-choosing-the-right-ai-model/

SLM


Time horizon of software tasks
different LLMs can complete 50% of the time
METR
Task duration (for humans)
where logistic regression of our data
predicts the AI has a 50% chance of succeeding
7 hours
6 hours
5 hours
4 hours
3 hours
2 hours
1 hour
30 min
0
Train adversarially robust image model
Exploit a buffer overflow
in libiec61850
Fix bugs in small python libraries
Train classifier
GPT-2
GPT-3
GPT-3.5
GPT-4
Claude 3.7 Sonnet
o3
GPT-5
Claude Opus 4.5
GPT-5.2
(high)
2020
2021
2022
2023
2024
2025
2026
LLM release date
Time Horizon 1.1 (Current)
Log Scale
Linear Scale
50% Success
80% Success

SLM

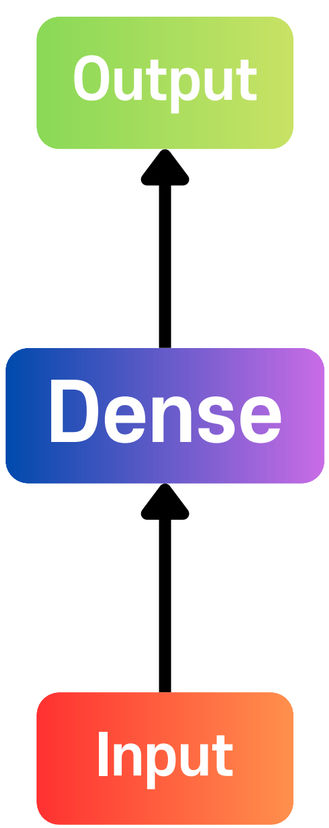
AI가 수행할 수 있는 작업은 7개월마다 2배로 증가



Slides by Junseop So

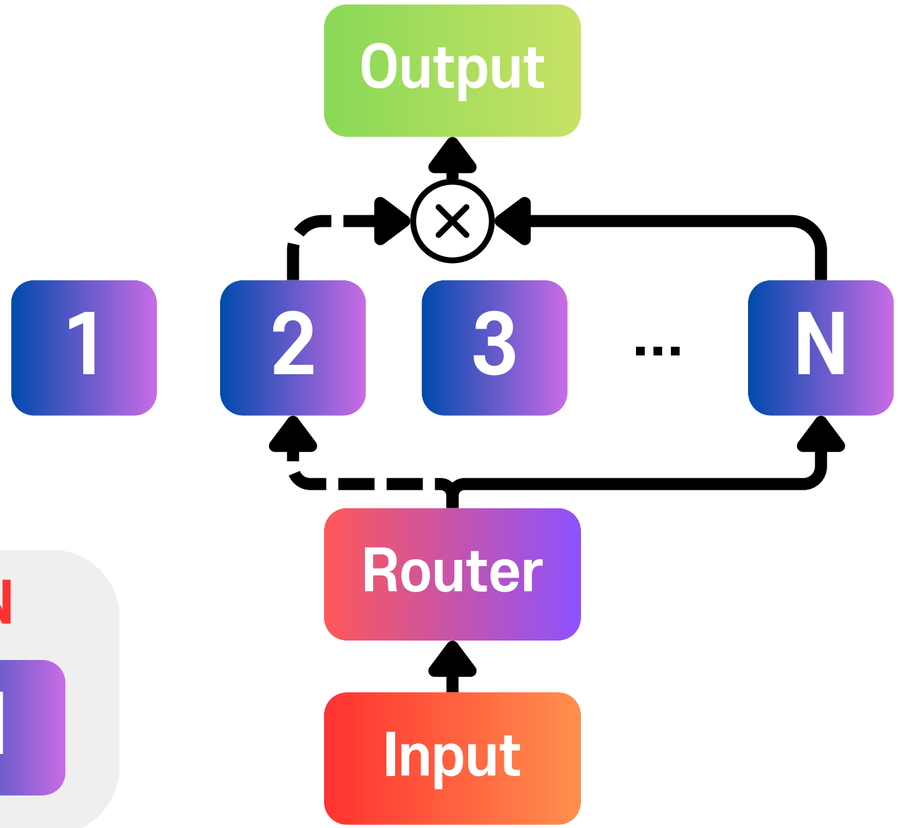
SLM

Dense and Mixture-of-Experts(MoE)



Same Size FFN



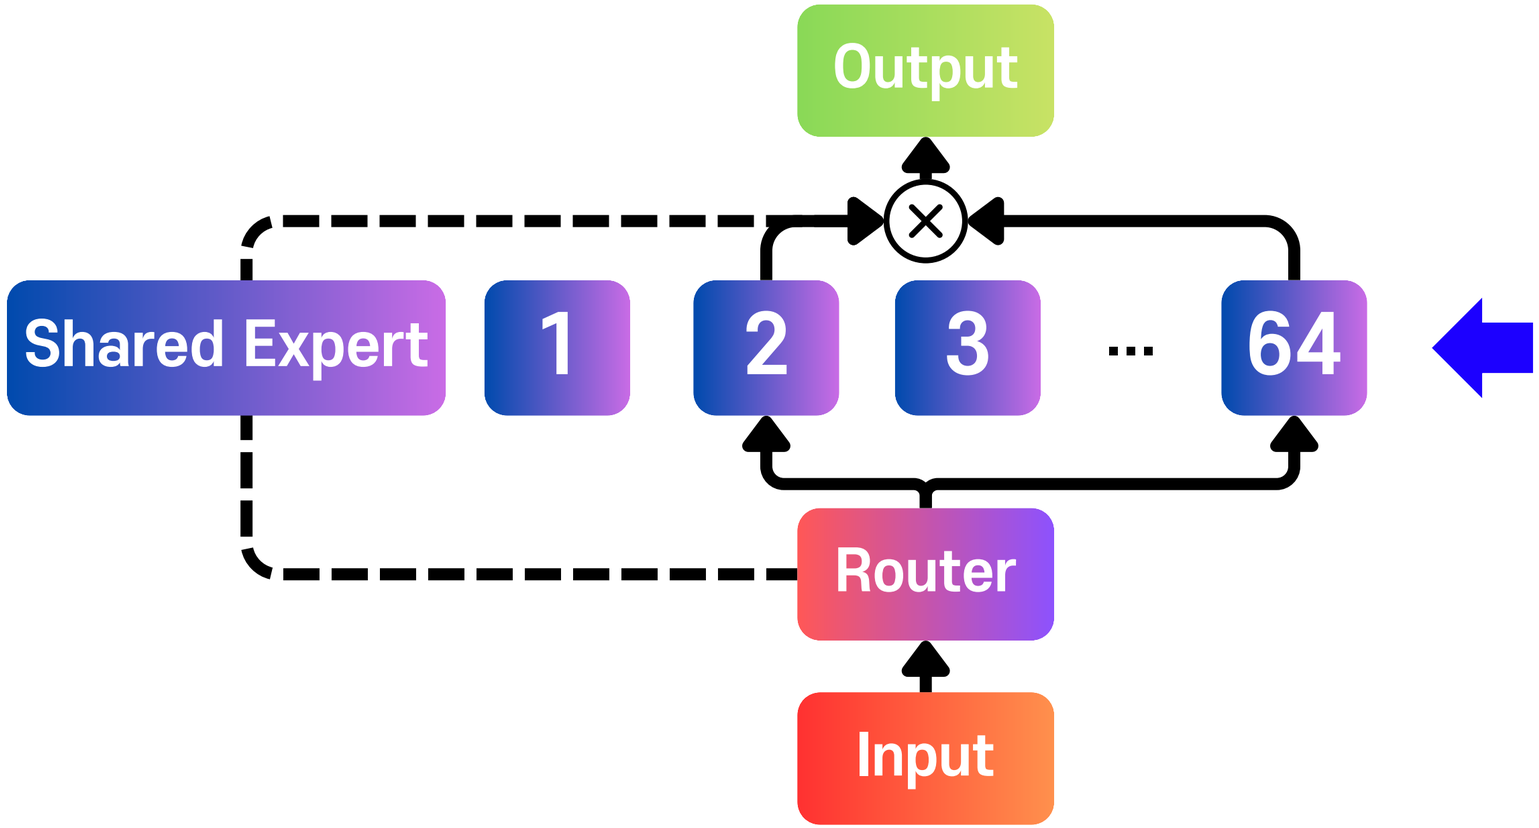


Slides by Junseop So

Noam Shazeer 2017 Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer

SLM

Small MoE

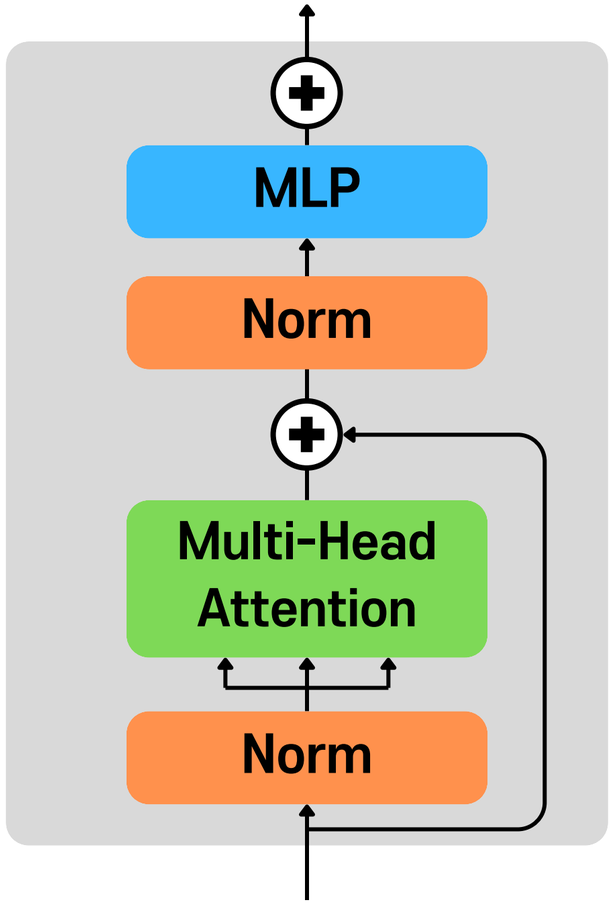


기존 FFN 크기의
25% 크기

Slides by Junseop So

SLM

Transformer Decoder

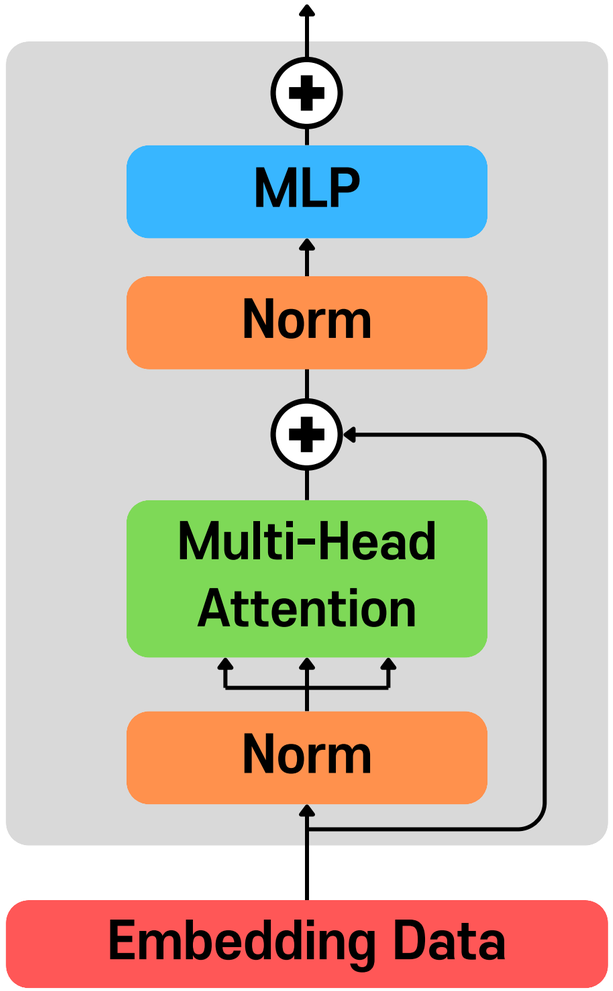


Slides by Junseop So

Attention Is All You Need, Vaswani et al., 2017

SLM

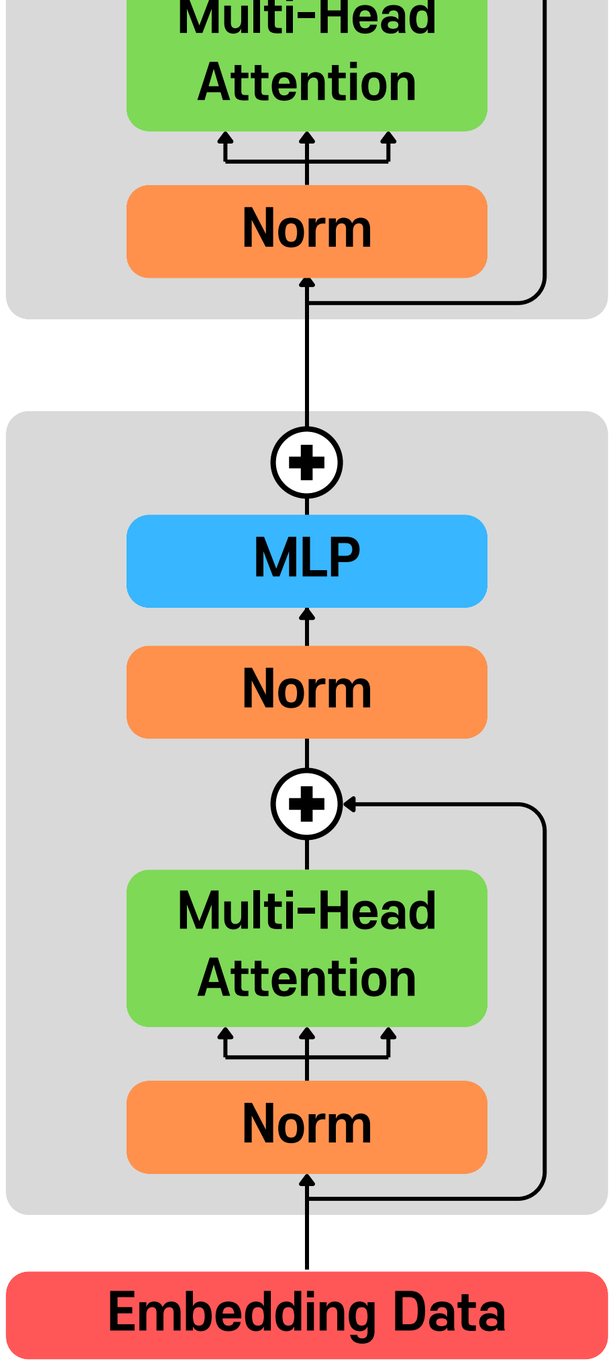
Embedding Layer



Slides by Junseop So

Attention Is All You Need, Vaswani et al., 2017

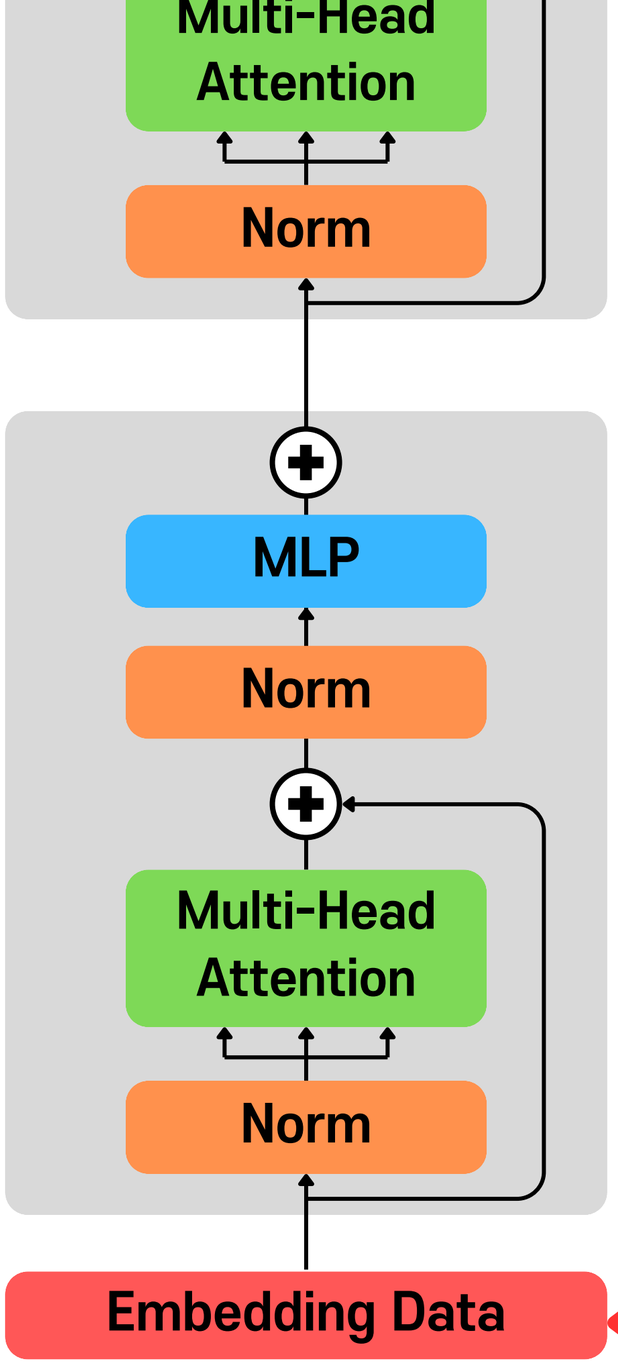
VLM



Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

VLM



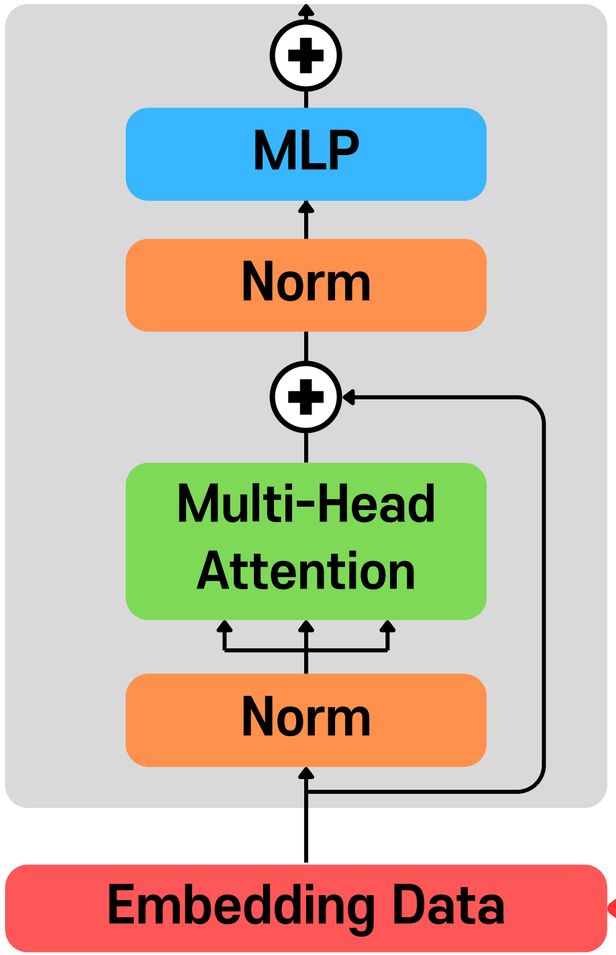
기본적으로 Embedding 된 Text 데이터가 입력됩니다.

Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

VLM

Vision Transformer



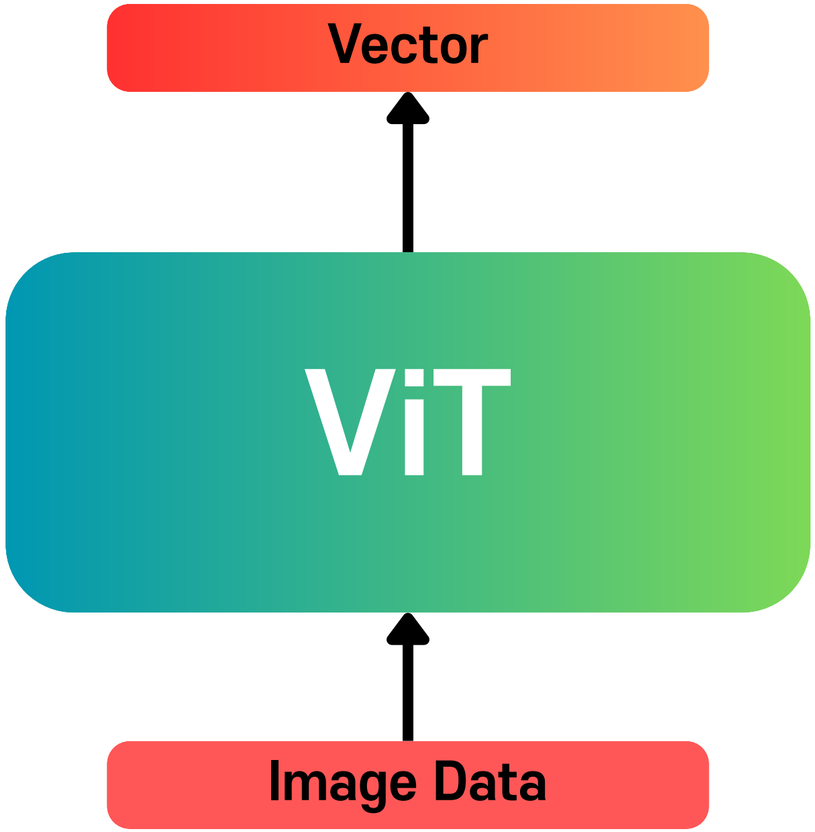
Vision의 경우 이미지 데이터가 Embedding되어 활용됩니다.

Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

Vision Transformer

Vision Transformer → Encoder

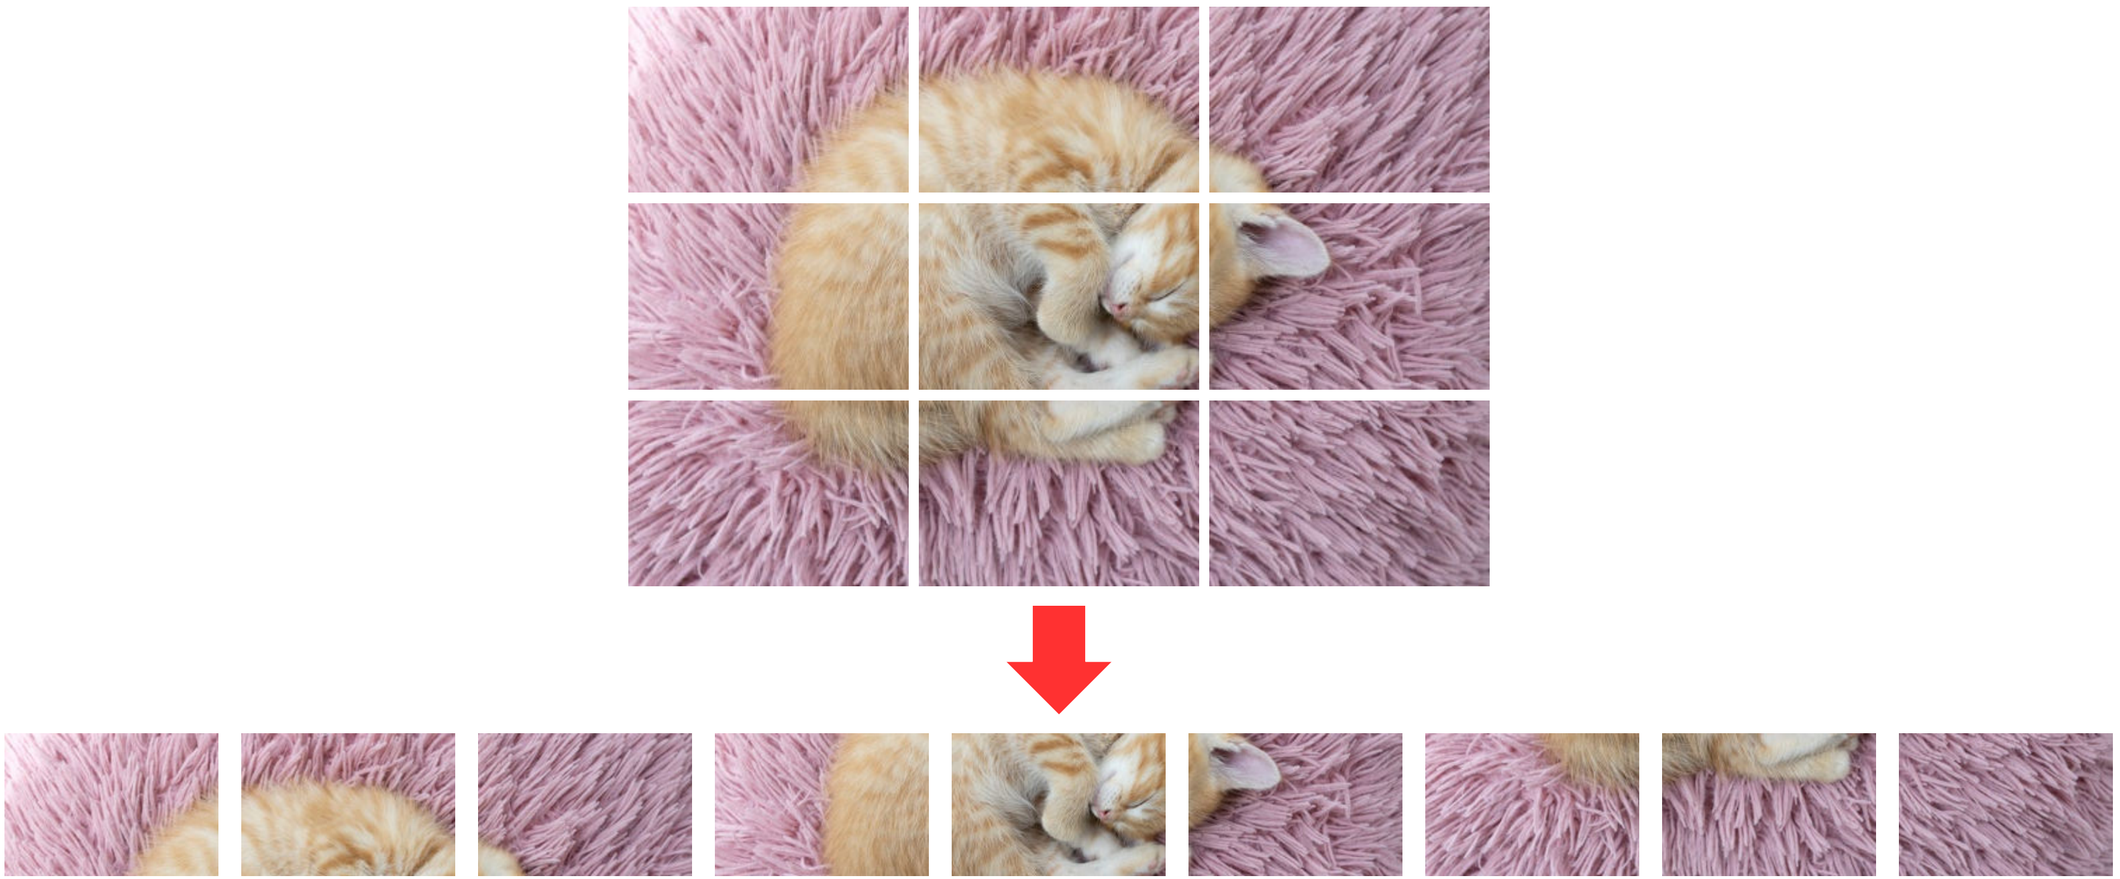


Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

Vision Transformer

Vision Transformer → Encoder

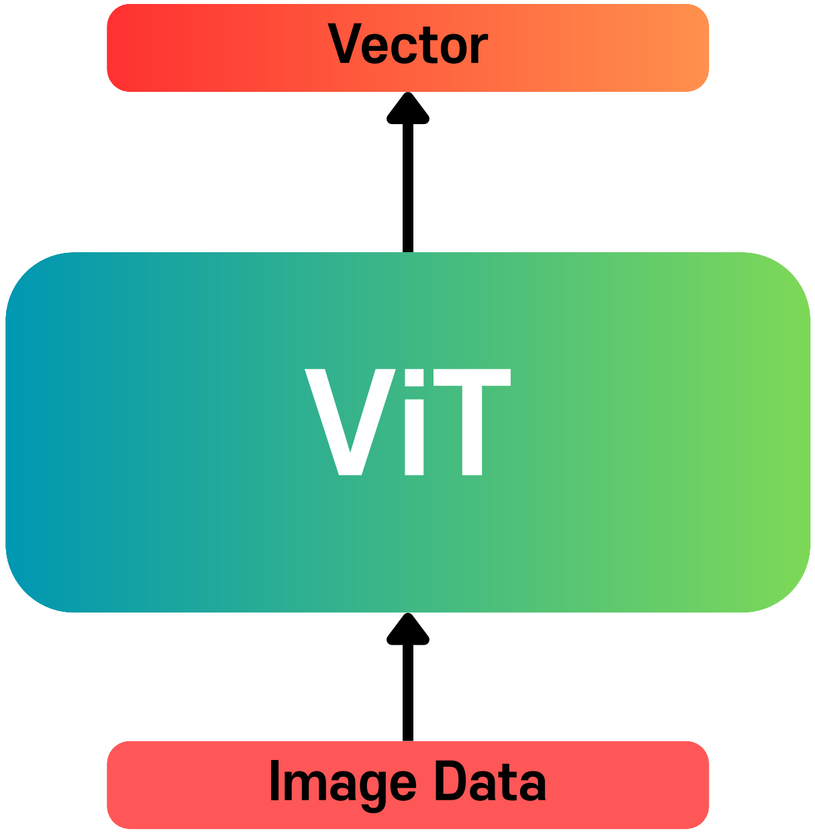


Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

Vision Transformer

Vision Transformer → Encoder

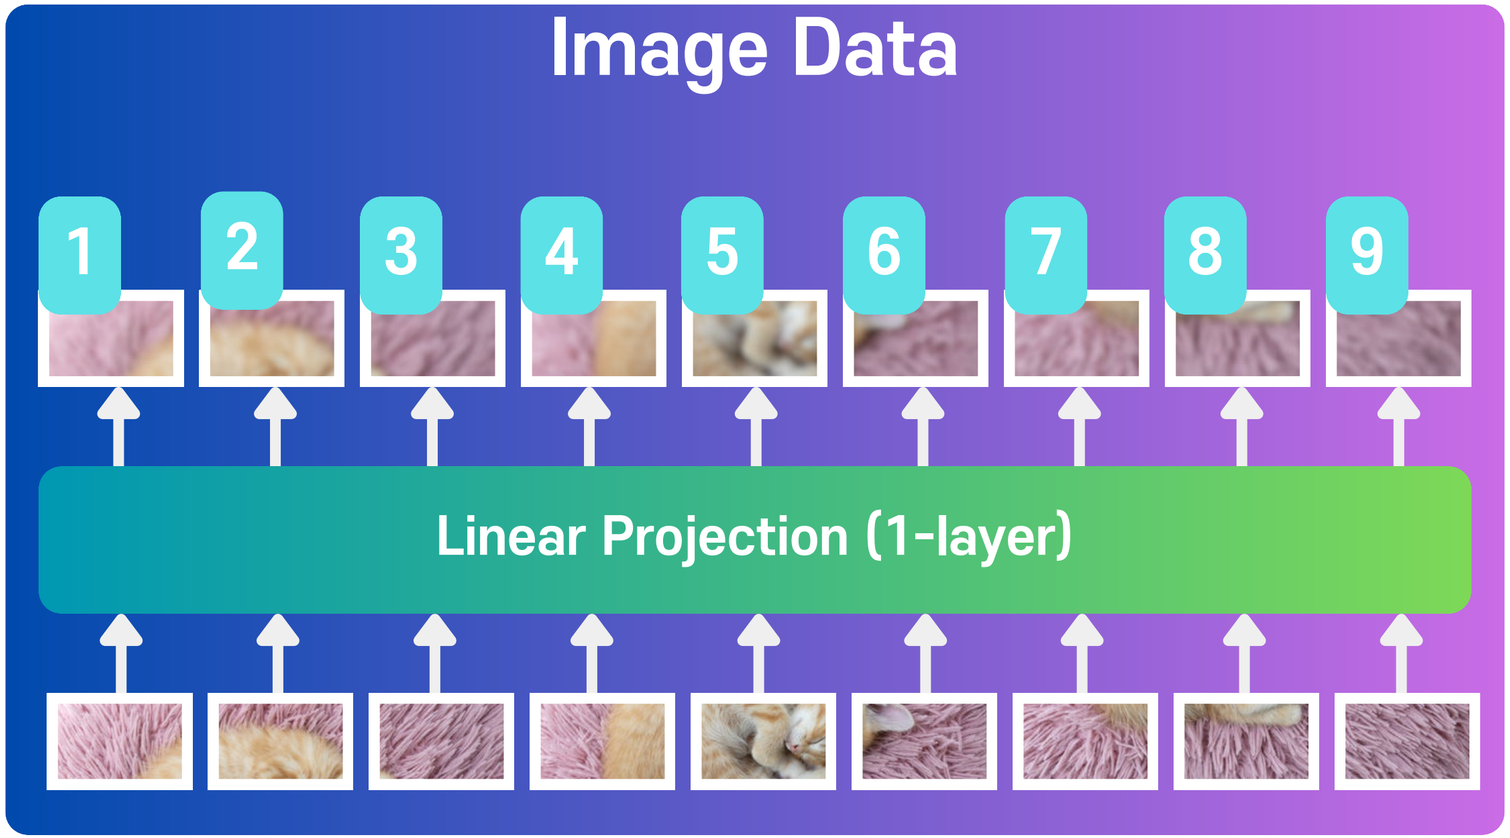


Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

Vision Transformer

Image Data Input (Linear Projection)



Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

Multimodal SLM

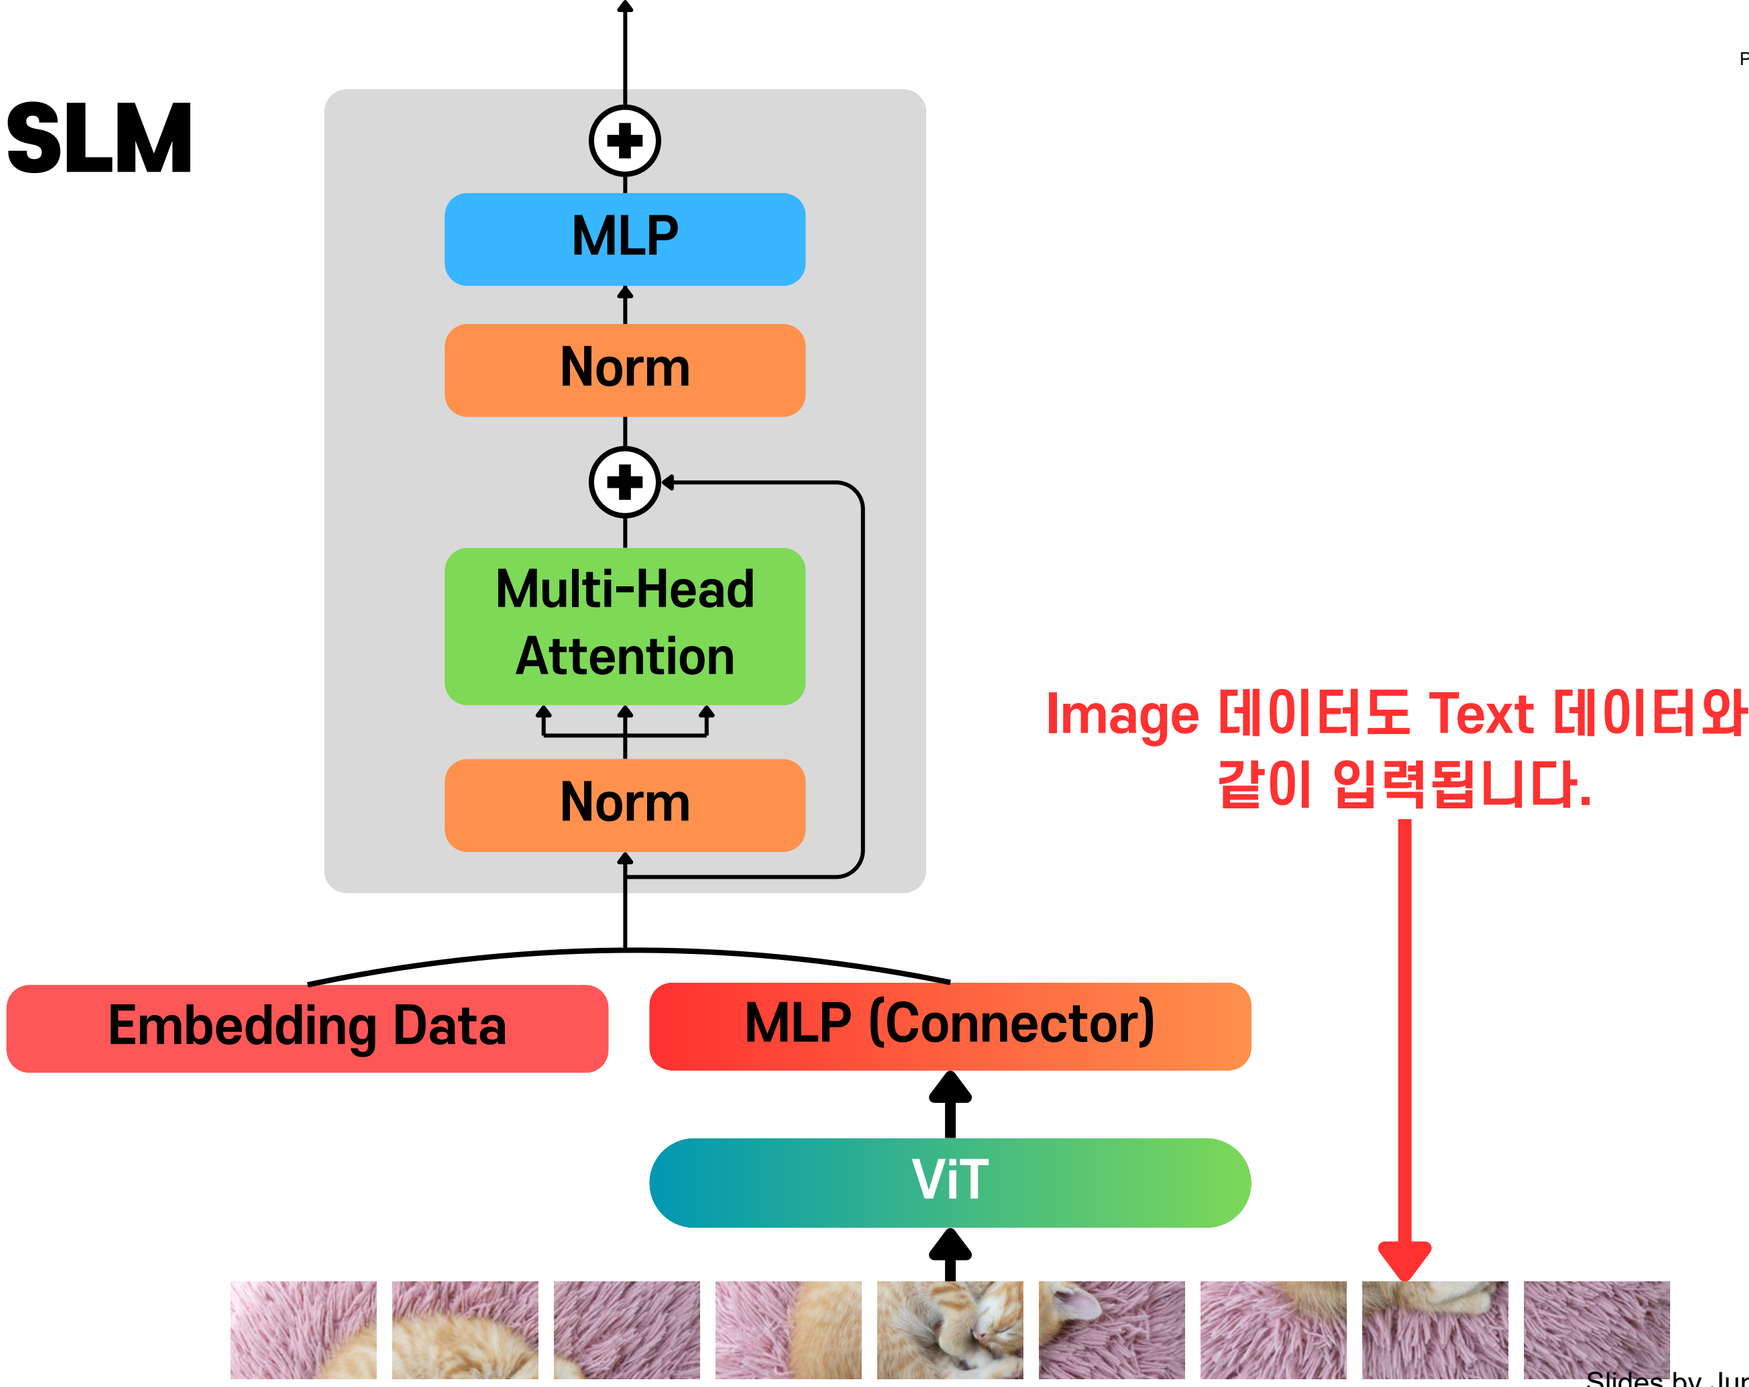
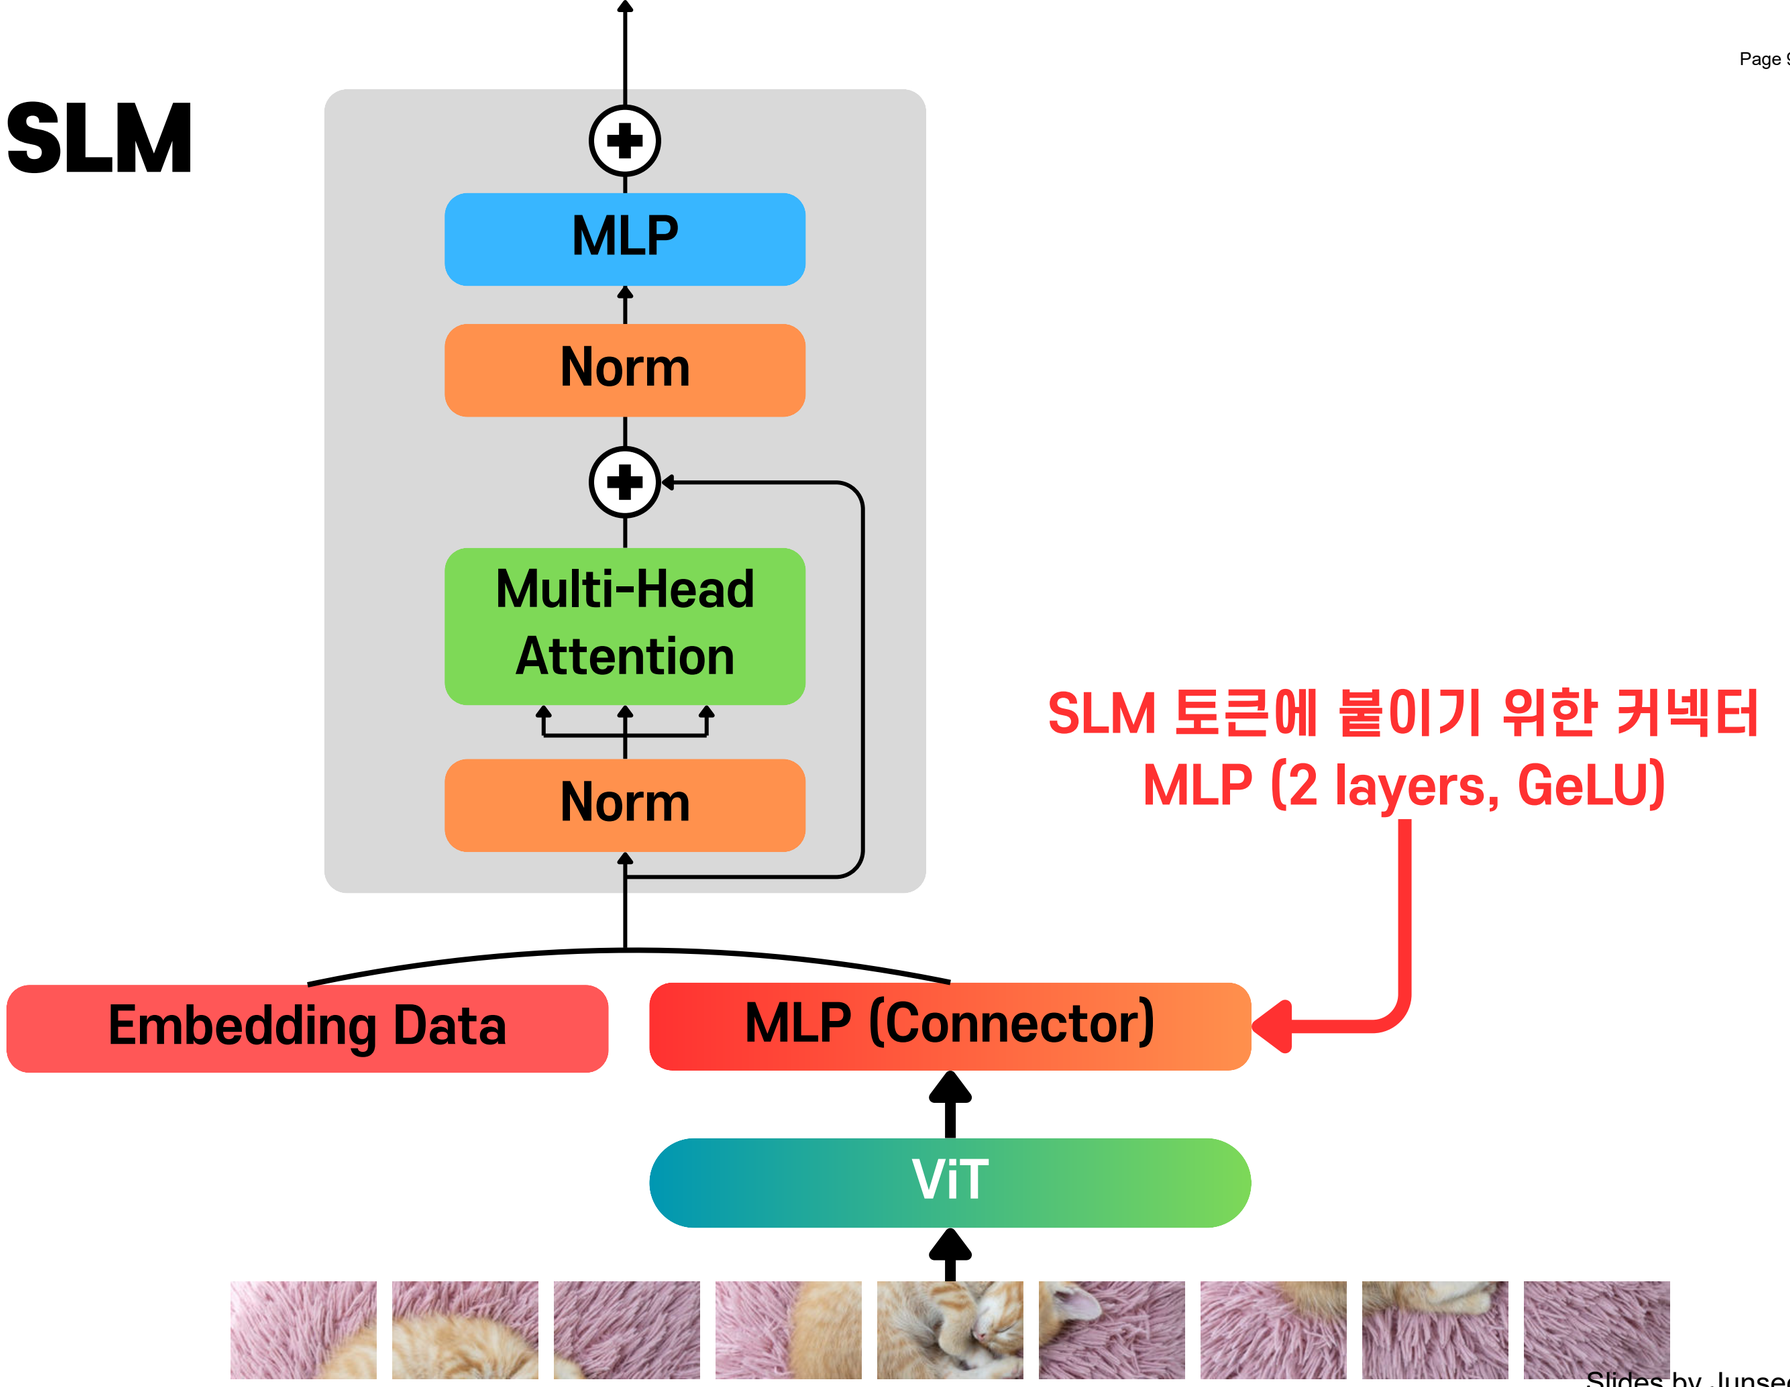


Image 데이터도 Text 데이터와 같이 입력됩니다.

Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

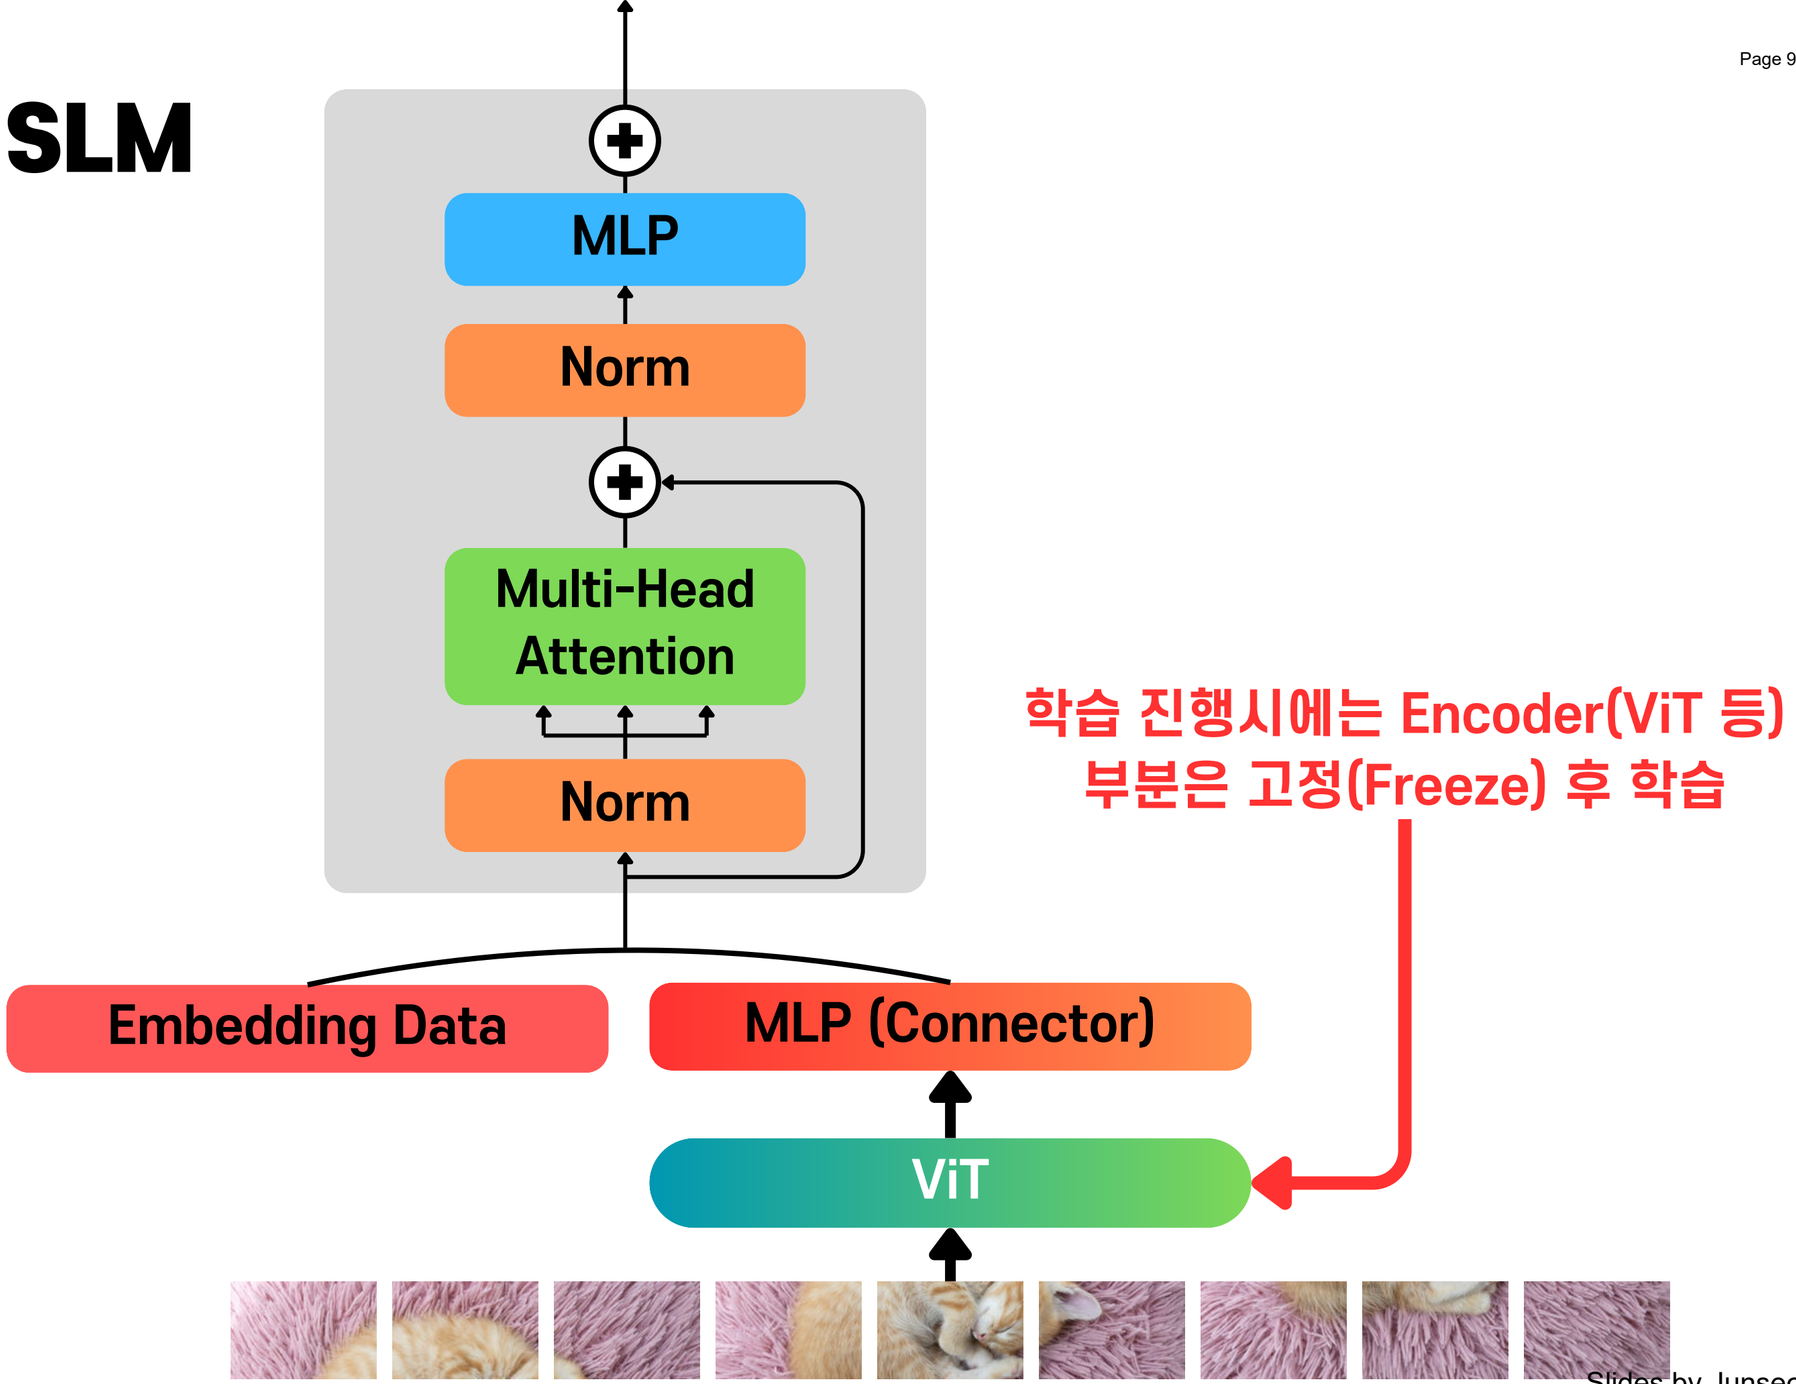
Multimodal SLM



Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

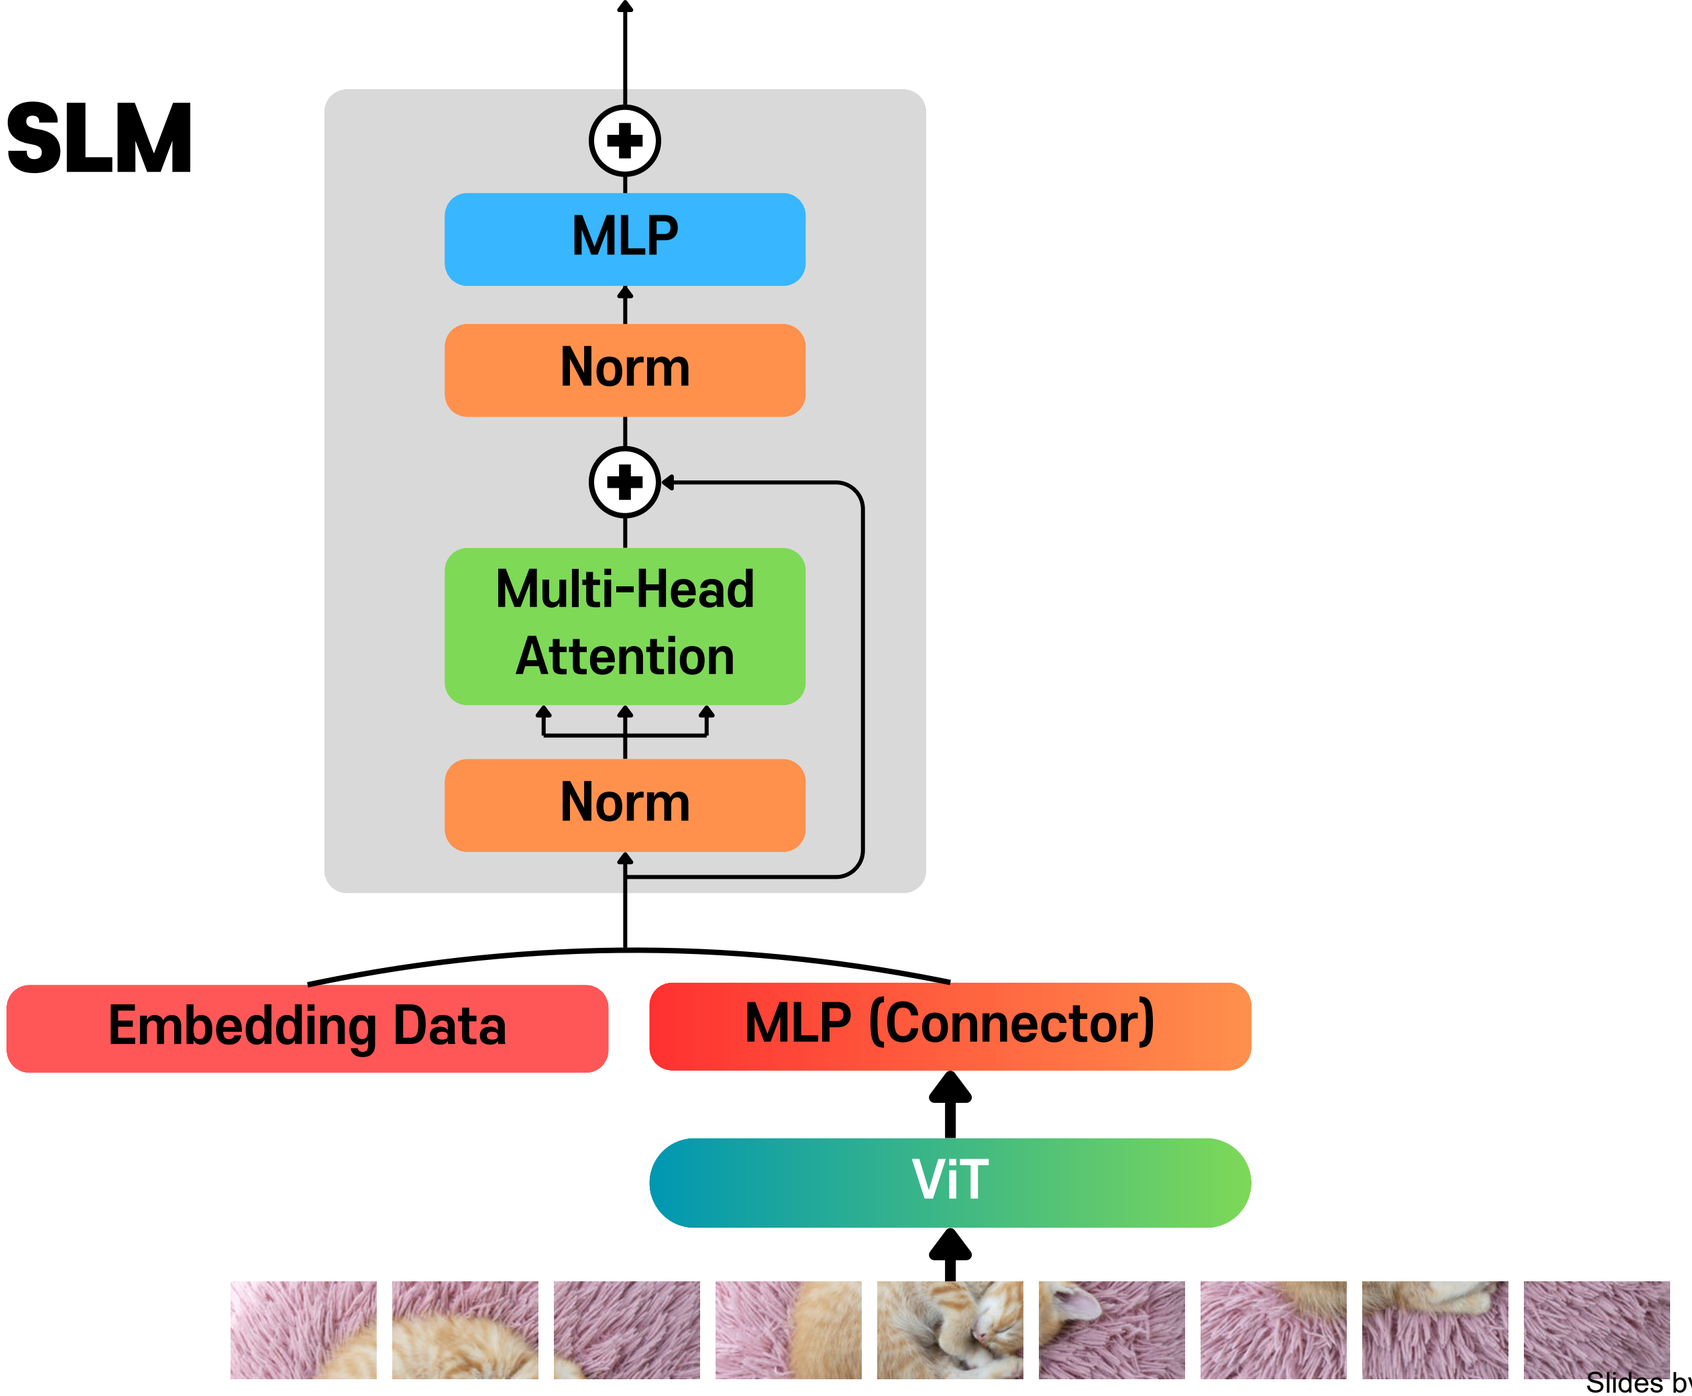
Multimodal SLM



Slides by Junseop So

Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

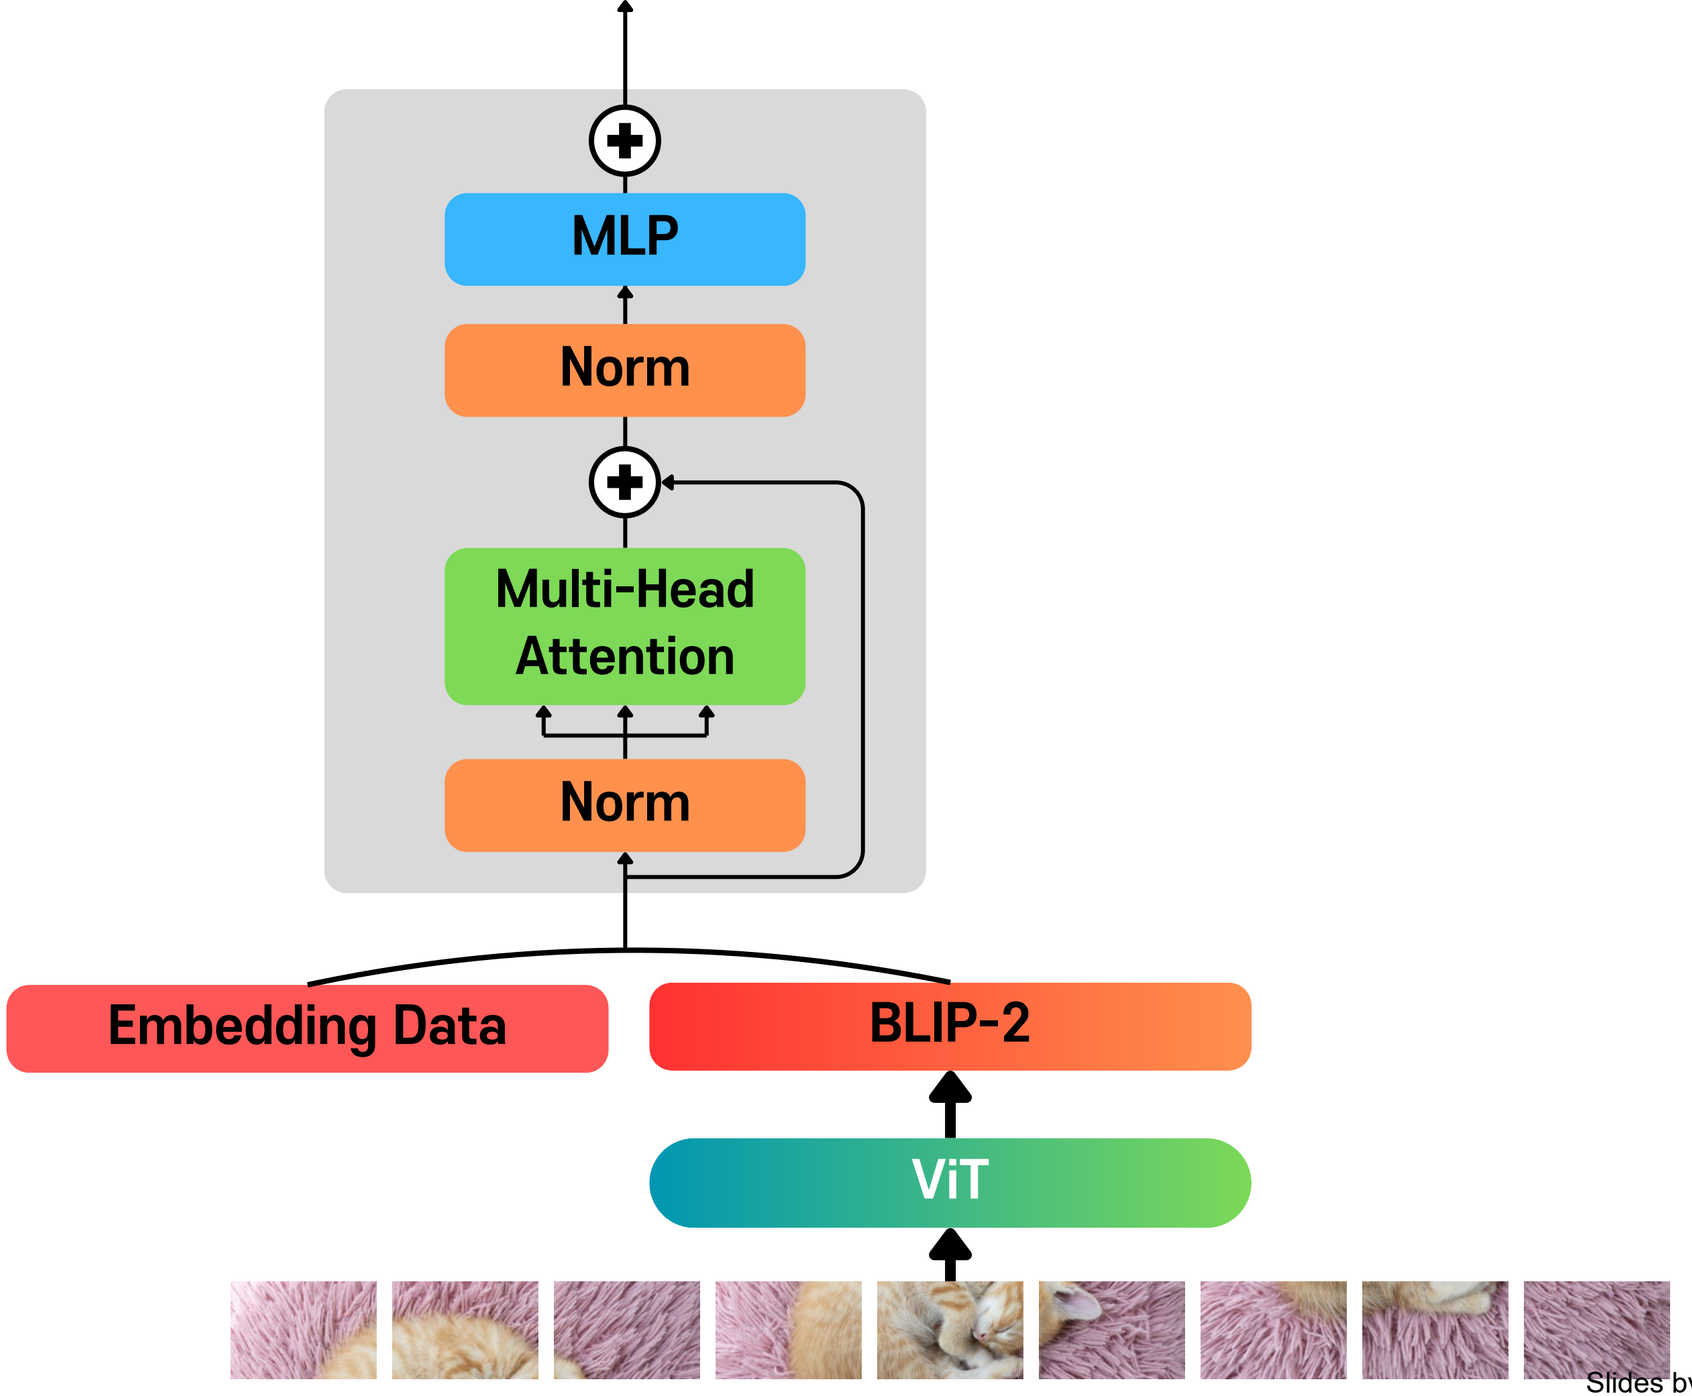
Multimodal SLM



Slides by Junseop So

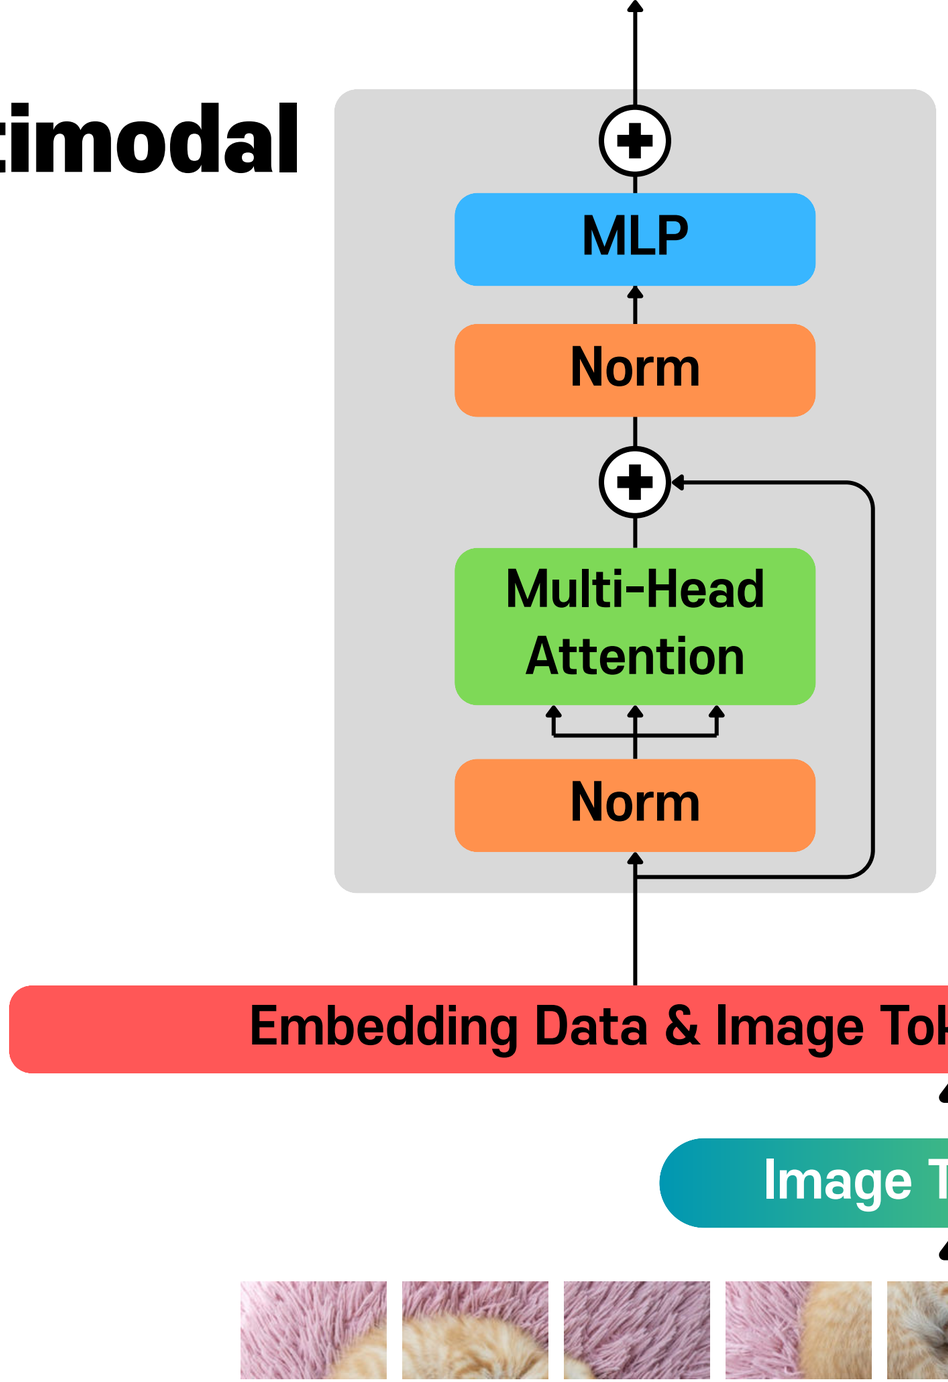
Dosovitskiy, Alexey. "An image is worth 16x16 words: Transformers for image recognition at scale. (2020)

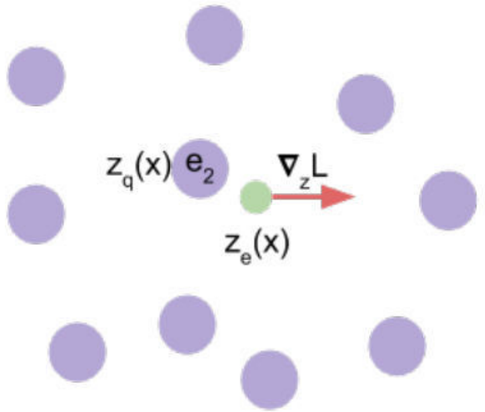
Q-Former



Slides by Junseop So

Native Multimodal





Vector Quantization 형태로
Codebook의 Token을 전달한다.



Slides by Junseop So

Vision SLMs Training





Slides by Junseop So

Connector

멀티모달 데이터 학습 방법

MLP Projector
LLaVA 1.5+

- 2-layer MLP +GeLU
- 구현 간단, 학습 속도 빠름
- 비전 토큰 수 그대로 보존
- 현재 표준

Q-Former
BLIP-2

- Cross-Attention 기반
- 비전 토큰 압축
- 학습 복잡도 높음
- 비전-언어 연관에 강점

Image Tokenizer
Native Multimodal

- VQ-VAE Codebook 방식
- 이미지 → 이산 토큰 변환
- 이미지 생성 가능
- 학습 복잡도 매우 높음

Training Data

학습 데이터의 구조

Standard Text Comletion

가장 기초적인 형태의 데이터 구조

**대한민국의 수도는 서울이다.
서울은 한강을 중심으로 강북과 강남으로 나뉘며,
다양한 문화유산과 현대적인 건축물이 공존하는 도시이다.**

Training Data

학습 데이터의 구조

Instruction Tuning

지시, 입력, 출력을 명확히 구분한 JSON 형태로
모델이 사용자의 명령을 따르도록 학습할 때, 사용합니다.

{“instruction”: “다음 문장을 영어로 번역하시오.”,
“input”: “오늘 날씨가 정말 좋네요.”
“output”:“The weather is really nice today.”}

Training Data

학습 데이터의 구조

Instruction Tuning

지시, 입력, 출력을 명확히 구분한 JSON 형태로
모델이 사용자의 명령을 따르도록 학습할 때, 사용합니다.

{“instruction”: “다음 문장을 영어로 번역하시오.”,
“input”: “오늘 날씨가 정말 좋네요.”
“output”:“The weather is really nice today.”}

Data

학습 데이터의 구조

```
# 테스트 메시지
messages = [
    {"role": "user", "content": [
        {"type": "image", "image": "dummy_image_obj"},
        {"type": "text", "text": "What is this?"}
    ]},
    {"role": "assistant", "content": "It is a cat."}
]
```

Data

학습 데이터의 구조

```
=== 모델이 실제로 보게 될 문자열 ===
<bos><start_of_turn>user
<start_of_image>What is this?<end_of_turn>
<start_of_turn>model
It is a cat.<end_of_turn>
```

Data

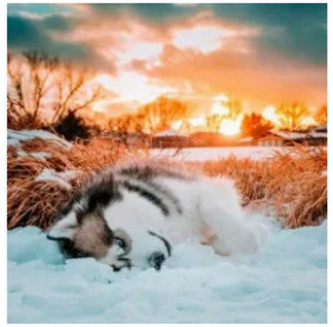
학습 데이터 (LAION-5B)

Q: An armchair that looks like an apple



C: Green Apple Chair

Q: A dog rolling in the snow at sunset



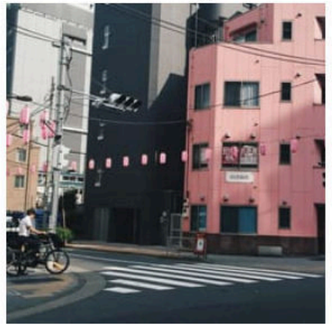
C: sun snow dog

Q: A graphic design color palette



C: Color Palettes

Q: pink photo of Tokyo



C: pink, japan, aesthetic image

Figure 3: **LAION-5B examples.** Sample images from a nearest neighbor search in LAION-5B using CLIP embeddings. The image and caption (C) are the first results for the query (Q).

Data



#24

uid
78c9e871806a073ead1036e22f72ebb5

url

https://static.wixstatic…96b4014efc78.jpg ↗

text
Barclay Hotel

original_width
250

original_height
333

clip_b32_similarity_score
0.312744

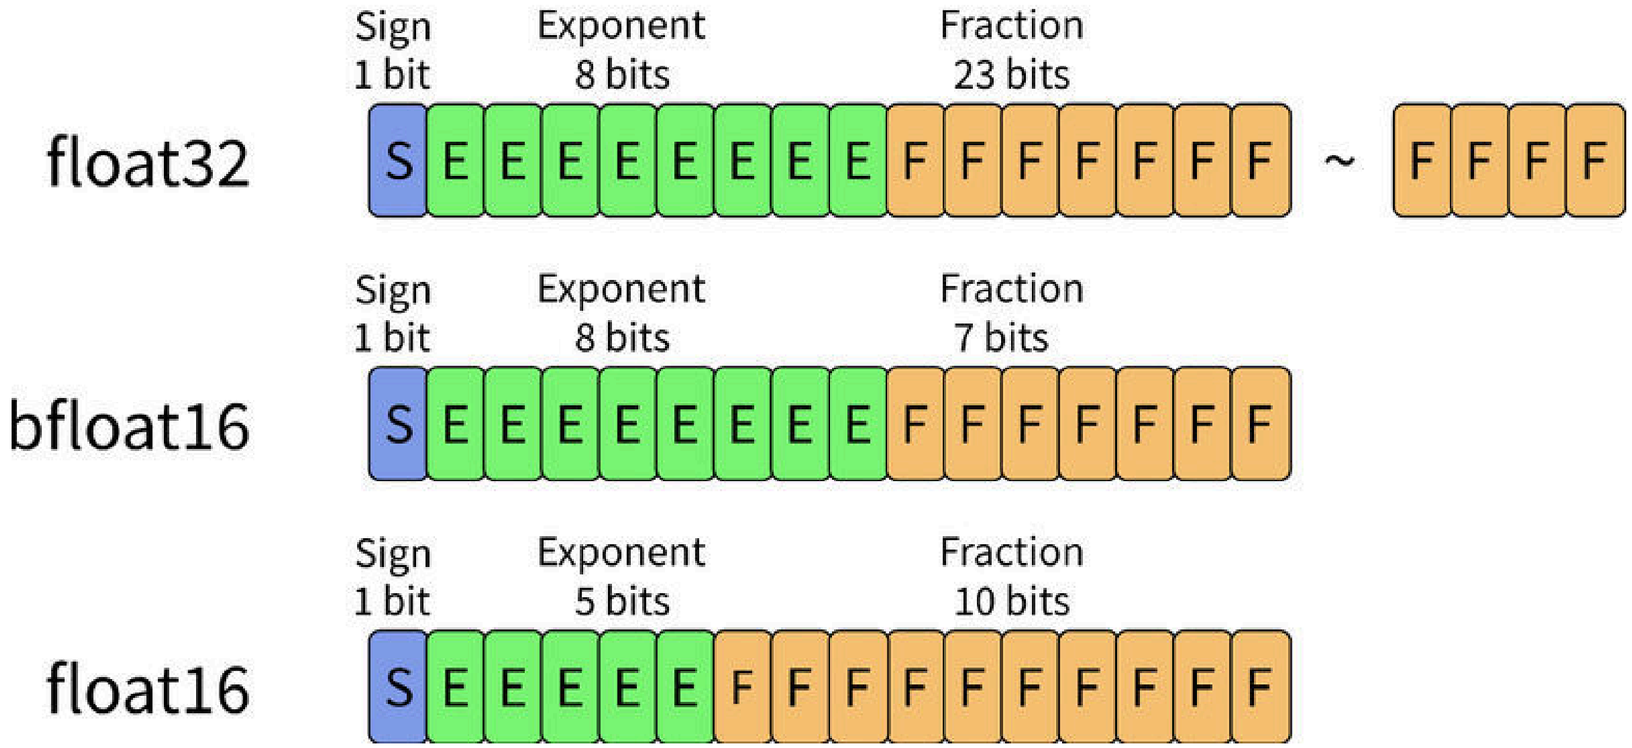
clip_l14_similarity_score
0.294678

face_bboxes
[]

sha256
5bfe4c35518be76e26468bf9d7ac9e92c0082b6b0f6cf7a4d3c5fdd91ecf1f60

Quantization

SLM



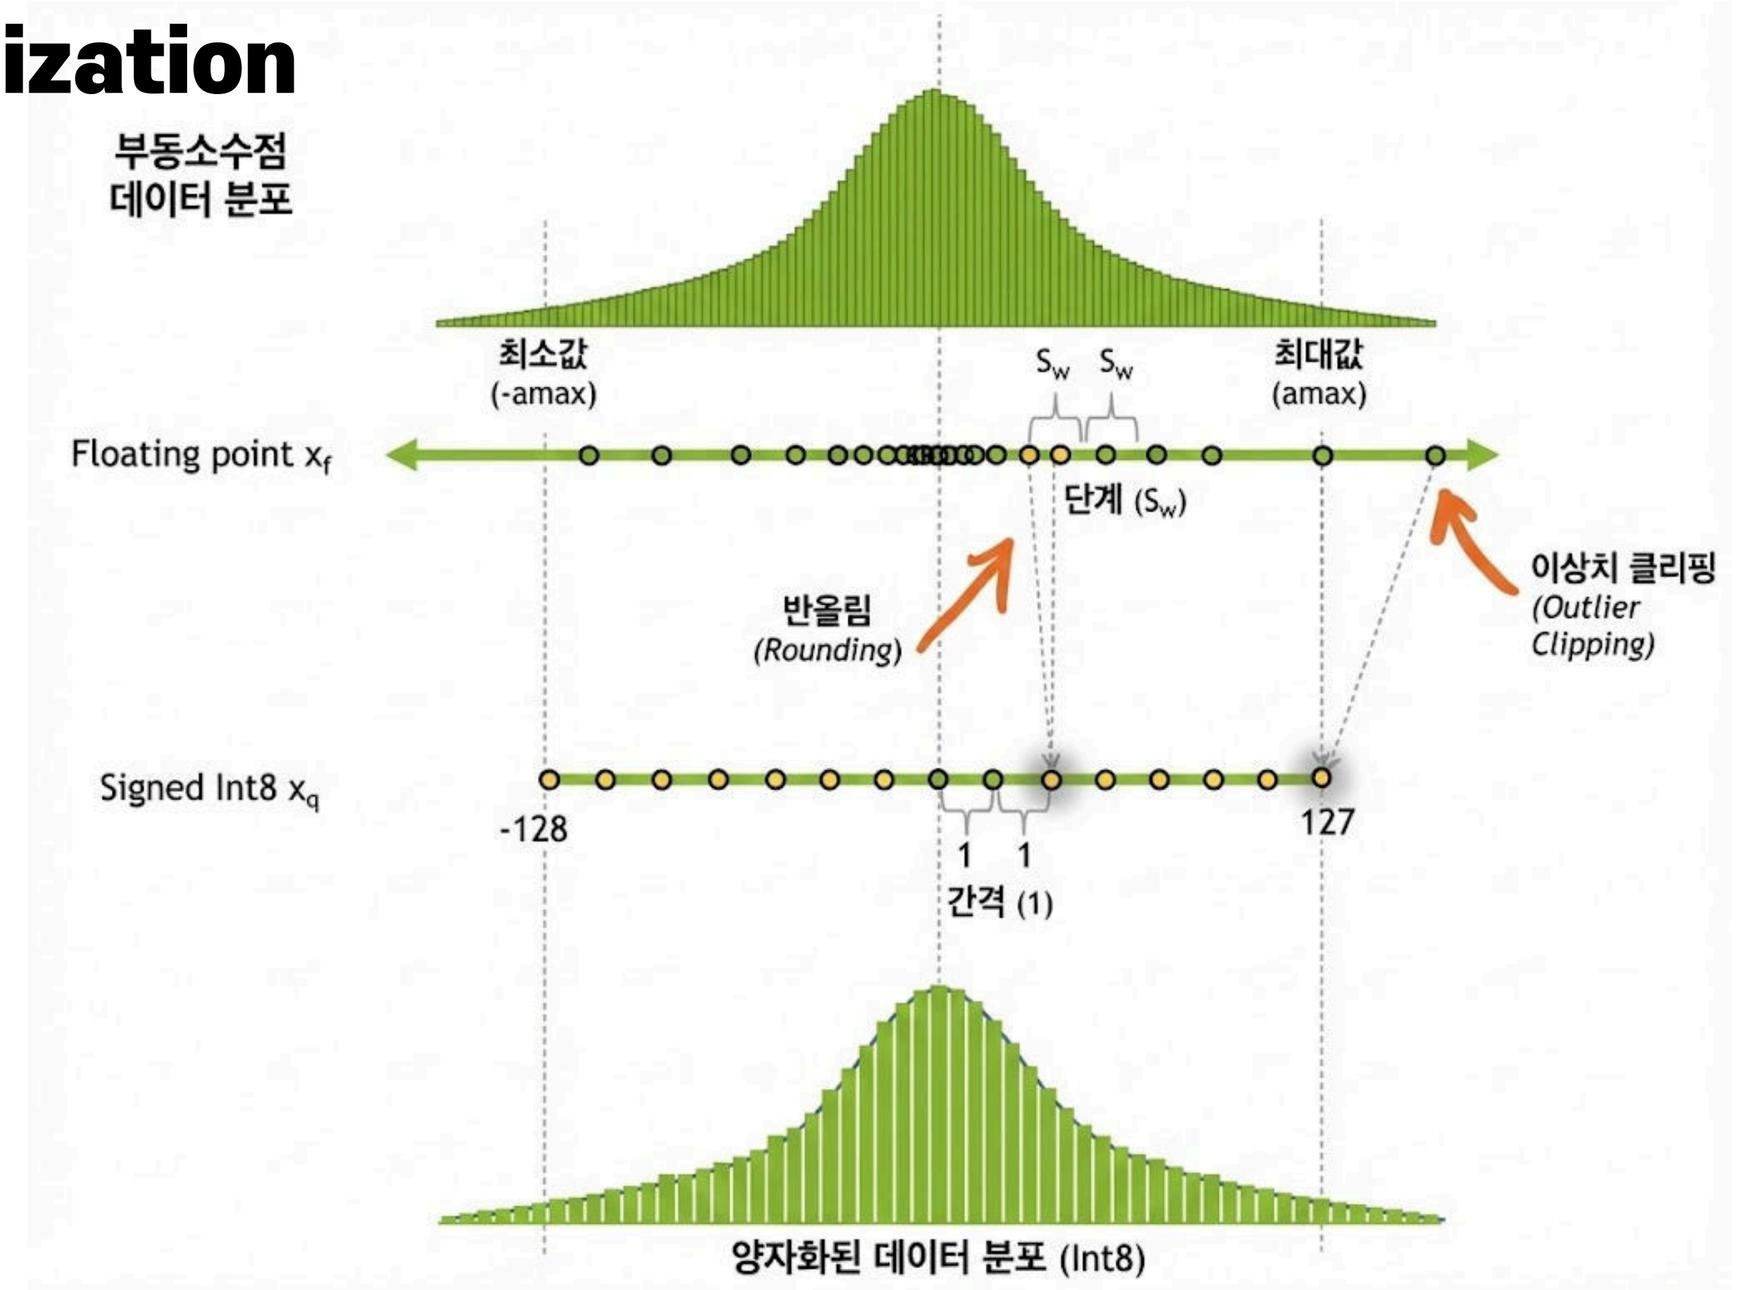
Quantization

지수부 가수부

$$1.23 \times 10^{-5}$$

자료형	총 크기	지수부 (범위)	가수부 (정밀도)	주요 용도
float32	32비트 (무거움)	8비트 (넓음)	23비트 (정밀함)	정밀 학습, 마스터 가중치 보존
bfloat16 (Google)	16비트 (가벼움)	8비트 (넓음, float32와 동일)	7비트 (다소 부정확)	LLM/SLM 학습 및 추론, QLoRA 연산
float16 (구형)	16비트 (가벼움)	5비트 (좁음, 에러 발생 쉬움)	10비트 (보통)	구형 GPU 추론

Quantization



QLoRA (Quantized Low-Rank Adaptation)



Quantization

모델 가중치 포멧

구분	safetensors	GGUF	GPTQ	AWQ
특징	Huggingface 배포 표준	llama.cpp 기반	가중치 오차 분배	중요 가중치 보호
장점	악성코드 차단 로딩속도 빠름	CPU, RAM 활용 가능 offloading	손실이 적고 추론 속도 빠름	양자화 속도 빠름 오버피팅 감소
단점	양자화 X	속도 느림	GPU만 사용가능	GPU만 사용가능

Vision SLM Pipeline

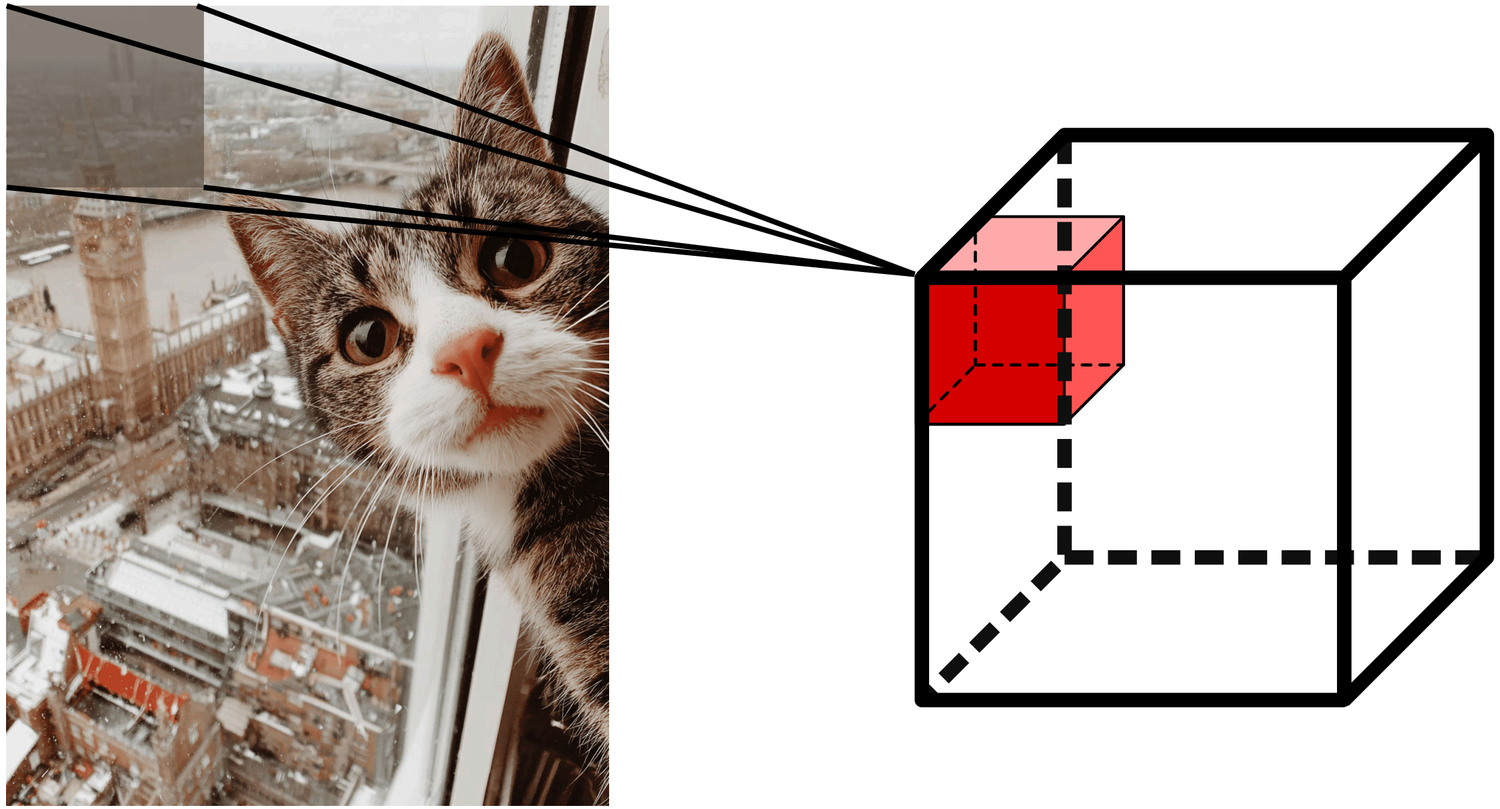
모델 가중치 포멧

모델 선택	데이터 준비	Fine-tuning	양자화	평가	배포
Qwen2.5-VL Gemma3 ...	이미지+텍스트 VQA 포맷 대화형 구조	Stage1: 정렬 Stage2: 튜닝 LoRA / QLoRA	AWQ / GPTQ GGUF 변환 ViT Freeze	DocVQA 등 밴치마크 평가 양자화 전후 비교	서버 및 엣지 디바이스 환경 배포

Vision Understanding & Generation

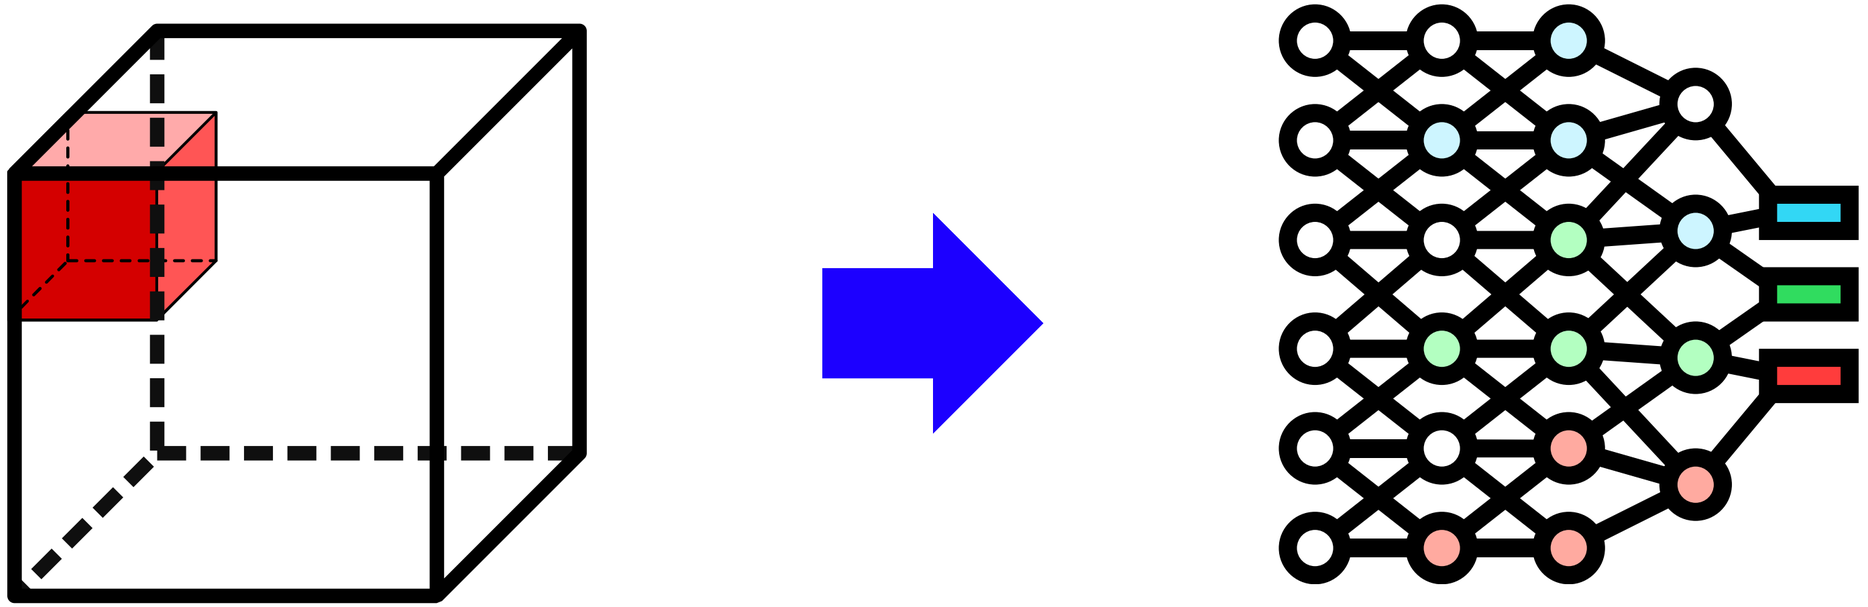
Vision Models

CNN의 특징 추출



Vision Models

CNN



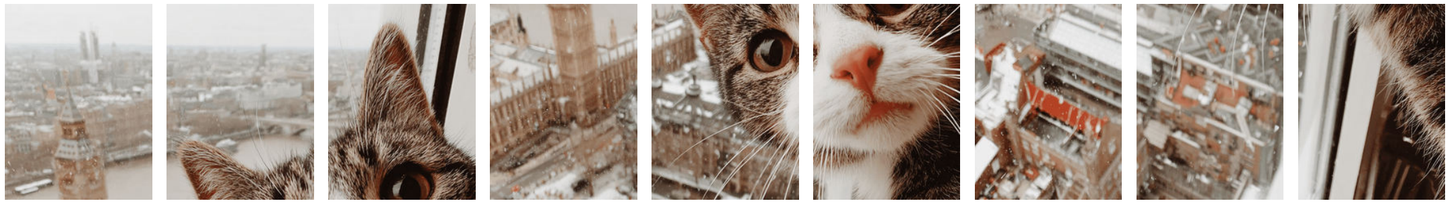
Vision Models

ViT



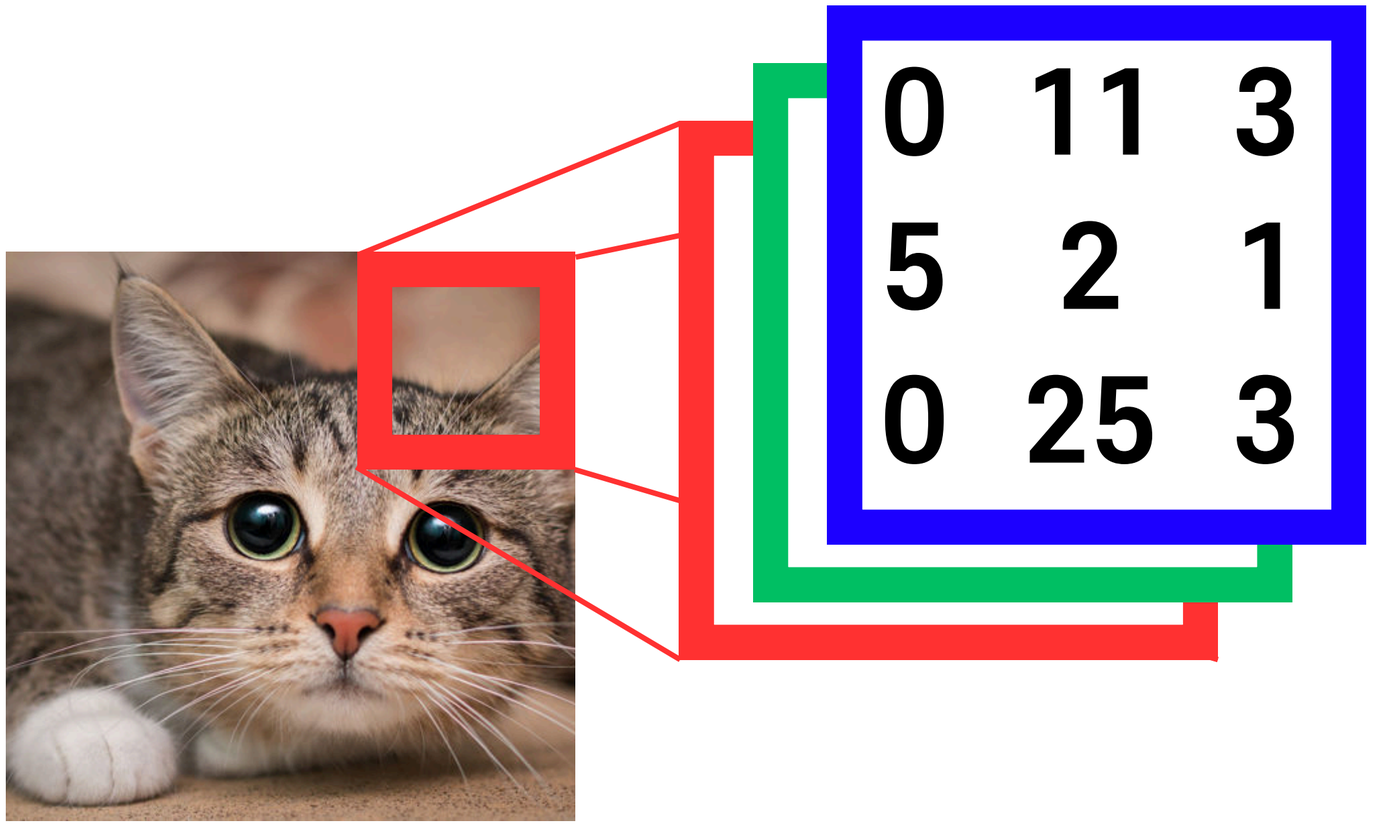
Vector Embedding

Vision Transformer



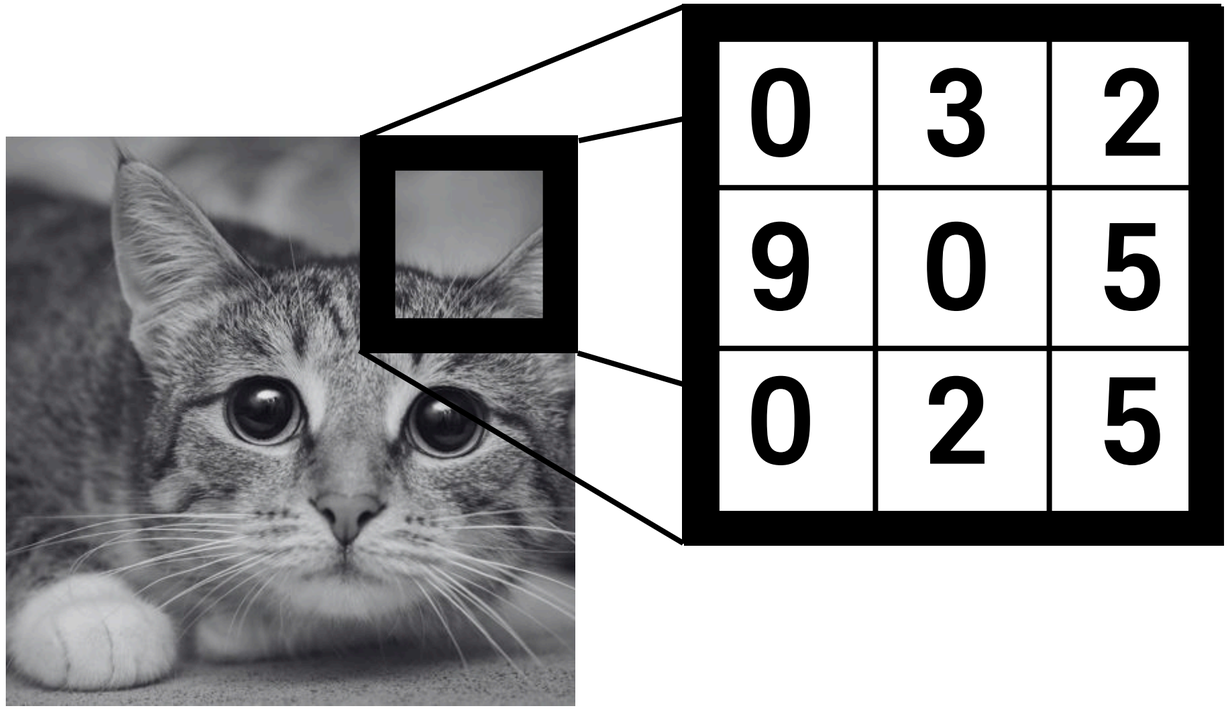
Deep Learning & Vector

Color image는 R, G, B 3개 채널을 가지고 있다.



Deep Learning & Vector

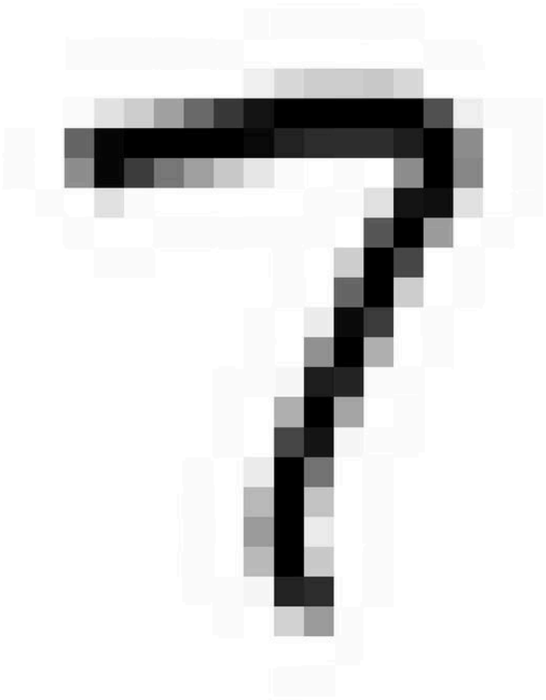
Black & White image는 1개 채널을 가지고 있다.



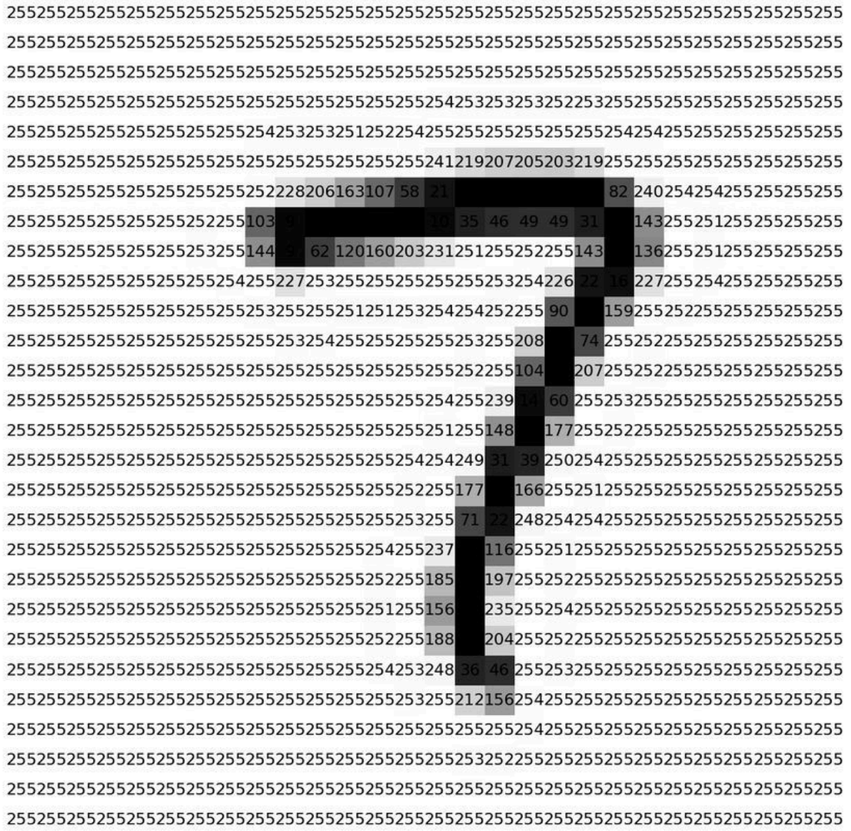
Deep Learning & Vector

더 간단한 이미지로 확인해봅시다

Resized Image



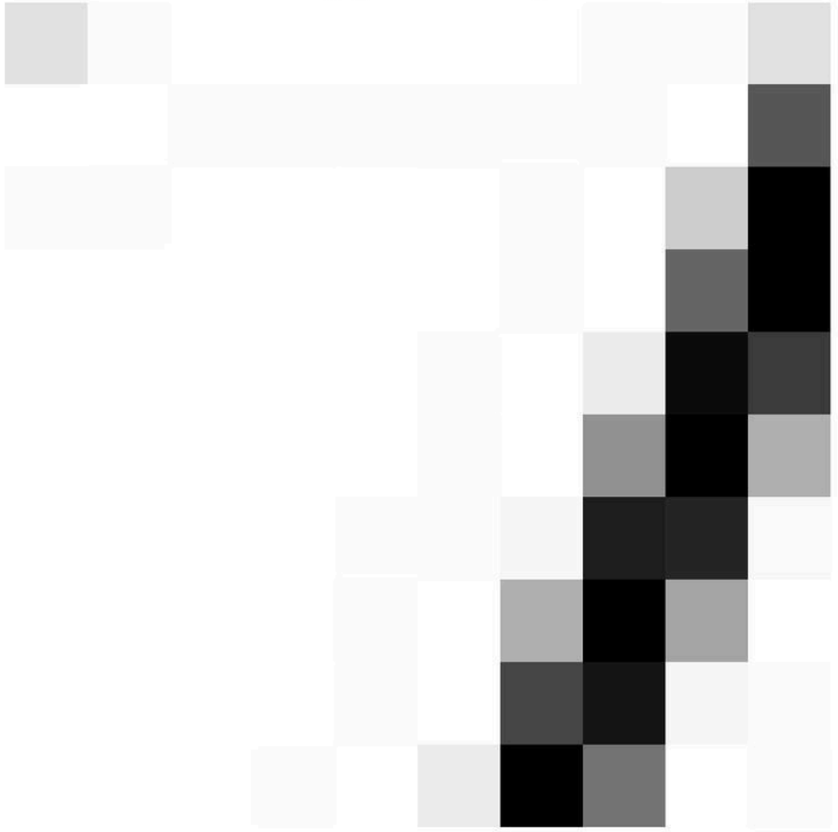
Pixel Data Matrix



Deep Learning & Vector

더 간단한 이미지로 확인해봅시다

Cropped Image

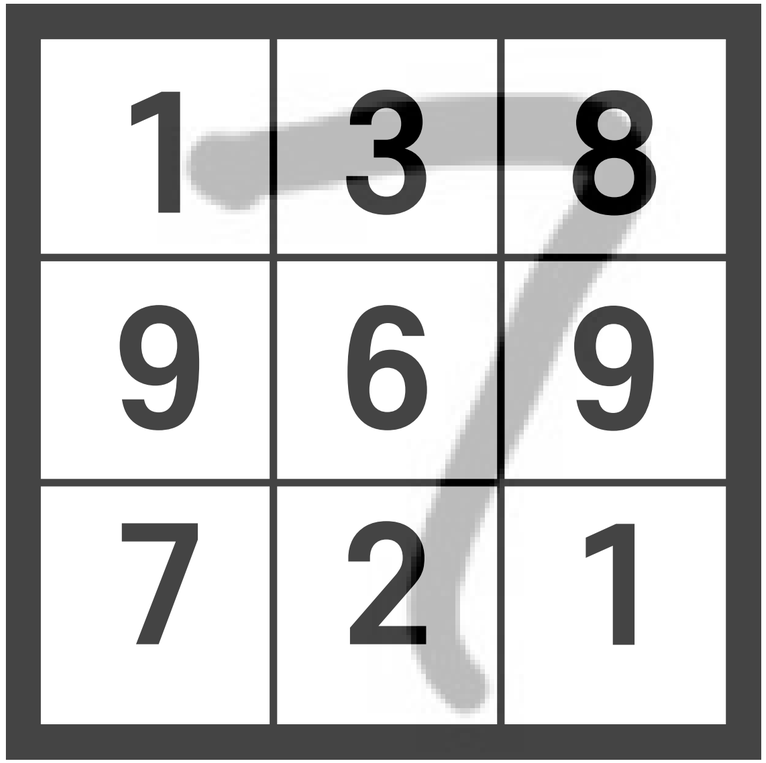


Cropped Pixel Data Matrix

227	253	255	255	255	255	255	253	254	226
255	255	251	251	253	254	254	252	255	90
253	254	255	255	255	255	253	255	208	
255	255	255	255	255	255	252	255	104	
255	255	255	255	255	254	255	239	14	60
255	255	255	255	255	251	255	148		177
255	255	255	255	254	254	249	31	39	250
255	255	255	255	252	255	177		166	255
255	255	255	255	253	255	71	22	248	254
255	255	255	254	255	237		116	255	251

Deep Learning & Vector

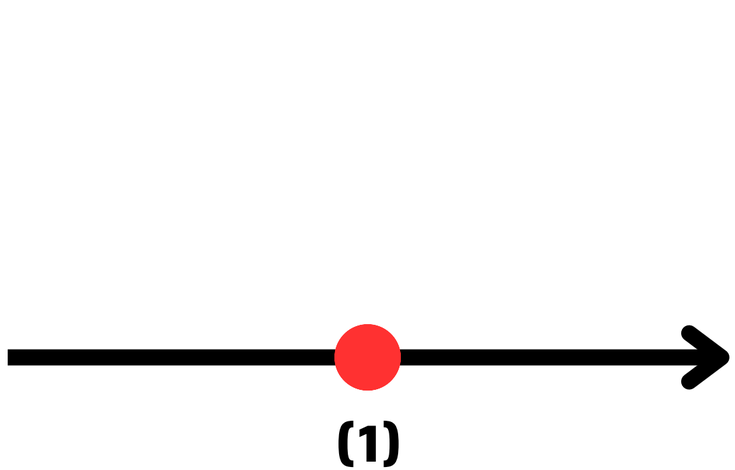
간단한 버전으로 생각해보자

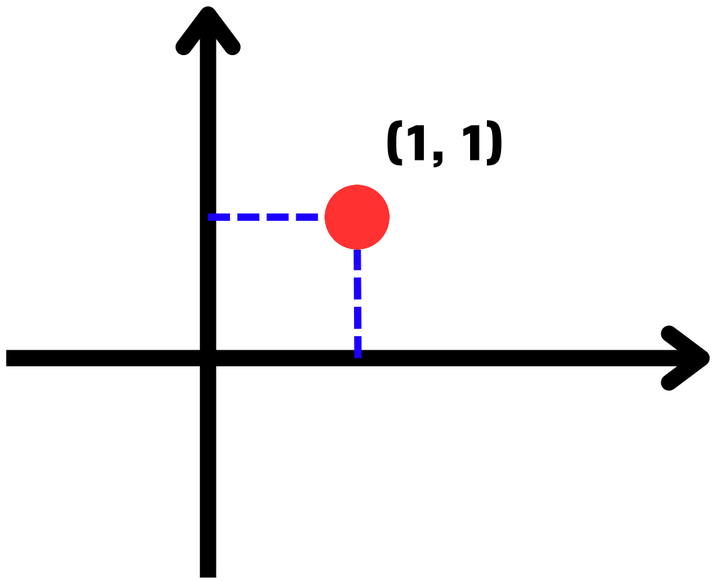


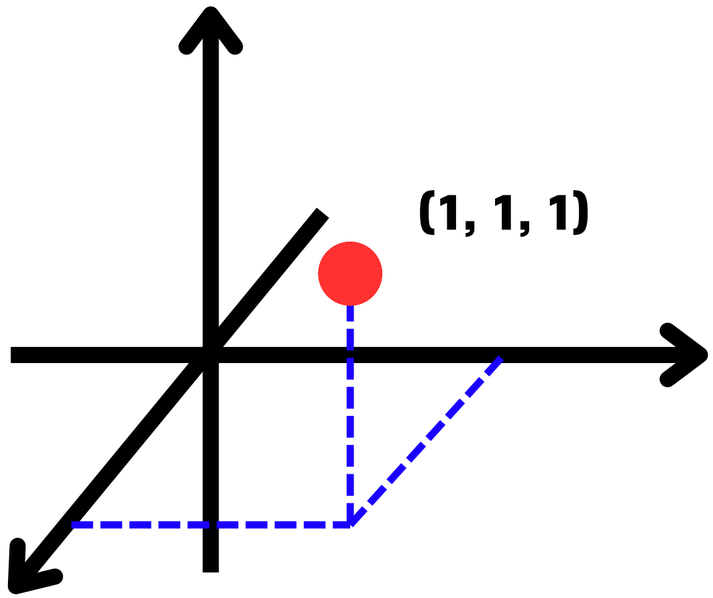
[1, 3, 8, 9, 6, 9, 7, 2, 1]

Deep Learning & Vector

하나의 점과 데이터

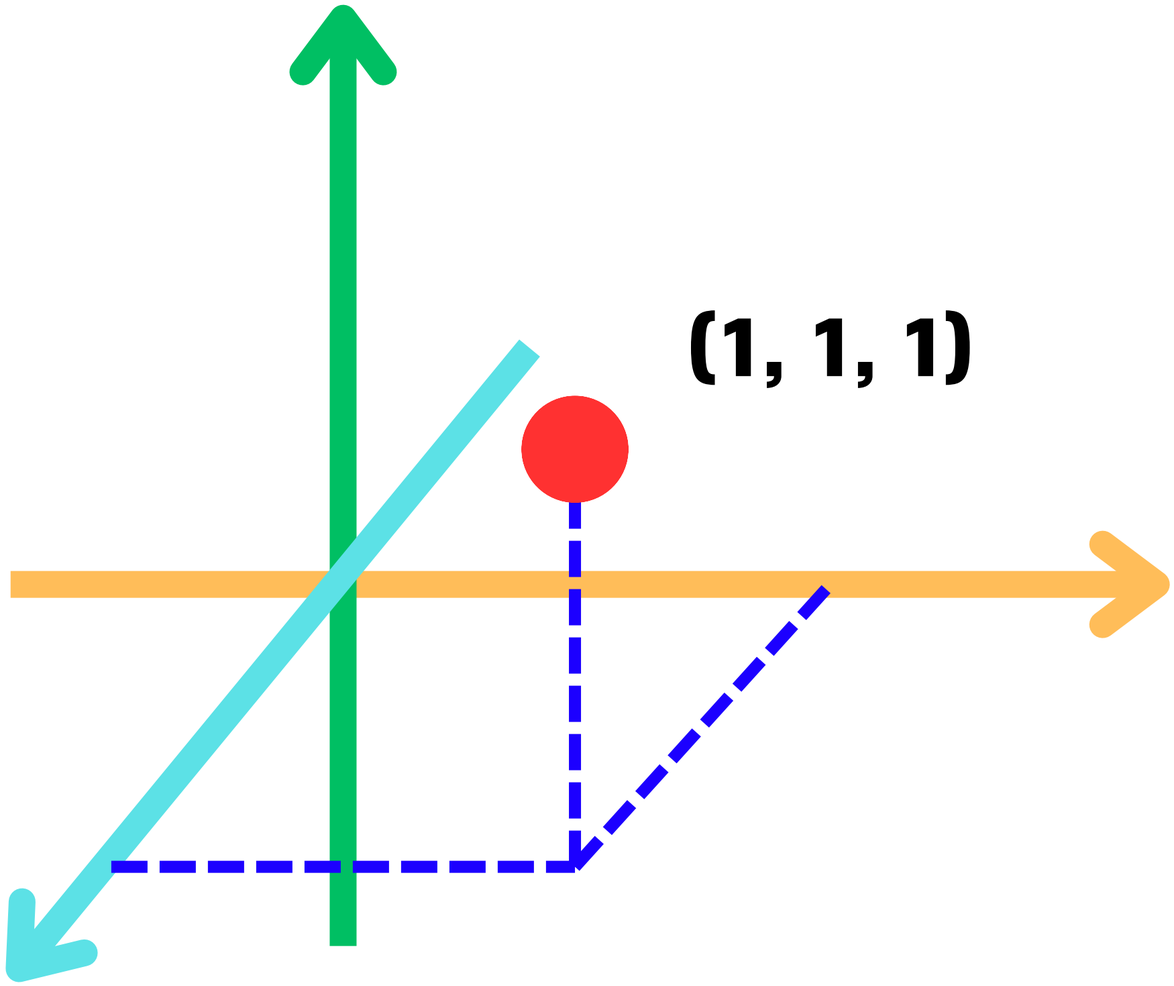






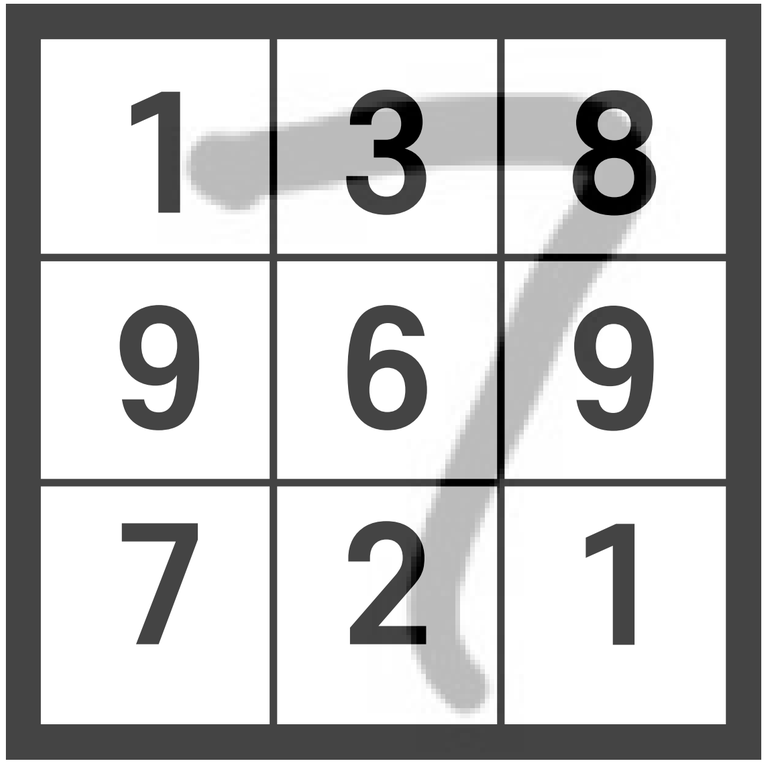
Deep Learning & Vector

축은 특징을 나타낸다

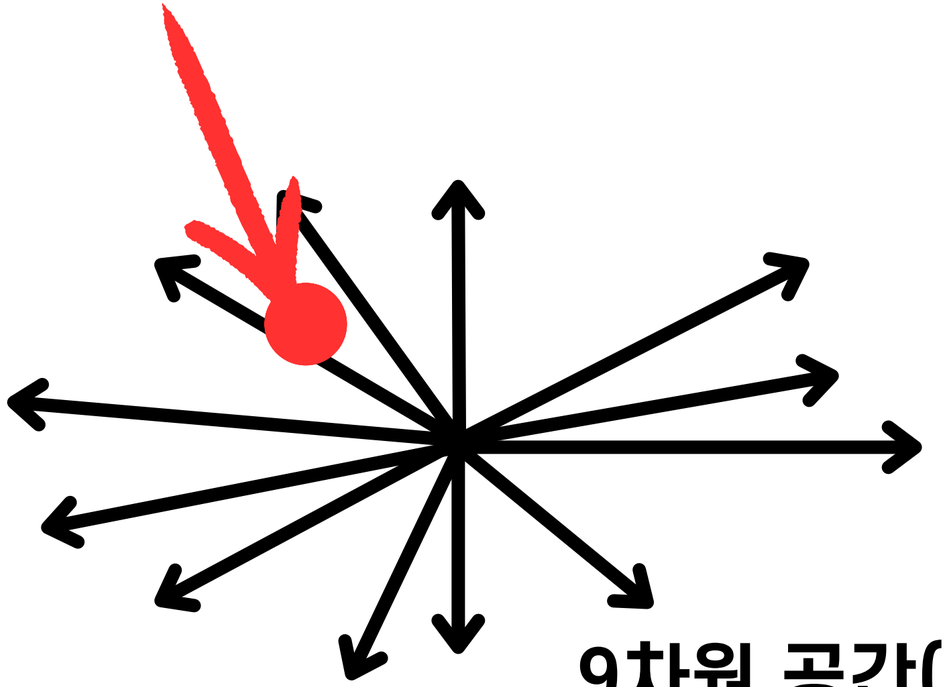


Deep Learning & Vector

간단한 버전으로 생각해보자



[1, 3, 8, 9, 6, 9, 7, 2, 1]



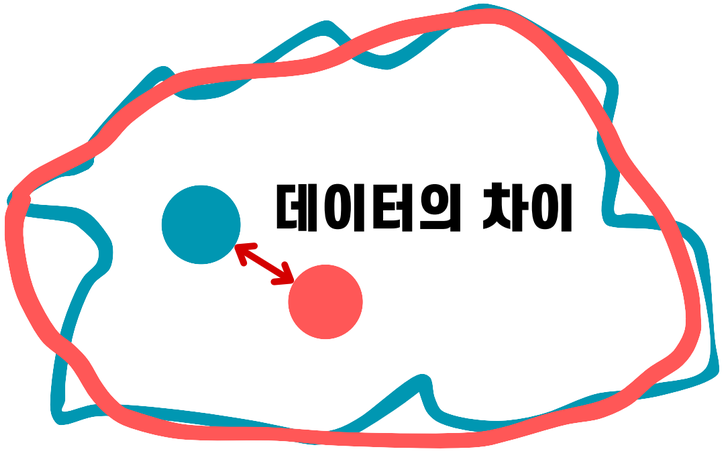
9차원 공간(추정)

Generation Models

확률의 렌즈



Real Data



True Data Distribution

Model Distribution



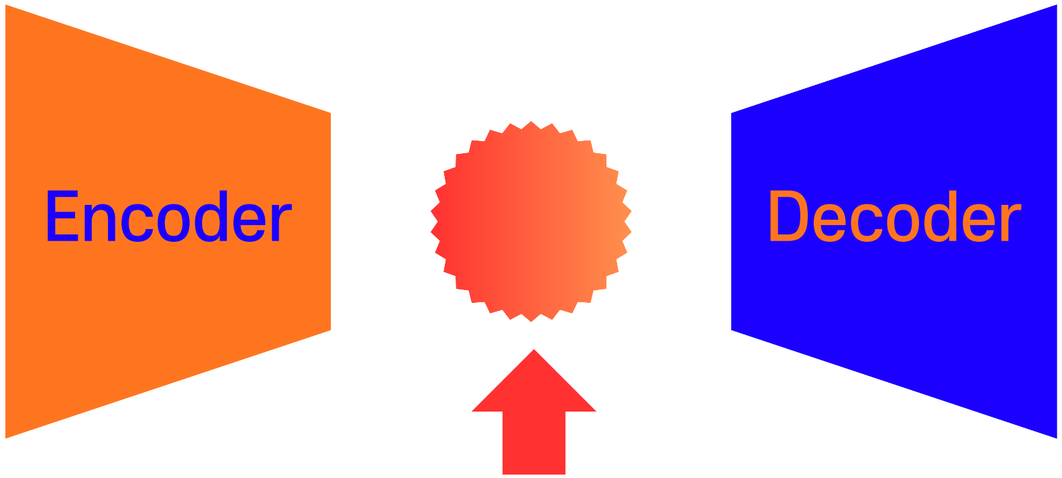
Generated Data

Slides by Junseop So

Generation Models

VAE







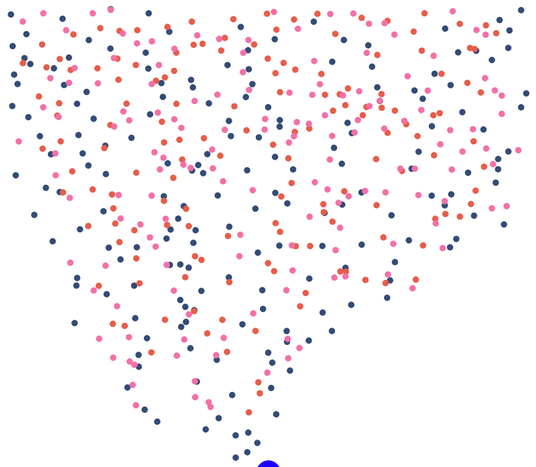
Latent space

Slides by Junseop So

Generation Models

Flow-based-Models

Complex Data **x**



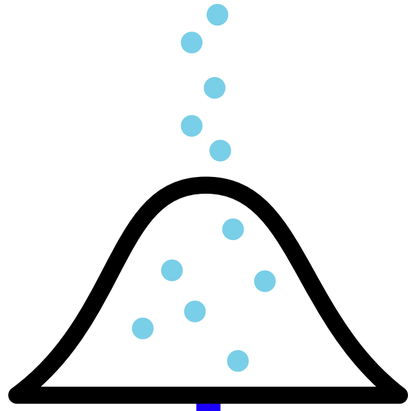
F(x) invertible tranform

F(x) invertible tranform

...

F(x) invertible tranform

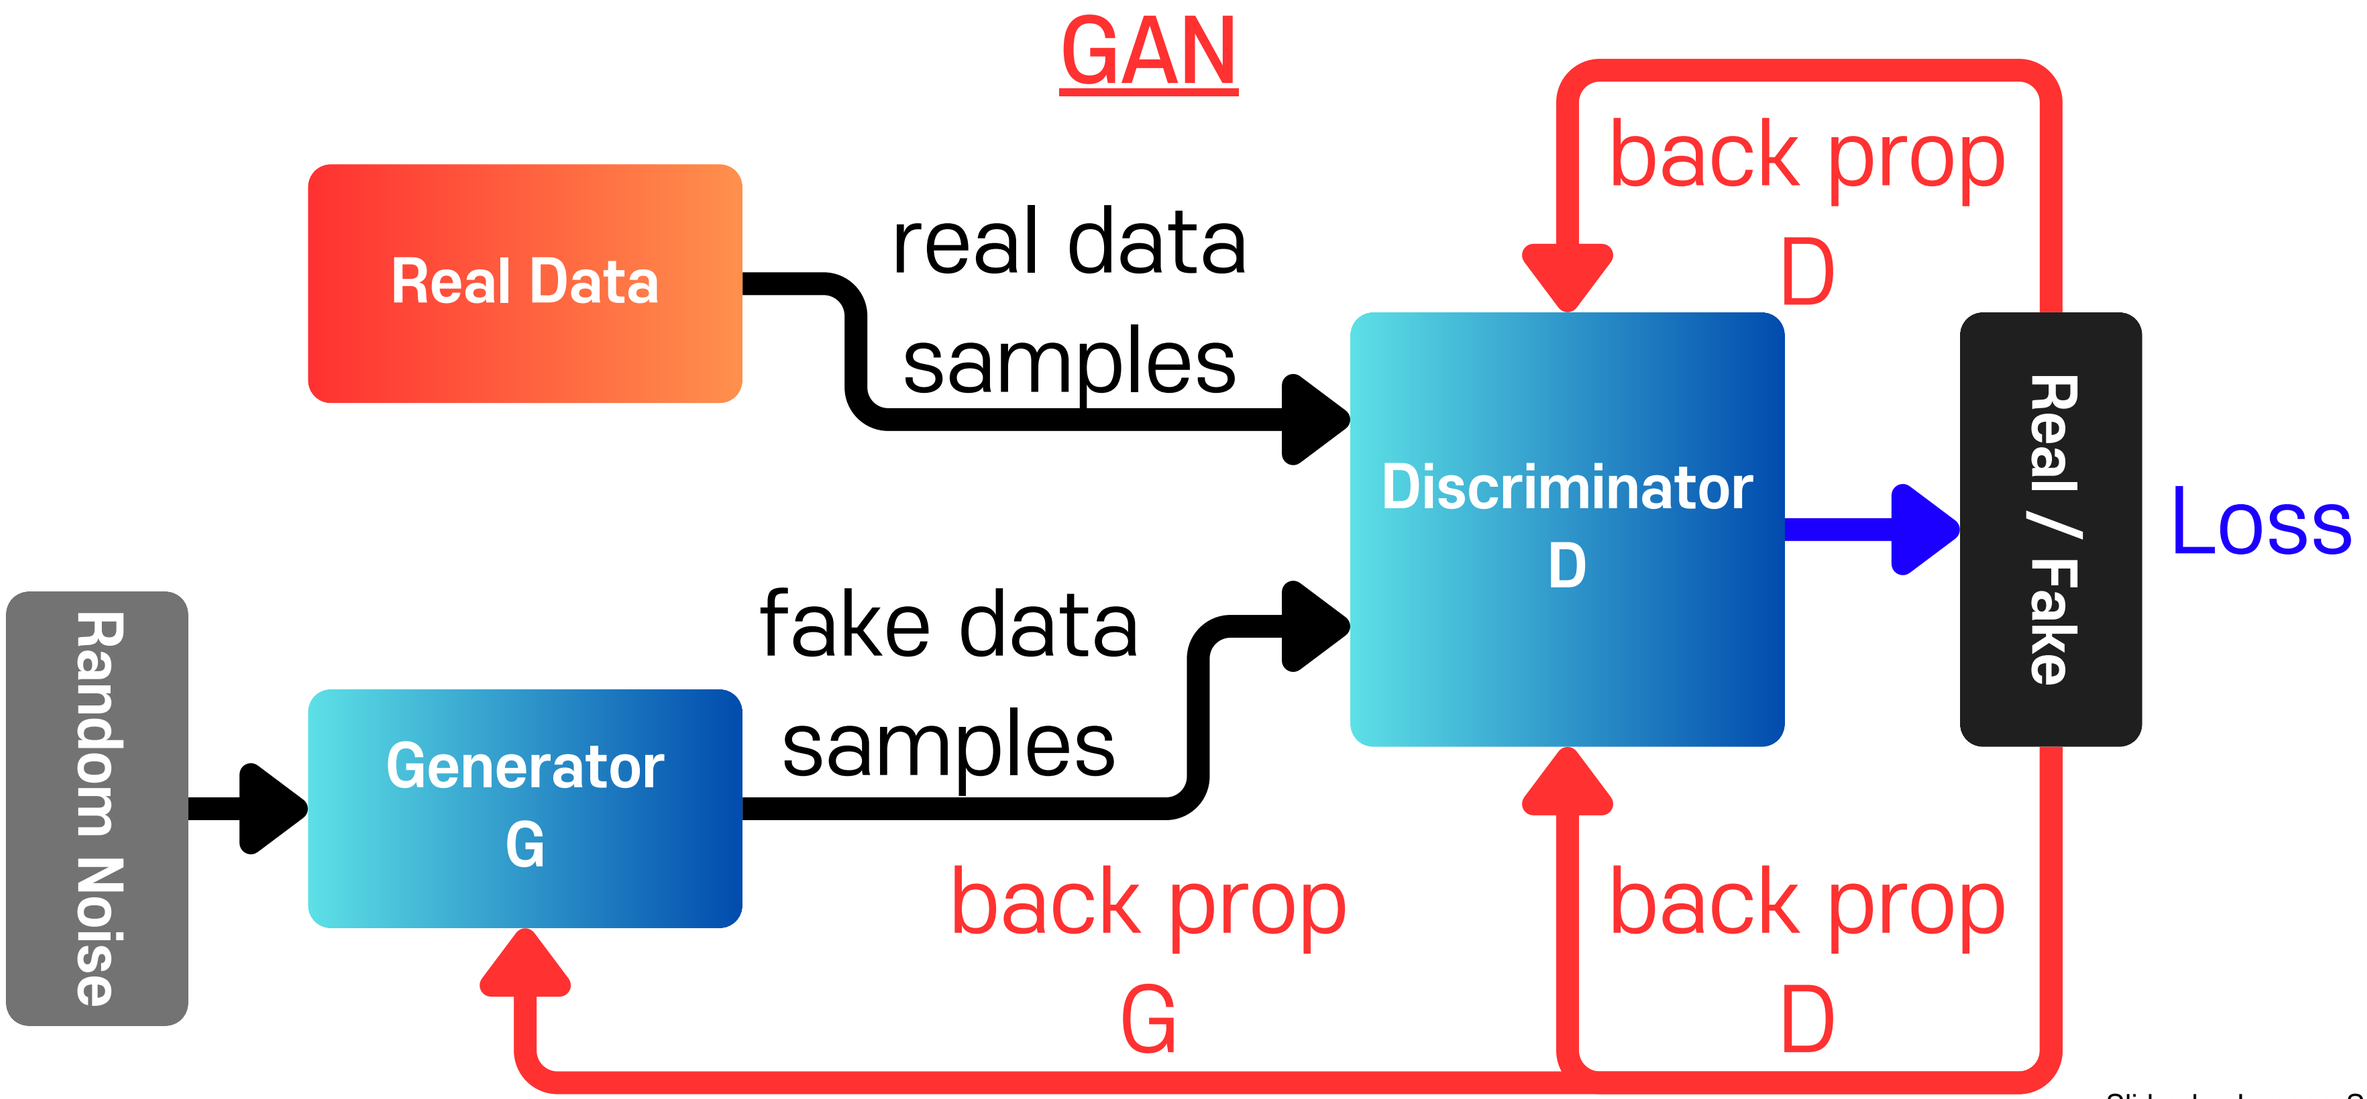
Normalized Simple Noise **z** Gaussian



$f^{-1}(z)$ **Generation**

Slides by Junseop So

Generation Models

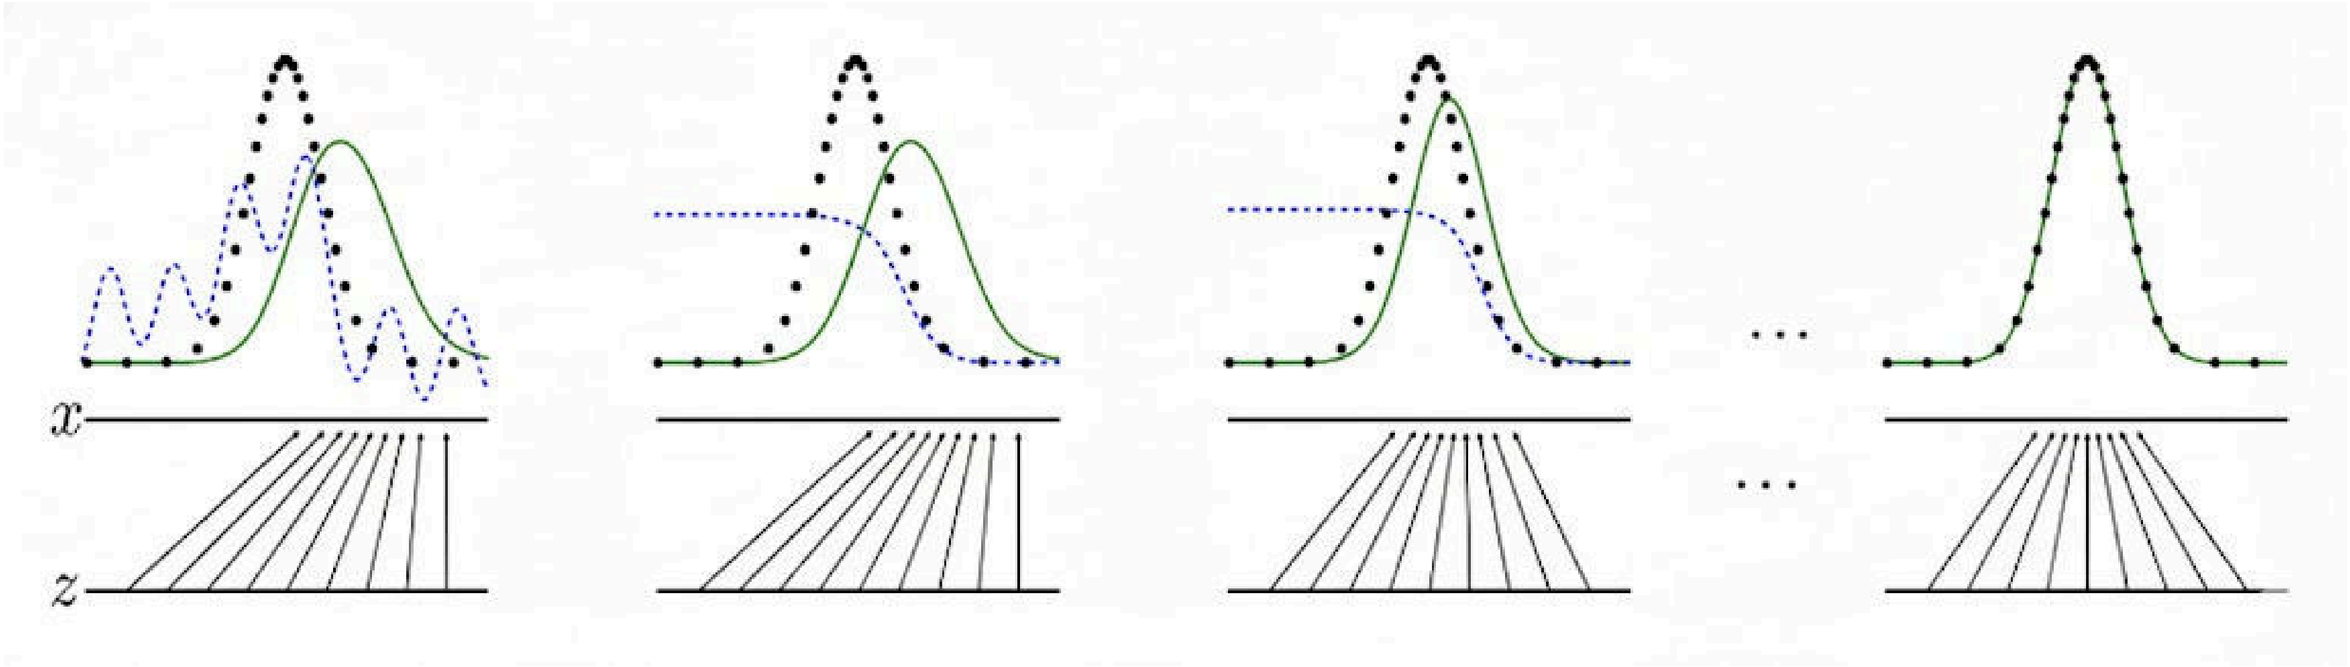


Slides by Junseop So

goodfellow, 2014, generativea dversarial networks

Generation Models

GAN

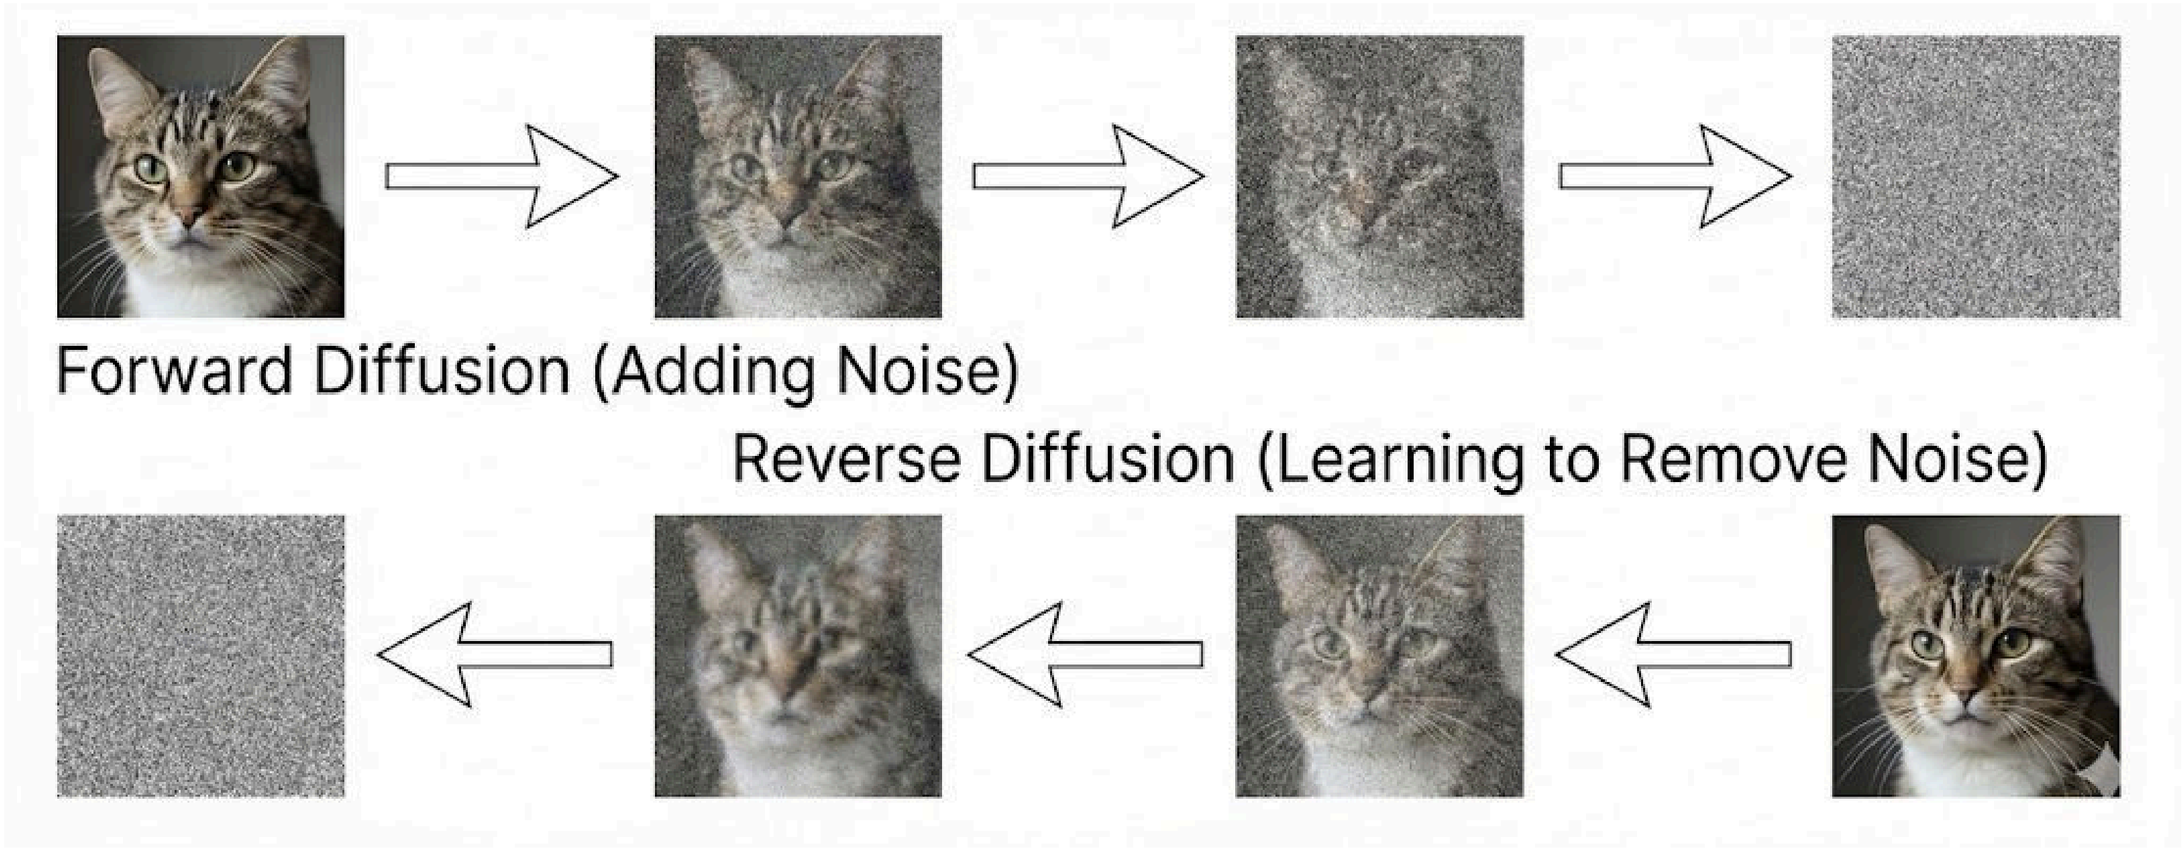


Slides by Junseop So

goodfellow, 2014, generativea dversarial networks

Generation Models

Diffusion Models (Training)

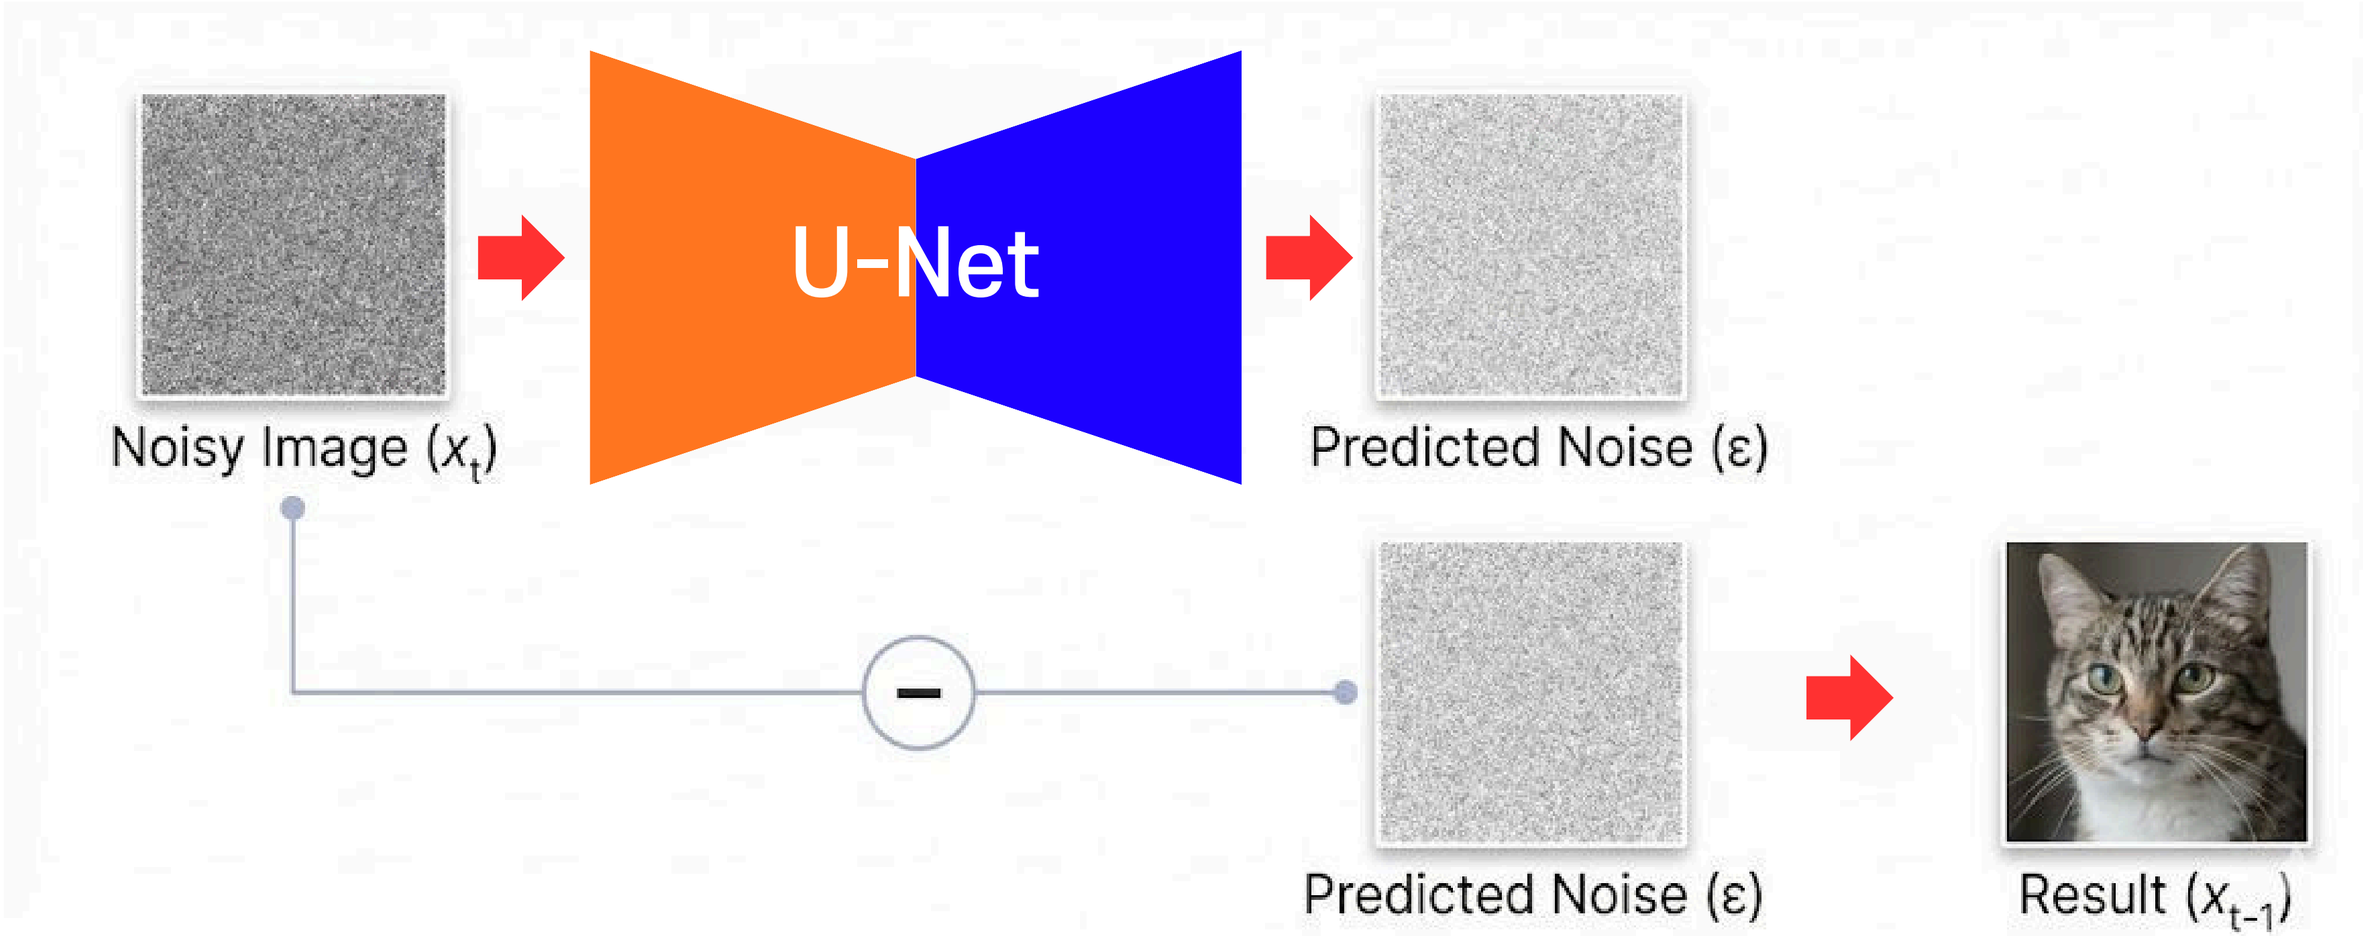


Slides by Junseop So

ho, 2020, Denoising diffusion probabilistic models

Generation Models

Diffusion Models (Inference)



Slides by Junseop So

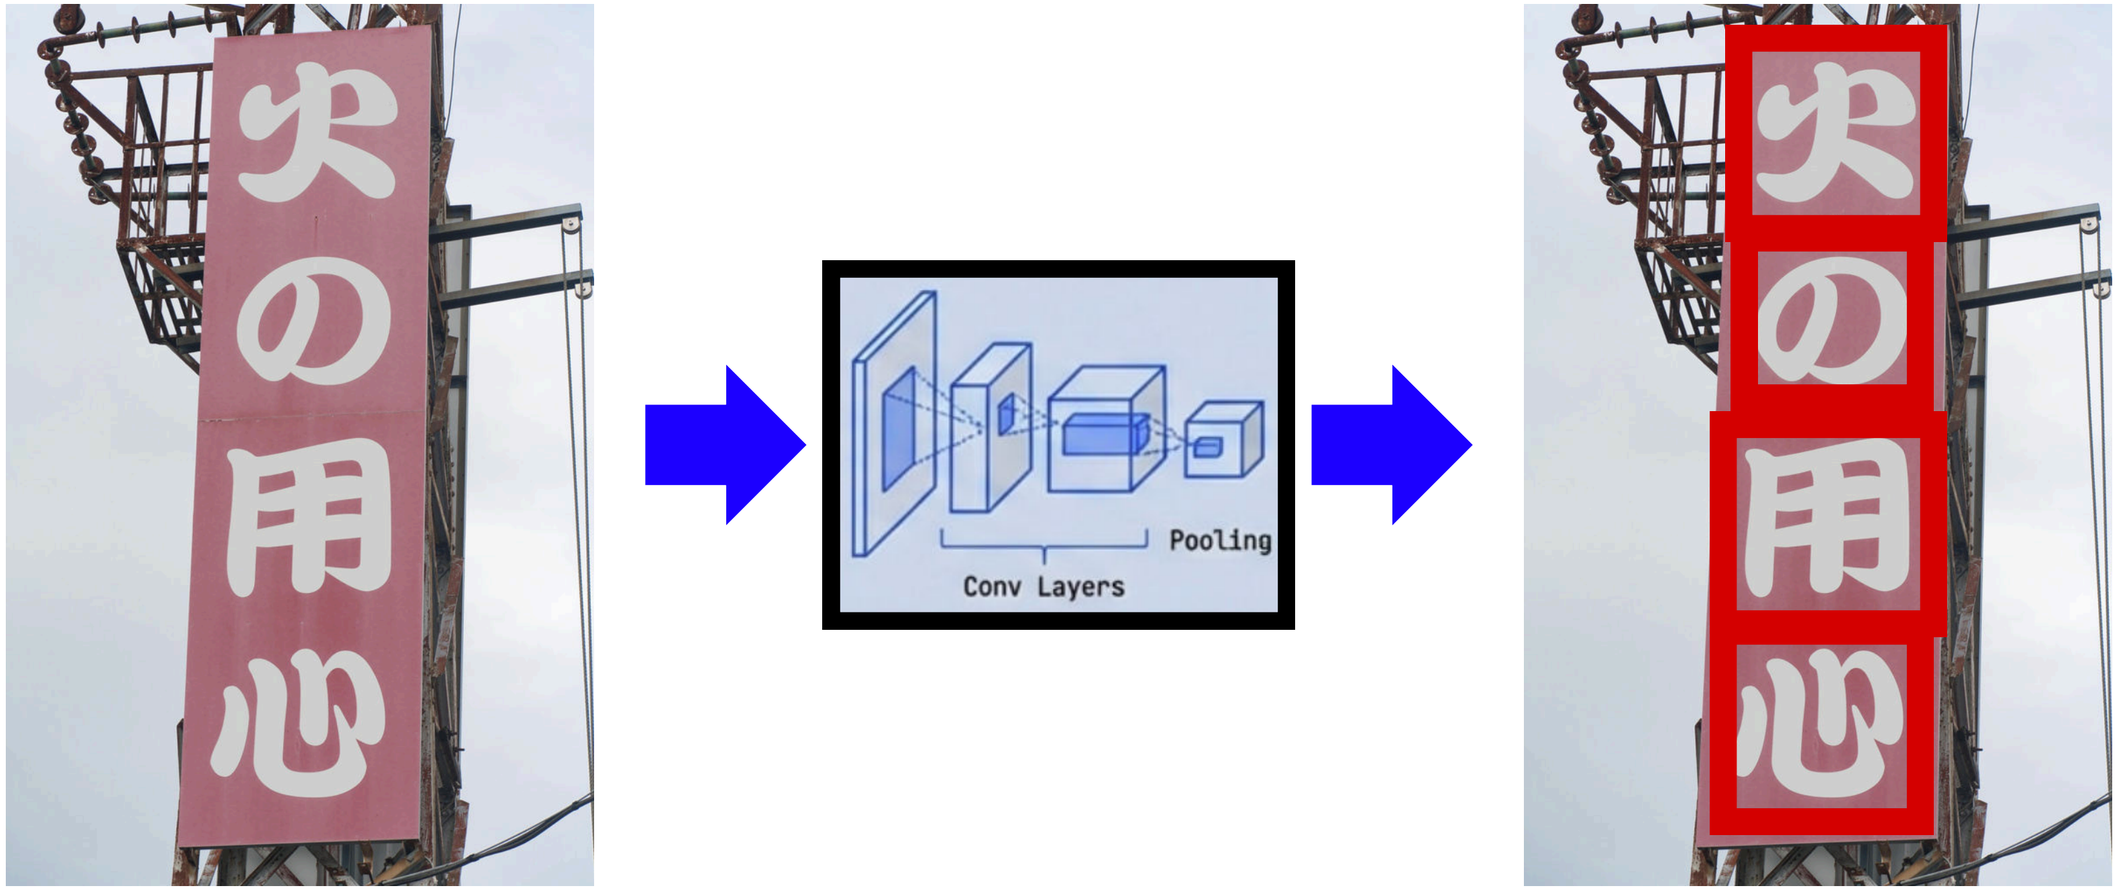
Optical Character Recognition (OCR)

Text Detection: Locating regions



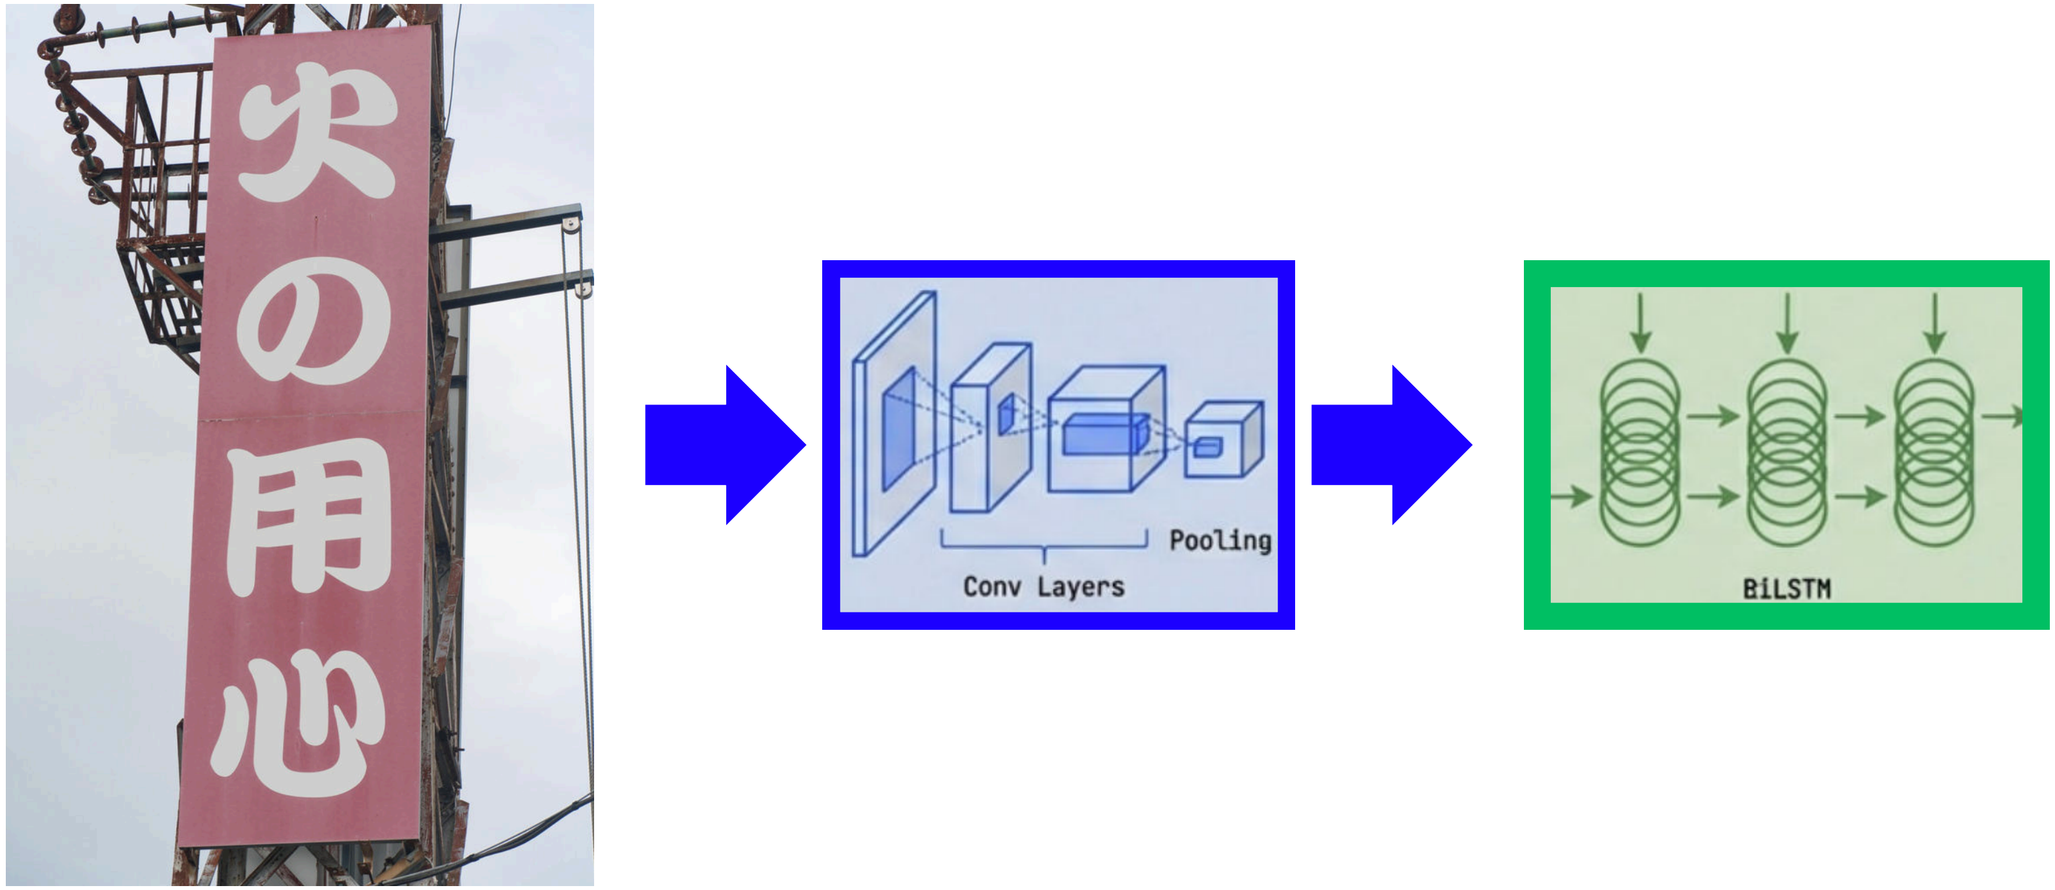
Optical Character Recognition (OCR)

Object Detection



Optical Character Recognition (OCR)

Object Detection



Optical Character Recognition (OCR)

Text Recognition: Image to String



➡ 火の用心

Optical Character Recognition (OCR)

Object Detection



Vision Encoder (ViT)

Text Decoder (GPT-style)

火
の
用
心

Optical Character Recognition (OCR)

Text Spotting: End-to-End



火の用心
(히노요진, ひのようじん)

Optical Character Recognition (OCR)

Document Understanding



火の用心
(히노요진, ひのようじん)

사진에서 글자가 적힌 시설물은
화재 감시탑(불망루)으로 보입니다.

Optical Character Recognition (OCR)

Document Understanding

Layout Analysis

Job Application Form

header

1. Personal Information

- **Full Name:** John Connor (존 코너)
- **Email Address:** john@gmail.com
- **Phone Number:** 010-1234-4567

Info

- **Current Address:** _____
- **LinkedIn Profile / Portfolio (Optional):** _____

Job Application

Name: John Connor
Email: John@gmail.com
Phone: 010-1234-5678

OCR & Info Extraction

RAG Document parser

Linearization: Markdown-Key-Value

ID	제품명	카테고리	가격	재고
101	맥북 프로	전자제품	3,500,000	5
102	데스크 의자	가구	250,000	12

Row 1: ID: 101, 제품명: 맥북 프로, 카테고리: 전자제품, 가격: 3,500,000, 재고: 5
Row 2: ID: 102, 제품명: 데스크 의자, 카테고리: 가구, 가격: 250,000, 재고: 12

RAG Document parser

Linearization: Markdown Table

ID	제품명	카테고리	가격	재고
101	맥북 프로	전자제품	3,500,000	5
102	데스크 의자	가구	250,000	12

```
| ID | 제품명 | 카테고리 | 가격 | 재고 |
|---|---|---|---|---|
| 101 | 맥북 프로 | 전자제품 | 3,500,000 | 5 |
| 102 | 데스크 의자 | 가구 | 250,000 | 12 |
```

ID	제품명	카테고리	가격	재고
101	맥북 프로	전자제품	3,500,000	5
102	데스크 의자	가구	250,000	12

RAG Document parser

Linearization: Docling

ID	제품명	카테고리	가격	재고
101	맥북 프로	전자제품	3,500,000	5
102	데스크 의자	가구	250,000	12


```
{
  "table_metadata": {"rows": 2, "cols": 5},
  "cells": [
    {"row": 0, "col": 0, "content": "ID", "is_header": true},
    {"row": 1, "col": 1, "content": "맥북 프로", "is_header": false}
  ]
}
```